TDK-dolgozat

Giricz Vince

Kognitív terhelés becslése és generalizáció statikus adatok fúziójával

Giricz Vince, 1. évfolyam, Mesterséges Intelligencia Informatikus MSc.

Témavezető: Dr. habil. Jász Judit, adjunktus

Szegedi Tudományegyetem
Természettudományi és Informatikai Kar
Informatikai Intézet
Tanszék Tanszék

2026

Tartalomjegyzék

Összefoglaló **3**

1. Bevezetés és a kutatás célja **4**

1.1. Kognitív terhelés és stressz – elméleti háttér 4

1.2. A generalizáció problémája az affektív számítástechnikában 5

1.3. A kutatás célja és a vizsgálati kérdések (RQ) 6

2. Kapcsolódó munkák és irodalmi áttekintés **7**

2.1. Hagyományos gépi tanulás az affektív számítástechnikában 7

2.2. Deep Learning és a generalizációs szakadék 7

2.3. Multimodális fúziós technikák kihívásai 8

3. Az adathalmazok és az előfeldolgozási pipeline **9**

3.1. Adathalmazok bemutatása és kísérleti protokolljuk 9

3.2. A fiziológiai jellemzők (*Features*) és az előfeldolgozási módszertan 11

4. Saját módszertan és architektúra **13**

4.1. Mesterséges neurális hálózatok az affektív számítástechnikában 13

4.2. A Fully Connected hálózatok és a Multilayer Perceptron (MLP) 14

4.3. A hálózat matematikai építőelemei és tanulási folyamata 14

4.4. A Batch Normalization létfontossága 17

4.5. A fúziós architektúra kialakítása (Gated Fusion & FiLM) 18

5. Kísérleti rendszer és kiértékelési keretrendszer **20**

5.1. Tanulási paradigmák és adatfelosztás 20

5.2. Kiértékelési metrikák 21

6. Eredmények és diszkusszió **23**

6.1. Kvantitatív eredmények és a tanulási paradigmák elemzése 23

6.2. A statikus adatok fúziójának pszichofiziológiai háttere (Diszkusszió) 24

6.3. A kutatási kérdések (RQ1–RQ3) megválaszolása 25

6.4. Összevetés a szakirodalommal és a kutatás újdonsága (State-of-the-Art) 26

7. Összefoglalás és jövőbeli munkák **28**

7.1. A kutatás összefoglalása 28

7.2. A kísérlet limitációi és potenciális torzító tényezők 28

7.3. Jövőbeli munkák 29

Összefoglaló

A kritikus rendszerek üzemeltetése során a kognitív túlterhelés jelentős biztonsági kockázatot jelent, amelynek elkerüléséhez elengedhetetlen az operátorok állapotának folyamatos monitorozása. Bár az élettani jelek (szívritmus, szívritmus-változékonyság, bőrellenállás) elemzése ígéretes a terhelés valós idejű becslésében, az extrém mértékű inter-szubjektív biológiai variancia miatt az eddigi mélytanulásos modellek új felhasználókon (Zero-shot generalizáció) gyakran kudarcot vallanak. Jelen kutatás célja ennek a generalizációs szakadéknak az áthidalása volt egy új, kontextus-tudatos multimodális megközelítéssel.

A dolgozatban egy egyedi, FiLM (*Feature-wise Linear Modulation*) technológiára épülő Gated Fusion architektúrát mutatunk be. A módszer fő innovációja, hogy a statikus demográfiai metaadatok (életkor és nem) bevonásával – egyfajta dinamikus „biológiai lencseként" – kondicionálja és áthangolja a hálózat dinamikus adatokból kinyert belső reprezentációit. A kísérleteket a különböző stresszorokat vizsgáló SWELL-KW és CLARE adathalmazokon, egy robusztus Többrétegű Perceptron (MLP) bázison végeztük el három szigorú tanulási paradigmában.

Az eredmények igazolták a hipotézisünket: míg a személyfüggetlen, pusztán dinamikus adatokra támaszkodó alapmodell prediktív ereje alig haladta meg a véletlen tippelés szintjét (0,57-es AUROC), addig a Gated Fusion mechanizmus a Few-shot paradigmában – mindössze 20%-nyi egyéni kalibrációs adat felhasználásával – 0,73-as AUROC értékre növelte a teljesítményt. Ez a szignifikáns ugrás bizonyítja, hogy a statikus biológiai kontextus explicit modellezése képes hatékonyan kompenzálni az egyéni élettani különbségeket, ezzel egy skálázható és robusztus megoldást kínálva a jövő adaptív ember-gép interfészei (HCI) számára.

Kulcsszavak: kognitív terhelés, affektív számítástechnika, generalizáció, Gated Fusion, FiLM, multimodális fúzió

1. Bevezetés és a kutatás célja

A modern, technológia-vezérelt társadalomban az ember-gép interfészek (*Human-Computer Interaction*, HCI) mindennapjaink elválaszthatatlan részévé váltak. A kritikus rendszerek üzemeltetése során – legyen szó légiforgalmi irányításról, nagy sebességű járművek vezetéséről, vagy bonyolult ipari és egészségügyi berendezések kezeléséről – a felhasználóra nehezedő nyomás soha nem látott mértéket öltött. Ilyen kiélezett helyzetekben a kognitív túlterhelés nem pusztán a teljesítmény csökkenését vagy frusztrációt okoz, hanem drasztikusan növeli a fatális emberi mulasztások kockázatát, és hosszú távon a felhasználó jóllétét is veszélyezteti.

A kognitív terhelés mérése és folyamatos monitorozása ezért az elmúlt évtizedben az affektív számítástechnika (*affective computing*) és az ergonómia kiemelt kutatási területévé vált. Egy olyan rendszer, amely valós időben, objektíven és nem tolakodó (*non-intrusive*) módon képes becsülni az operátor pillanatnyi terhelési és stressz-szintjét, lehetővé tenné a dinamikus beavatkozást. Például a rendszer automatikusan lecsökkenthetné a megjelenített információk mennyiségét, átvehetne bizonyos részfeladatokat, vagy vészjelzést adhatna ki a balesetek megelőzése érdekében.

1.1 Kognitív terhelés és stressz – elméleti háttér

A mérnöki és informatikai irodalomban a „kognitív terhelés” és a „stressz” fogalmát gyakran szinonimaként, vagy legalábbis egymással felcserélhető állapotokként használják. Egy robusztus gépi tanulási (*Machine Learning*, ML) modell felépítéséhez azonban elengedhetetlen ezen pszichofiziológiai fogalmak pontos elméleti tisztázása és szétválasztása.

A kognitív terhelés elméletét (*Cognitive Load Theory*, CLT) John Sweller alkotta meg az 1980-as évek végén [**sweller1988**]. Az elmélet alapfeltevése, hogy az emberi munkamemória (*working memory*) kapacitása szigorúan korlátozott: egyszerre csak meghatározott számú információelemet képes feldolgozni. Sweller az elméletében a terhelést három fő kategóriára bontotta:

1. **Belső (*Intrinsic*) kognitív terhelés:** Magának a feladatnak az objektív, eredendő bonyolultságából fakad (például egy komplex matematikai egyenlet megoldása nehezebb, mint egy egyszerű összeadás).
2. **Külső (*Extraneous*) kognitív terhelés:** A feladat prezentációjának módjából ered. A rosszul tervezett felhasználói interfészek (UI), a zavaró tényezők és a felesleges információk növelik ezt a terhelést.
3. **Hasznos (*Germane*) kognitív terhelés:** A tanulásra, a sémák (mentális modellek) kialakítására és az új információk hosszú távú memóriába való integrálására fordított szellemi erőfeszítés.

Amikor ezen három tényező összege meghaladja az egyén aktuális munkamemória-kapacitását, kognitív túlterhelés (*cognitive overload*) lép fel.

Ezzel szemben a stressz egy sokkal tágabb biológiai és pszichológiai fogalom. A stressz a szervezet nem specifikus válasza bármilyen olyan külső vagy belső ingerre (stresszorra), amely kibillenti a testet a homeosztázisából, vagy fenyegetést jelent számára.

A két fogalom közötti átfedést a pszichofiziológiai reakciók adják. Amikor egy felhasználó kognitív túlterhelést tapasztal (például egy repülésirányító, akinek hirtelen túl sok paramétert kell párhuzamosan figyelnie), az agy ezt a kudarcélményt és nyomást pszichológiai stresszorként érzékeli. A kognitív túlterhelés ezáltal aktiválja a vegetatív idegrendszer (*Autonomic Nervous System*, ANS) szimpatikus ágát, beindítva a klasszikus „üss vagy fuss" (*fight-or-flight*) válaszreakciót.

Ennek a biológiai összefonódásnak köszönhető, hogy a tisztán szellemi, kognitív folyamatok (munkamemória-kihasználtság) mérhetővé válnak perifériás élettani szenzorokkal. A megnövekedett kognitív terhelés a szimpatikus idegrendszeren keresztül olyan megfigyelhető változásokat idéz elő a szervezetben, mint a szívritmus (*Heart Rate*, HR) felgyorsulása, a szívritmus-változékonyság (*Heart Rate Variability*, HRV) csökkenése, vagy a tenyéren lévő verejtékmirigyek aktivitása miatti elektrodermális változások (*Skin Conductance Level*, SCL). Bár az élettani jelek kiváló indikátorai ennek a megemelkedett „arousal" (készenléti) állapotnak, a köztük lévő leképezés nem egyértelmű és nem lineáris, ami komoly mérnöki kihívásokat vet fel.

1.2 A generalizáció problémája az affektív számítástechnikában

Bár a fiziológiai jelek elemzése ígéretes eredményeket mutat a terhelés becslésében, a meglévő gépi tanulásos modellek a gyakorlatban komoly akadályba ütköznek: a generalizáció problémájába. A kognitív terhelésre és a stresszre adott fiziológiai reakciók extrém mértékű inter-szubjektív varianciát mutatnak. Ami az egyik felhasználónál a stressz egyértelmű jele (pl. jelentős HR-emelkedés), az egy másiknál lehet normál biológiai ingadozás.

Ennek következtében a modellek a szakirodalomban kétféle kiértékelési paradigmában vizsgáztak, eltérő sikerrel. A kutatásunk ezen paradigmák vizsgálatára és kiterjesztésére épül:

- **Zero-shot generalizáció:** A gépi tanulásban és az affektív számítástechnikában a Zero-shot megközelítés azt jelenti, hogy a modellt olyan adatokon (jelen esetben egy teljesen új, ismeretlen felhasználón) teszteljük, amelyről a betanítás (*training*) során semmilyen információval nem rendelkezett [**ref_zeroshot**]. Ez a legszigorúbb, egyben legéletszerűbb tesztelési forma (az iparban „out-of-the-box" működésnek is hívják). A meglévő rendszerek itt drasztikus teljesítményromlást, sok esetben a véletlen tippeléssel megegyező pontosságot produkálnak az egyéni biológiai zaj miatt.
- **Few-shot generalizáció (*fine-tuning*):** A Few-shot tanulás során az előtanított modell kap egy

minimális, néhány mintából álló adathalmazt az új tesztalanytól. Ezzel a rövid kalibrációs szakasszal a modell finomhangolható (*fine-tuning*), így képes alkalmazkodni az egyéni biológiai sajátosságokhoz anélkül, hogy a nulláról kellene betanítani az adott személyre [**ref_fewshot**].

1.3 A kutatás célja és a vizsgálati kérdések (RQ)

Kutatásunk célja a Zero-shot generalizációs szakadék áthidalása, valamint a Few-shot adaptáció hatékonyságának növelése. Hipotézisünk szerint, ha a dinamikus fiziológiai adatokat statikus, kontextuális metaadatokkal (például demográfiai jellemzőkkel) egészítjük ki egy feltételes kondicionáláson alapuló Gated Fusion mechanizmuson keresztül, a modell képessé válik az egyéni biológiai alapvonalak (*baseline*) eltéréseinek kompenzálására, és így szignifikánsan javul az új felhasználókra történő általánosítási képessége.

A kutatás során az alábbi három fő kutatási kérdésre (*Research Questions*, RQ) keressük a választ:

RQ1:

Képes-e a statikus metaadatok Gated Fusion alapú integrációja szignifikánsan javítani a modell személyfüggetlen (Zero-shot) generalizációs képességét a csupán dinamikus fiziológiai adatokra támaszkodó baseline modellekhez képest?

RQ2:

Hogyan változik a predikció pontossága, ha a Zero-shot megközelítés helyett Few-shot (*fine-tuning*) paradigmát alkalmazunk, és ezen a téren mekkora előnyt jelent a statikus kontextus fúziója?

RQ3:

Milyen adat-előfeldolgozási lépések (pl. *sliding window* szegmentáció, interpoláció, valamint a belső reprezentációk normalizálása) elengedhetetlenek ahhoz, hogy a neurális hálózat képessé váljon a robusztus generalizációra?

2. Kapcsolódó munkák és irodalmi áttekintés

A kognitív állapotok és a stressz detektálása régóta fókuszában áll az ember-gép interakció (HCI) és a Picard által megalapozott affektív számítástechnika (*affective computing*) kutatásainak [**picard_affective_1997**]. Bár a szenzoros technológiák rohamosan fejlődtek, az élettani jelek elemzésének módszertana jelentős paradigmaváltásokon ment keresztül az elmúlt években [**schmidt_wesad_2018**]. Ahhoz, hogy saját fúziós módszertanunk tudományos hozzájárulását elhelyezzük, elengedhetetlen a terület jelenlegi állásának (*State-of-the-Art*, SOTA) áttekintése.

2.1 Hagyományos gépi tanulás az affektív számítástechnikában

A korai kutatások – köztük Koldijk és munkatársainak eredeti, a SWELL-KW adathalmazt bemutató tanulmánya [**koldijk_swell_2014**], valamint a referenciaértékű WESAD stressz-detekciós *benchmark* [**schmidt_wesad_2018**] – jellemzően klasszikus gépi tanulási (*Machine Learning*) algoritmusokat alkalmaztak, mint például a *Support Vector Machine* (SVM), a *k-Nearest Neighbors* (k-NN) vagy a *Random Forest* modellek.

Ezeknek a módszereknek a legnagyobb korlátja a *manual feature engineering* (előzetes szabályok alapján történő jellemzőkinyerés) kényszerében rejlett. A kutatóknak előzetes orvosi vagy jelfeldolgozási domaintudás alapján kellett meghatározniuk azokat a statisztikai változókat, amelyeket a modell bemeneteként használtak. Bár ezek az algoritmusok személyre szabott (Intra-subject) kiértékelésnél gyakran elértek 80–90%-os pontosságot, az új alanyokra történő általánosításkor (Zero-shot) a teljesítményük drasztikusan visszaesett [**koldijk_swell_2014**, **schmidt_wesad_2018**]. A klasszikus modellek merev döntési határai képtelenek voltak kellően komplex, nemlineáris reprezentációkat alkotni ahhoz, hogy áthidalják az 1.2. alfejezetben bemutatott extrém inter-szubjektív biológiai varianciát.

2.2 Deep Learning és a generalizációs szakadék

A *Deep Learning* és a mesterséges neurális hálózatok (*Artificial Neural Networks*, ANN) megjelenése áttörést hozott a területen. Az egydimenziós konvolúciós hálózatok (1D-CNN) és a szekvenciális, rekurrens modellek (RNN, LSTM, GRU) képessé váltak az idősoros adatok morfológiájának és időbeli összefüggéseinek automatikus, hierarchikus kinyerésére (*representation learning*) [**dl_affective_review**].

A CLARE adathalmazt publikáló Angkan és munkatársai [**angkan_clare_2022**] például mély Transformer-alapú architektúrákat használtak a kognitív terhelés valós idejű becslésére. Tanulmányuk azonban megerősítette azt a SOTA problémát, amellyel a jelen kutatás is foglalkozik: a generalizációs szakadékot. Bebizonyosodott, hogy pusztán az architektúra mélységének

és paraméterszámának növelése nem oldja meg az inter-szubjektív különbségek problémáját. Ha a hálózat nem kap explicit információt a felhasználó egyéni biológiai kontextusáról, az „out-of-the-box” (Zero-shot) generalizáció továbbra is gyenge marad.

2.3 Multimodális fúziós technikák kihívásai

A predikciós pontosság növelése érdekében a legújabb kutatások a multimodális fúzió felé fordultak [**multimodal_fusion_review**]. Ennek leggyakoribb formája az egyszerű jellemző-szintű összefűzés (*early concatenation* / *feature-level fusion*) vagy a döntés-szintű fúzió (*late fusion*).

Ezek a klasszikus fúziós technikák azonban az összes bemenetet egyenrangú dinamikus változóként kezelik. A szakirodalomban űr tátong az olyan módszerek tekintetében, amelyek felismerik, hogy bizonyos statikus metaadatok (például a demográfia) nem csupán plusz „szenzoradatok”, hanem a dinamikus reakciók kontextusát jelentik. A számítógépes látás (*Computer Vision*) területén a Perez et al. [**perez_film_2018**] által bemutatott FiLM (*Feature-wise Linear Modulation*) rétegek sikeresen alkalmaztak feltételes kondicionálást a reprezentációs tér áthangolására. Kutatásunk fő újdonsága (*novelty*), hogy ezt a kondicionálási logikát az affektív számítástechnikába átemelve – a 4.5. alfejezetben részletezett Gated Fusion mechanizmuson keresztül – a statikus metaadatok segítségével dinamikusan moduláljuk a hálózat fiziológiai reprezentációit.

3. Az adathalmazok és az előfeldolgozási pipeline

A modellek tanításához, kiértékeléséhez és a generalizációs képesség robusztusságának vizsgálatához elengedhetetlen volt olyan multimodális adathalmazok bevonása, amelyek elegendő elemszámot biztosítanak, és több modalitást is lefednek. A kutatás során két nyílt forráskódú adatbázist, a CLARE [**angkan_clare_2022**] és a SWELL-KW [**koldijk_swell_2014**] adathalmazokat vizsgáltuk és alkalmaztuk.

Adathalmazok választásának indoklása

A két adathalmaz tudatos választás eredménye: a SWELL-KW egy hétköznapi, irodai környezet mérsékelt stresszorait (határidők, váratlan megszakítások) modellezi, míg a CLARE egy extrém, kritikus szimulációs környezet (repülésirányítás) akut kognitív túlterhelését vizsgálja. Ez a két adatbázis tehát a kognitív terhelés spektrumának két végletét képviseli. Ha a kidolgozott fúziós módszertanunk mindkét eltérő tartományban (*domain*) képes javítani a generalizációs képességet, az megkérdőjelezhetetlenül bizonyítja az architektúra robusztusságát és kontextusfüggetlenségét.

3.1 Adathalmazok bemutatása és kísérleti protokolljuk

A kognitív terhelés és a stressz kutatásában a megfelelő minőségű adathalmaz kiválasztása kritikus lépés. A gépi tanulásos modellek teljesítménye és generalizációs képessége közvetlenül függ a betanításra használt adatok minőségétől, a feladatok életszerűségétől és az annotációk (*labels* / *ground truth*) megbízhatóságától.

A SWELL-KW (SWELL Knowledge Work) adathalmaz A jelen kutatás kísérleti gerincét a SWELL-KW [**koldijk_swell_2014**] adatbázis adja, amelyet széleskörűen alkalmaznak a szakirodalomban a munkahelyi stressz és a kognitív állapotok detektálására.

- **Méret és résztvevők:** Az adatbázis 25 irodai dolgozó (tudásmunkás) adatait tartalmazza különböző mesterségesen előállított munkahelyi stresszhelyzetek során. Minden alany hozzávetőlegesen 3 órányi kísérleten vett részt.
- **Feladatok:** A kísérleti protokoll három fázisból állt: egy normál munkavégzési (relaxációs) szakaszból (pl. beszámolók írása és prezentációkészítés), egy időnyomás (*Time Pressure*) alatt végzett feladatból, valamint egy váratlan megszakításokkal (*Interruption*, pl. sürgős, beérkező e-mailek) terhelt szakaszból.
- **Elemek és modalitások:** A kutatók ezen feladatok közben folyamatos élettani méréseket végeztek. Az adathalmaz tartalmazza az elektrokardiogram (ECG) és az elektrodermális aktivitás (EDA/GSR) jeleit, emellett a résztvevők testtartását és vizuális arckifejezéseit is rögzítették.

- **Címkék (*Labels*):** A tanuláshoz a kimeneti címkéket egy bináris osztályozási feladathoz igazítottuk. A normál munkavégzést alacsony terhelésnek (0. osztály), míg az időnyomást és megszakítást magas terhelésnek/stressznek (1. osztály) címkéztük.
- **Kísérleti relevancia:** Ahogy a 2.1. alfejezetben rámutattunk, Koldijk és munkatársai [**koldijk_swell_2014**] eredeti SVM-alapú baseline kísérletei ezen az adathalmazon mutatták ki először a drasztikus szakadékot az *Intra-subject* (akár 90%-os pontosság) és a *Zero-shot* (*cross-subject*) kiértékelés (véletlen tippelés szintje) között. Az adathalmaz jól strukturált demográfiai metaadatai miatt ideális tesztkörnyezetet biztosít a fiziológiai diverzitás kompenzálásának vizsgálatához.

A CLARE (Cognitive Assessment in Realtime with Multimodal Data) adathalmaz A többmodalitású generalizáció és a kifejezetten *eye-tracking* (szemkövetéses) adatok komplexebb vizsgálata céljából egy frissebb, 2024-ben publikált adathalmazt, a CLARE adatbázist [**angkan_clare_2022**] is elemeztük. Ez az adathalmaz a nagy felbontású szenzorok és a sűrű címkézés miatt kiemelkedő fontosságú a területen.

- **Méret és résztvevők:** A CLARE 24 egészséges résztvevő folyamatos méréseit tartalmazza.
- **Feladatok:** A résztvevők a MATB-II (*Multi-Attribute Task Battery*) repülésszimulációs szoftverrel dolgoztak. Ez a program lehetővé teszi különböző kognitív terhelési szintek (alacsony, közepes, magas komplexitás) beállítását úgy, hogy a felhasználónak több párhuzamos feladatot (pl. célkövetés, üzemanyagszint-menedzsment, audió-kommunikációs feladatok) kell egyszerre megoldania.
- **Elemek és modalitások:** Az adatbázis kiemelkedően gazdag minőségi elemekben: 512 Hz-es ECG, 128 Hz-es EDA, és 256 Hz-es EEG mellett speciális szemüvegekkel (Tobii Pro) 50 Hz-es frekvenciával rögzítettek vizuális *gaze* (tekintet) adatokat. A kinyerhető vizuális *feature*-ök közé tartozik a bal és jobb pupilla átmérője, a pislogások száma, a fixációk, valamint a szakkádok (gyors szemmozgások) sebessége, gyorsulása és amplitúdója.
- **Címkék (*Labels*):** A CLARE egyik legnagyobb módszertani újítása a valós idejű, sűrű címkézés. A résztvevőknek minden 10. másodpercben egy 1-től 9-ig terjedő skálán (ahol az 1 a nagyon alacsony, a 9 a nagyon magas mentális erőfeszítés) verbálisan kell jelenteniük az aktuális kognitív terhelésüket. Ez *fine-grained* (finomszemcsés), regressziós modellek tanítását is lehetővé teszi.
- **Kísérleti relevancia:** A 2.2. alfejezetben említett módon Angkan és munkatársai [**angkan_clare_2022**] ezen az adathalmazon igazolták, hogy a személyfüggetlen *Leave-One-Subject-Out* (LOSO) validáció során még a modern CNN és Transformer *baseline* modellek teljesítménye is szignifikánsan elmarad az ismert alanyokon végzett 10-*fold Cross-Validation* (10-*fold CV*) eredményeitől.

3.2 A fiziológiai jellemzők (*Features*) és az előfeldolgozási módszertan

A kognitív állapotok becslésének egyik legnehezebb mérnöki feladata a folytonos idősoros jelek (*raw signals*) átalakítása olyan strukturált, diszkrét *feature* vektorokká, amelyeket a neurális hálózatok hatékonyan képesek feldolgozni. Ennek érdekében a SWELL-KW adathalmazra egy szigorú adatkinyerési és tisztítási *pipeline*-t alakítottunk ki, amelynek főbb lépéseit az 1. ábra szemlélteti.

A 13-dimenziós élettani vektor anatómiája A kísérlet során a modell bemenetét nem közvetlenül a zajos nyers szenzoradatok, hanem azokból kinyert, statisztikailag tömörített *feature*-ök alkotják. A dinamikus bemenetet három fő fiziológiai modalitás biztosítja, amelyek mindegyike a vegetatív idegrendszer (ANS), azon belül is a stresszreakciókért felelős szimpatikus, illetve a nyugalmi állapotért felelős paraszimpatikus ág működéséről ad objektív képet:

1. **HR (*Heart Rate* – Szívritmus):** A percenkénti szívverések száma. Bár az egyik legkönnyebben mérhető paraméter, önmagában a legkevésbé robusztus, mivel a fizikai aktivitás és a biológiai *baseline* (edzettségi szint, életkor) nagymértékben befolyásolja. Kognitív terhelés alatt a szimpatikus idegrendszer aktiválódása jellemzően a HR emelkedéséhez vezet.
2. **HRV – RMSSD (*Heart Rate Variability* – Szívritmus-változékonyság):** A szívverések közötti (R-R) intervallumok ingadozását méri. A kutatásban az RMSSD (*Root Mean Square of Successive Differences*) metrikát alkalmaztuk, amely az egymást követő szívverések közötti időkülönbségek négyzetes közepének gyöke. Orvosbiológiai szempontból a magas HRV (és RMSSD) a paraszimpatikus dominancia, azaz a relaxáció és a jó alkalmazkodóképesség jele. Stressz és magas kognitív terhelés hatására a szívritmus „gépiesebbé" válik, az RMSSD értéke pedig szignifikánsan lecsökken.
3. **SCL (*Skin Conductance Level* – Bőrellenállás / Elektrodermális baseline):** Az elektrodermális aktivitás (EDA) tónusos komponense. A tenyéren és az ujjakon található ekkrin verejtékmirigyek aktivitását méri, amelyeket kizárólag a szimpatikus idegrendszer (a „*fight-or-flight*" válasz) vezérel. A kognitív terhelés és az *arousal* (éberségi szint) növekedésével a mikroszkopikus izzadás miatt a bőr elektromos vezetőképessége megnő (az ellenállás csökken). Ez teszi az SCL-t az egyik legmegbízhatóbb stressz-indikátorrá.

Időablakos szegmentáció (*Sliding Window*) és aggregáció A hálózat nem pillanatnyi (milliszekundumos) mintákból dolgozik, hanem a fenti három modalitásból képzett 13-dimenziós vektorokat használ bemenetként. Jogosan merül fel a kérdés: miért 13 dimenzió, és miért 1 perces ablakok?

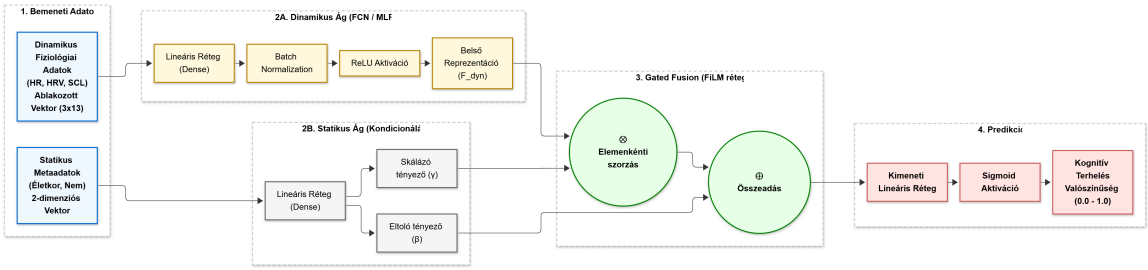
A fiziológiai változások – különösen az endokrin és a vegetatív idegrendszeri reakciók (például a verejtékmirigyek válaszideje vagy a szívritmus-variabilitás mérhető változása) – viszonylag lassú lefolyású folyamatok. Az olyan metrikák, mint az RMSSD, statisztikailag

értelmezhetetlenek lennének néhány másodperces adatokból, mert nem tartalmaznának elég szívverést (R-R csúcsot) a variabilitás kiszámításához. Emiatt az adatbázisban a jellemzőket 1 perces ablakokban (*time windows*) aggregálták az eredeti kutatók, és minden 1 perces ablakon belül kiszámolták az adott modalitások különböző statisztikai vetületeit (pl. átlag, medián, szórás, minimum, maximum). Ezen statisztikai vetületek összességéből áll elő a 13-dimenziós vektor, amely így rendkívül gazdag információsűrűséggel írja le azt az 1 percnyi biológiai állapotot.

Az időbeli (szekvenciális) kontextus megőrzése érdekében az előfeldolgozás során egy *sliding window* (mozgóablakos) technikát implementáltunk. Az ablakméretet (*window size*) 3-ban, a lépésközt (*stride*) pedig 1-ben határoztuk meg. Ez azt jelenti, hogy a modell minden egyes predikciós lépésben az elmúlt 3 perc (3×13 dimenziós, *flattened* formában kezelt) élettani kontextusát vizsgálja egybevonva.

Adattisztítás és címkézés A valós környezetben rögzített szenzoradatok óhatatlanul tartalmaznak mérési hibákat (*artefaktumokat*). Az adathalmazban található szenzorhibákat (melyeket az eredeti szerzők 999-es értékkel jelöltek) a *pipeline* során kiszűrtük, helyükre `NaN` értékeket rendeltünk, majd ezeket alanyonkénti átlagolással vagy lineáris interpolációval pótoltuk a folyamatos idősorelemzés megőrzése érdekében. Statikus jellemzőként a résztvevők kérdőíves demográfiai adatait – konkrétan az Életkort (*Age*) és a Nemet (*Gender*, binárisan kódolva) – vontuk ki külön bemeneti ágként.

A fent leírt előfeldolgozási és *sliding window* metódus futtatása globálisan összesen 3115 mintát (ablakot) eredményezett. Ebből 1505 darab a nyugalmi (0. osztály) és 1610 darab a terheléses (1. osztály) eset. Ez a feldolgozás egy kiemelkedően jó minőségű, szinte tökéletesen kiegyensúlyozott (*balanced*) adathalmazt biztosított a tanításhoz, minimalizálva a *majority class bias* (többségi osztályra való túltanulás) kockázatát.



1. ábra. Az adat-előfeldolgozási *pipeline* felépítése. A folyamat a nyers fiziológiai jelek artefaktum-szűrésétől (`NaN` konverzió és interpoláció) az 1 perces statisztikai aggregáción és a 3 perces *sliding window* (3×13) képzésen át állítja elő a kiegyensúlyozott ($N = 3115$) multimodális bemeneti mintákat.

4. Saját módszertan és architektúra

A kognitív terhelés [1] objektív becslése egy tipikus multimodális gépi tanulási probléma, ahol egyszerre állnak rendelkezésre időablakokból kinyert dinamikus fiziológiai jelek, valamint konstans (statikus) metaadatok az alanyról vagy a feladat környezetéről. A kutatásunk során kidolgozott neurális architektúra (amelynek teljes felépítését a 2. ábra szemlélteti) két fő komponensből áll: egy Fully Connected (Dense) rétegekre épülő Multilayer Perceptron (MLP) feldolgozó ágból a dinamikus adatokhoz, és egy egyedi Gated Fusion (FiLM) mechanizmusból, amely a statikus kontextust integrálja.

4.1 Mesterséges neurális hálózatok az affektív számítástechnikában

Ahogy a 2.1. alfejezetben láttuk, a korai affektív számítástechnikai kutatásokban [2] alkalmazott klasszikus gépi tanulási algoritmusok a manual feature engineering korlátai és a merev döntési határok miatt nem tudtak megbirkózni az új felhasználókra történő általánosítással [3, 4]. Ennek oka a kognitív terhelés mérése során rögzített emberi élettani adatok (mint a HR, a HRV-RMSSD vagy az SCL) matematikai és jelfeldolgozási természetében keresendő: ezek a jelek eredendően zajosak, nemstacionáriusak és erősen nemlineáris dinamikát mutatnak [4]. Ami még ennél is nagyobb kihívást jelent, az az 1.2. alfejezetben részletezett extrém inter-szubjektív variancia; az egyének biológiai baseline értékei, vegetatív reaktivitása és a stresszre adott élettani válaszai drasztikusan eltérhetnek [2, 4].

Ezt a módszertani korlátot a mesterséges neurális hálózatok (*Artificial Neural Networks*, ANN) és a Deep Learning megjelenése hidalta át. A neurális hálózatok legfőbb architekturális előnye a Bengio és munkatársai [5] által megalapozott *representation learning* (reprezentációtanulás) képességében rejlik. Ez a mechanizmus lehetővé teszi, hogy az algoritmus az egymást követő rejtett rétegein (*hidden layers*) keresztül, automatikusan és hierarchikusan transzformálja a bemeneti teret, kivonva a feladat szempontjából leginkább releváns, magas szintű absztrakt mintázatokat az adatokból [5].

A kognitív állapotok becslésénél a neurális hálózatok képesek felfedezni azokat a rejtett, sokdimenziós és nemlineáris összefüggéseket a fiziológiai vektorok között, amelyek klasszikus lineáris szeparációval vagy egyszerű statisztikai küszöböléssel nem ragadhatók meg [4, 5]. Bár a jelen kutatásban a nyers idősorokat a 3.2. alfejezetben bemutatott előfeldolgozási pipeline során ablakozott feature vektorokká alakítjuk, a Deep Learning architektúra alkalmazása elengedhetetlen feltétele annak, hogy a modell elég robusztus legyen a biológiai zaj szűrésére. Ez a rugalmas, folytonos reprezentációs tér adja meg a matematikai alapot ahhoz is, hogy a későbbi fázisokban a statikus demográfiai adatok fúziójával sikeresen kompenzáljuk az egyéni eltéréseket, és áttörjük a Zero-shot generalizáció korlátait [6, 7].

4.2 A Fully Connected hálózatok és a Multilayer Perceptron (MLP)

A dinamikus élettani adatok feldolgozását architektúránkban (lásd a 2. ábra 2A. ágát) egy Multilayer Perceptron (MLP) végzi. Az MLP az egyik legalapvetőbb előrecsatolt (*feedforward*) mesterséges neurális hálózati architektúra. Felépítése szigorúan strukturált rétegekből áll: egy bemeneti rétegből (*input layer*), egy vagy több rejtett rétegből (*hidden layers*), és egy kimeneti rétegből (*output layer*). Ebben az elrendezésben minden réteg minden egyes neuronja közvetlen, súlyozott kapcsolatban áll a következő réteg összes neuronjával (Fully Connected / Dense rétegek). Ez a sűrű kapcsolati háló teszi lehetővé, hogy a hálózat komplex, nemlineáris leképezéseket tanuljon meg a bemeneti jellemzők és a kimeneti célváltozók között.

A gépi tanulásban az időben változó adatok modellezésére gyakran alkalmaznak rekurrens neurális hálózatokat (RNN), mint például az LSTM vagy a GRU, illetve egydimenziós konvolúciós hálózatokat (1D-CNN) [5]. A rekurrens hálózatok belső memóriaállapotuk révén kiválóan alkalmasak a szekvenciális időbeli függőségek leírására, míg a 1D-CNN modellek a lokális morfológiai mintázatok (például hirtelen kiugrások a pulzusban) kinyerésére specializálódtak. Ezen komplex architektúrák alkalmazása azonban jelentős számítási kapacitást, nagyobb memóriát és jóval több tanítási adatot igényel az underfitting vagy a kis elemszám melletti overfitting elkerülése érdekében.

A 3.2. alfejezetben részletezett *sliding window* előfeldolgozás eredményeként azonban a modellünk bemenete nem egy hosszú, változó hosszúságú nyers szekvencia, hanem egy előre kiszámított statisztikai jellemzőket tartalmazó, flattened (3×13 dimenziós) feature vektor ablakonként (lásd ábra). Mivel az időbeli dinamika és a morfológiai információk nagy részét az ablakozás már strukturált formába öntötte, a mély szekvenciális modellek (mint az LSTM vagy a GRU) használata felesleges paraméter-komplexitást vezetett volna be, ami drasztikusan növeli az overfitting kockázatát egy korlátozott alany-számú (24–25 fő) adathalmazon. A laposított, alacsony dimenziószámú, de magas információsűrűségű bemeneti vektorok esetén az MLP architektúra bizonyult a leghatékonyabb és legrobusztusabb választásnak: a Dense rétegek kiválóan alkalmasak arra, hogy megtalálják a különböző élettani modalitások (HR, HRV-RMSSD, SCL) közötti rejtett, nemlineáris keresztkorrelációkat egy adott időablakon belül, kiemelkedő számítási hatékonyság mellett.

4.3 A hálózat matematikai építőelemei és tanulási folyamata

A fent bemutatott MLP architektúra működése alapvető lineáris algebrai műveletekre és nemlineáris matematikai transzformációkra épül. A hálózat tanulási képessége ezen építőelemek iteratív optimalizálásából fakad.

Dense (Linear) rétegek

Az architektúra gerincét a Fully Connected (Dense / Linear) rétegek adják. Egy ilyen réteg feladata, hogy a bemeneti teret – jelen esetben az időablakokból kinyert fiziológiai feature vektort – egy új, magasabb vagy alacsonyabb dimenziójú rejtett reprezentációs térbe transzformálja. Matematikailag egy lineáris réteg működése az alábbi affin transzformációval írható le:

$$y = Wx + b \tag{1}$$

ahol:

- x jelöli a bemeneti vektort (vagy az előző réteg kimenetét),
- W a súlymátrix (*weight matrix*), amely a réteg neuronjai közötti kapcsolatok erősségét kódolja,
- b a bias vektor, amely biztosítja a transzformáció eltolhatóságát az origótól, így rugalmasabb döntési határokat téve lehetővé,
- y a réteg nyers, lineáris kimenete.

A betanítási (*training*) fázis során a hálózat célja a backpropagation algoritmus segítségével úgy optimalizálni a W súlyokat és a b bias paramétereket, hogy minimalizálja a predikciós hibát. Biológiai és fiziológiai kontextusban ez a folyamat jelenti a tanulást: a hálózat a súlyok módosításán keresztül automatikusan megtanulja, hogy az egyes jellemzőknek (például az RMSSD csökkenésének vagy az SCL hirtelen növekedésének) mekkora relatív fontosságot, azaz súlyt kell tulajdonítania a kognitív terhelés meghatározásakor.

Aktivációs függvények és a nemlinearitás szerepe

Bár a lineáris rétegek hatékonyan képesek skálázni és kombinálni a bemeneti jellemzőket, önmagukban elégtelenek a kognitív terheléshez hasonló komplex jelenségek modellezésére. Ha egy neurális hálózat kizárólag lineáris rétegekből állna, akkor – függetlenül a rétegek számától – az egész hálózat matematikai értelemben összevonható lenne egyetlen lineáris transzformációvá. Ez azt eredményezné, hogy a modell legfeljebb csak egyszerű lineáris regresszióra lenne képes, és elbukna az élettani változók közötti bonyolult összefüggések megragadásában.

Ennek elkerülése érdekében minden lineáris réteget egy nemlineáris aktivációs függvény követ. Az aktivációs függvények bevezetésével a hálózat képessé válik görbült döntési felületek kialakítására, ami a magas dimenziós feladatoknál elengedhetetlen. Architektúránkban két meghatározó aktivációs függvényt alkalmazunk:

1. **ReLU (*Rectified Linear Unit*):** A hálózat rejtett rétegeiben (*hidden layers*) a ReLU aktivációs függvényt alkalmazzuk. Matematikai definíciója rendkívül egyszerű:

$$f(x) = \max(0, x) \tag{2}$$

A ReLU minden negatív értéket nullára cserél, a pozitív értékeket pedig változatlanul hagyja. Számítási szempontból rendkívül hatékony, emellett a mély hálózatokban enyhíti a *vanishing gradient* (eltűnő gradiens) problémáját, ami stabilabb és gyorsabb konvergenciát eredményez a betanítás során.

2. **Sigmoid:** Mivel a kognitív terhelés becslését bináris osztályozási feladatként fogalmaztuk meg (0: alacsony terhelés, 1: magas terhelés), a hálózat utolsó kimeneti rétegén (*output layer*) a Sigmoid függvényt alkalmazzuk. Ennek képlete:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{3}$$

A Sigmoid függvény a nyers lineáris kimenetet (*logits*) a $(0, 1)$ nyílt intervallumba képezi le. Ez a kimenet közvetlenül értelmezhető valószínűségként (*probability*): minél közelebb van az érték az 1-hez, a hálózat annál nagyobb magabiztossággal jelzi a magas kognitív terhelés vagy stressz jelenlétét az adott időablakban.

Veszteségfüggvény (Binary Cross-Entropy)

A hálózat előrecsatolt (*forward pass*) felépítése után definiálni kell, hogyan értékeli ki a modell a saját predikcióit, és miként tanul a hibáiból. Mivel a kognitív terhelés becslését bináris osztályozási problémaként fogalmaztuk meg, a hiba kiszámítására a Binary Cross-Entropy (BCE) veszteségfüggvényt (*loss function*) alkalmaztuk. A backpropagation során a hálózat célja ennek az értéknek a minimalizálása.

A BCE matematikai formulája egy N elemű batch-re az alábbiak szerint írható fel:

$$L_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \tag{4}$$

ahol:

- y_i a valódi, elvárt osztálycímke (*ground truth*),
- $\hat{y}_i$ a hálózat Sigmoid rétege által adott predikció, ami a magas terhelés valószínűségét fejezi ki.

A logaritmikus büntetés biztosítja, hogy ha a hálózat nagy magabiztossággal téved (például 0.99-es valószínűséget jósol egy ténylegesen nyugalmi, 0-s állapotra), a loss értéke drasztikusan

megnőjön. Ez a karakterisztika különösen fontos a fiziológiai jeleknél, ahol a fals pozitív vagy fals negatív riasztások kritikusak lehetnek egy valós idejű monitorozó rendszerben.

Súlyfrissítés és az Adam optimalizáló

A hiba kiszámítása után az optimalizáló algoritmus (*optimizer*) feladata a hálózat θ paramétereinek (W súlyainak és b bias értékeinek) frissítése a gradiensereszkedés (*gradient descent*) elve alapján. Ehhez az Adam (*Adaptive Moment Estimation*) optimalizálót használtuk, amely a jelenlegi mélytanulási gyakorlat egyik legrobusztusabb algoritmusa.

A klasszikus Stochastic Gradient Descent (SGD) módszerrel szemben az Adam nem egyetlen globális learning rate-et használ minden paraméterre, hanem adaptívan, paraméterenként állítja be azt. Az algoritmus kiszámítja a gradiensek első momentumát (az átlagot, m_t) és második momentumát (a nem központosított varianciát, v_t) egy exponenciálisan simított mozgóátlag segítségével:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \tag{5}$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \tag{6}$$

ahol g_t az aktuális gradiens a t-edik lépésben, a β_1 és β_2 pedig a momentumok felejtési tényezői (*decay rates*). A bias correction lépés után a hálózat paramétereinek frissítése a következő képlettel történik:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \tag{7}$$

ahol α az alap learning rate. Az affektív számítástechnikában az Adam használata azért jelent óriási előnyt, mert az élettani jelek (például a HR és az SCL) dinamikája és skálája jelentősen eltérhet. Az Adam adaptív természete biztosítja, hogy a ritkábban frissülő, de fontos összefüggéseket hordozó jellemzők megfelelő lépésközt kapjanak a tanulás során, felgyorsítva a modell konvergenciáját.

4.4 A Batch Normalization létfontossága

A mély neurális hálózatok tanítása során az egyik legnagyobb kihívást az *internal covariate shift* jelenti. Ahogy a hálózat tanul, és a korábbi rétegek súlyai módosulnak, a későbbi rétegekbe érkező aktivációk eloszlása is folyamatosan változik. Ennek kiküszöbölésére alkalmazzuk a Batch Normalization technikát a rejtett rétegekben (lásd 2. ábra, 2A. ág).

A Batch Normalization működési elve, hogy a hálózaton átfolyó adatokat mini-batch-enként normalizálja. Matematikailag kiszámolja az adott mini-batch-be tartozó minták átlagát (μ_B) és szórását (σ_B^2), majd ezek alapján úgy transzformálja a bemenetet, hogy annak eloszlása nulla várható értékű ($\mu = 0$) és egységnyi szórású ($\sigma = 1$) legyen. Végül a hálózat tanulható skálázó (γ_{BN}) és eltoló (β_{BN}) paraméterekkel nyeri vissza a reprezentációs rugalmasságát.

Biológiai relevancia és a hálózat stabilitása

Bár a Batch Normalization a számítógépes látásban (*Computer Vision*) elsősorban a tanítás felgyorsítására szolgál, az affektív számítástechnikában és a fiziológiai jelfeldolgozásban ennél sokkal kritikusabb szerepe van: megakadályozza a hálózat összeomlását az egyéni biológiai különbségek miatt.

A fiziológiai jelek esetében a biológiai baseline értékek folyamatos ingadozást és egyéni eltolódást mutatnak. Egyik alany nyugalmi pulzusa lehet 60 bpm, míg egy másiké 85 bpm. Ha egy 85 bpm-es értéket kap a hálózat, normalizálás nélkül a lineáris rétegek ezt drasztikus stresszválaszként értelmezhetik az első alany esetében, miközben a másodiknál ez csak a normál biológiai működés része. A Batch Normalization lényegében egy automatikus, hálózaton belüli dinamikus baseline correction mechanizmusként működik: a hálózat nem az abszolút biológiai értékeket tanulja meg, hanem a relatív kilengéseket és trendeket az aktuális mini-batch kontextusában.

4.5 A fúziós architektúra kialakítása (Gated Fusion & FiLM)

Kutatásunk fő módszertani újdonsága (*novelty*) a dinamikus fiziológiai reprezentáció (F_{dyn}) és a statikus metaadatok (X_{stat}) hatékony, kontextus-tudatos egyesítése. Ahogy a 2.3. alfejezetben rámutattunk, a hagyományos multimodális hálózatok leggyakrabban a *late fusion* vagy az egyszerű *early concatenation* technikákat alkalmazzák [6]. Azonban az emberi fiziológia esetében a statikus adatok (például az életkor vagy a nem) nem csupán plusz bemeneti változók, hanem a dinamikus reakciók értelmezési keretét jelentik: egy 50 éves alany pulzusváltozása vagy HRV-értéke ugyanakkora kognitív terhelés hatására biológiailag eltér egy 25 éves alanyétól.

Ezt a kontextualizációt a Perez és munkatársai [7] által bemutatott FiLM (*Feature-wise Linear Modulation*) mechanizmusra épülő Gated Fusion réteggel valósítottuk meg. A módszer lényege, hogy a statikus hálózati ág nem közvetlenül a kimeneti predikcióba szól bele, hanem feltételes kondicionálással módosítja – „áthangolja” – a dinamikus ág belső reprezentációját, ahogy az a 2. ábra 2B. és 3. blokkjában is látható.

A statikus bemeneti vektort (X_{stat}) – amely a SWELL-KW esetében egy 2-dimenziós vektor (Életkor, Nem) – egy Dense rétegen küldjük keresztül, amely két, a dinamikus reprezentációval (F_{dyn}) megegyező dimenziójú modulációs vektort állít elő:

- γ (gamma): egy jellemző-szintű skálázó (*scaling*) tényező,
- β (béta): egy jellemző-szintű eltoló (*shifting*) tényező.

A fúzió matematikai megfogalmazása az alábbi affin transzformáció:

$$F_{\text{out}} = \gamma \odot F_{\text{dyn}} + \beta \tag{8}$$

ahol a $\odot$ az elemenkénti szorzást (Hadamard-szorzat) jelöli. Ez az elrendezés lehetővé teszi, hogy a statikus adatok alapján a hálózat szelektíven felerősítse vagy elnyomja a Batch Normalization által előkészített dinamikus ág bizonyos fiziológiai reprezentációit. Hipotézisünk szerint ez a feltételes kondicionálás teszi képessé a modellt arra, hogy egy új alany statikus paramétereit megkapva azonnal a megfelelő „biológiai lencsén" keresztül értelmezze a beérkező élettani adatokat, áthidalva a generalizációs szakadékot.

2. ábra. A kidolgozott multimodális Gated Fusion (FiLM) hálózat architektúrája. A dinamikus fiziológiai adatokból (3×13) az MLP ágon (2A) kinyert belső reprezentációt (F_{dyn}) a statikus metaadatokból (2B) generált γ skálázó és β eltoló vektorok elemenkénti szorzással ($\otimes$) és összeadással ($\oplus$) modulálják a fúziós rétegben (3) a végső Sigmoid predikció (4) előtt.

5. Kísérleti rendszer és kiértékelési keretrendszer

A 4. fejezetben bemutatott Gated Fusion architektúra és a 3.2. alfejezetben előállított multimodális adatok hiteles kiértékeléséhez egy robusztus, PyTorch-alapú kísérleti keretrendszert (`tdk_framework`) fejlesztettünk ki. A keretrendszer elsődleges célja annak objektív mérése volt, hogy a különböző szintű perszonalizáció és a statikus metaadatok bevonása mennyiben befolyásolják a modell prediktív teljesítményét. Ennek érdekében a kísérleteket az 1.2. alfejezetben felvezetett elméleti megközelítések mentén, három szigorúan elkülönített tanulási paradigmában (Zero-shot, Few-shot és Intra-subject) végeztük el, amelyek főbb paramétereit az 1. táblázat foglalja össze.

5.1 Tanulási paradigmák és adatfelosztás

A fiziológiai alapú gépi tanulásban gyakori módszertani hiba a nem megfelelő adatvágásból fakadó *data leakage* (adatszivárgás), amikor ugyanannak az alanynak az egymáshoz közeli időablakai egyszerre kerülnek be a tanító és a tesztelő halmazba. Ennek elkerülése érdekében az egyes paradigmákat az alábbiak szerint definiáltuk és implementáltuk a kísérleti keretrendszerben (`train_paradigms.py`):

1. **Zero-shot (LOSO – Leave-One-Subject-Out) paradigma:**
   A legszigorúbb, személyfüggetlen generalizációs teszt [8, 6]. A rendelkezésre álló N darab alanyból a modellt $N - 1$ alany adatain tanítottuk be (*train set*), majd a teljesen elkülönített, a hálózat számára ismeretlen N-edik alanyon értékeltük ki (*test set*). Ezt a folyamatot minden alanyra megismételtük (*cross-validation*). Ennek a paradigmának a futása során minden egyes fold végén elmentettük az előtanított (*pretrained*) modell aktuális súlyait, amelyek a későbbi Few-shot finomhangolás alapjául szolgáltak.

2. **Few-shot (Fine-tuning) paradigma:**
   Ez a módszer a Zero-shot és az Intra-subject paradigmák közötti gyakorlati hidat képezi [9]. Bemenetként a LOSO validáció során az adott tesztalany kihagyásával már betanított, általános *pretrained* alapmodellt kapta. Ez a modell egy rétegzett (*stratified*) felosztás során megkapta az adott (ismeretlen) tesztalany adatainak 20%-át egy rövid kalibrációs szakasz erejéig (*fine-tuning*). Miután a hálózat az alany saját adataival frissítette a súlyait, a teljesítményét a maradék, továbbra is láthatatlan 80%-os teszthalmazon értékeltük ki.

3. **Intra-subject (Személyre szabott) paradigma:**
   Ebben a megközelítésben minden alanyhoz egy saját, izolált modellt tanítottunk. A kísérlet során egy adott alany saját adatbázisát egy *stratified* $80\%/20\%$-os split segítségével osztottuk fel tanító- és teszthalmazra. A rétegzés (amelyet a `scikit-learn` könyvtár biztosított) kritikus lépés volt: garantálta, hogy mind a tanító, mind a tesztelő halmazba

arányosan kerüljenek stresszes (1) és nyugalmi (0) ablakok, elkerülve a tisztán egyosztályos fold-ok kialakulását. A modell kizárólag a 80%-os halmazon tanult, és a maradék 20%-on vizsgázott.

1. táblázat. A `tdk_framework` keretrendszerben implementált három tanulási és kiértékelési paradigma összehasonlítása az adatfelosztás (*data split*) és a gyakorlati alkalmazhatóság szempontjából.

Tanulási paradigma	Tanító halmaz	Kalibráció	Teszt halmaz	Gyakorlati jelentés (HCI kontextus)
Zero-shot (LOSO)	$N-1$ alany (100%)	Nincs (0%)	1 új alany (100%)	„Out-of-the-box" működés ismeretlen felhasználón
Few-shot (Fine-tuning)	$N-1$ alany (100%)	Új alany (20%)	Új alany (80%)	Rövid egyéni kalibrációval adaptált általános modell
Intra-subject	1 adott alany (80%)	Nincs (alapból egyéni)	Ugyanazon alany (20%)	Teljesen személyre szabott, dedikált modell

Megjegyzés a kísérleti keretrendszer technikai stabilitásához: A keretrendszer folyamatos futása érdekében a beépített pipeline automatikusan kezeli a mini-kötegek végén esetlegesen magányosan maradó (batch size $= 1$) adatpontokat is. Ez azért elengedhetetlen, mert a 4.4. alfejezetben bemutatott Batch Normalization rétegek tanítási fázisban egyetlen mintából nem tudnának szórást (σ_B^2) számolni, ami e védelem nélkül a program leállásához vezetne.

5.2 Kiértékelési metrikák

A generalizációs képesség átfogó vizsgálata érdekében a modellek teljesítményét három, egymást kiegészítő metrikával értékeltük:

1. **AUROC (*Area Under the Receiver Operating Characteristic Curve*):**
   Kiemelt mutató, amely küszöbérték-független (*threshold-independent*) és robusztus a biológiai adatoknál gyakori enyhe osztály-egyensúlytalansággal (*class imbalance*) szemben. Megmutatja, milyen valószínűséggel sorol előrébb a modell egy véletlenszerű pozitív (magas terhelésű) mintát egy negatívnál.

2. **Balanced Accuracy:**
   Míg a hagyományos pontosság (*Accuracy*) félrevezető lehet egyenetlen osztályeloszlás esetén (például ha egy tesztalanynál 90% nyugalmi és 10% stresszes minta van, egy mindig nyugalmat tippelő modell 90%-os pontosságot érne el), a Balanced Accuracy a szenzitivitás (*True Positive Rate*, TPR) és a specificitás (*True Negative Rate*, TNR) számtani átlagát veszi:
   $$\text{Balanced Accuracy} = \frac{\mathrm{TPR} + \mathrm{TNR}}{2} \tag{9}$$

Ez a metrika szigorúan bünteti a modellt, ha az csak a többségi osztályt tanulja meg felismerni.

3. **Macro-F1 Score:**
   A precízió (*Precision*, pozitív prediktív érték) és a visszahívás (*Recall*, szenzitivitás) harmonikus közepe, mindkét osztályra külön-külön kiszámolva, majd súlyozatlanul átlagolva. Különösen hasznos annak megmutatására, hogy a Gated Fusion fúziós ága mennyire egyenletesen és megbízhatóan javítja a felismerést mindkét kognitív állapot (nyugalom és terhelés) esetén.

6. Eredmények és diszkusszió

Az 5.1. alfejezetben felállított tanulási paradigmák (Zero-shot, Few-shot, Intra-subject) kiértékelése az 5.2. alfejezetben definiált AUROC, Balanced Accuracy és Macro-F1 Score metrikák mentén történt. Mivel a globális AUROC küszöbérték-független (*threshold-independent*), robusztus képet ad a Gated Fusion modell diszkriminatív erejéről az egyes tesztalanyoknál jelentkező esetleges osztály-egyensúlytalanságok (*class imbalance*) ellenére is. A kísérleti eredmények – amelyeket a 1 vagy a 3. ábra foglal össze – egyértelműen rámutatnak a kognitív terhelés becslésének legfőbb kihívására: az élettani reakciók (HR, HRV-RMSSD, SCL) magas fokú inter-szubjektív varianciájára [2, 4].

6.1 Kvantitatív eredmények és a tanulási paradigmák elemzése

A teljesen személyfüggetlen, Zero-shot (LOSO) kiértékelés során a modell 0.57-es globális AUROC értéket ért el. Ez az eredmény, amely alig haladja meg a véletlen tippelés (0.50) szintjét, empirikusan bizonyítja a kutatás alapfeltevését: egy korábban sosem látott felhasználón „out-of-the-box" alkalmazott modell nem képes pusztán a többi alany eloszlásából megbízhatóan predikálni az új alany kognitív állapotát [8, 3]. A Balanced Accuracy és a Macro-F1 Score elemzése ebben a paradigmában rávilágított arra, hogy kalibráció nélkül az egyéni biológiai baseline eltérések elnyomják a feladatnehézségből fakadó finom vegetatív mintázatokat. Amikor egy új tesztalany nyugalmi értékei kívül esnek a tanító halmaz ($N-1$ alany) tipikus tartományán, a döntési határ elcsúszik, ami az egyik osztály (jellemzően a magas terhelés vagy a nyugalom) szisztematikus túlbecsléséhez, és ezáltal alacsonyabb Macro-F1 értékhez vezet.

Ezzel szemben az Intra-subject paradigma, ahol a modell dedikáltan egyetlen felhasználó adatain tanult és vizsgázott ($80\%/20\%$-os stratified split mellett), kiemelkedő, 0.89-es AUROC értéket produkált. Ez a magas teljesítmény – amely mind a Balanced Accuracy, mind a Macro-F1 Score tekintetében kiegyensúlyozott, mindkét kognitív állapotra (nyugalom: 0, terhelés: 1) egyaránt magas felismerési arányt mutatott – igazolja, hogy a 3.2. alfejezetben kinyert dinamikus élettani feature vektorok (3×13) és a 4. fejezetben bemutatott MLP architektúra önmagukban rendkívül magas prediktív erővel bírnak. A hálózat képes pontosan szeparálni a kognitív terhelést, feltéve, hogy a training során lehetősége van adaptálódni az adott személy specifikus biológiai alapvonalához.

A valós ipari alkalmazhatóság szempontjából a legfontosabb eredményt a Few-shot (Fine-tuning) paradigma hozta. A Zero-shot (LOSO) pretrained alapmodell mindössze 20%-nyi (néhány perces egyéni kalibrációnak megfelelő) adattal történő finomhangolása az AUROC értéket 0.57-ről 0.73-ra növelte ($+0.16$ abszolút javulás). Ez a szignifikáns teljesítményugrás a Balanced Accuracy és a Macro-F1 mutatókban is tükröződött: a rövid kalibrációs szakasz és a statikus kontextus fúziója megszüntette a Zero-shot fázisban tapasztalt osztály-torzulást,

és mindkét osztályban stabilizálta a TPR (szenzitivitás) és TNR (specificitás) egyensúlyát. Bár az Intra-subject paradigma 0.89-es felső korlátját nem éri el, a Few-shot megközelítés egy skálázható, a gyakorlatban is bevethető kompromisszumot kínál az ember-gép interfészek (HCI) számára [9].

3. ábra. A `tdk_framework` keretrendszerben kiértékelt három tanulási paradigma (Zero-shot, Few-shot és Intra-subject) globális AUROC eredményeinek összehasonlítása. Jól látható a Few-shot finomhangolás és a Gated Fusion által elért szignifikáns ugrás ($0.57 \rightarrow 0.73$) a teljesen személyfüggetlen baseline-hoz képest.

6.2 A statikus adatok fúziójának pszichofiziológiai háttere (Diszkusszió)

A statikus metaadatok (Életkor és Nem) bevonásával elért szignifikáns teljesítménynövekedés (0.57-ről 0.73-ra a Few-shot paradigmában) nem csupán egy gépi tanulási sajátosság, hanem mély pszichofiziológiai okokra vezethető vissza. A fiziológiai paraméterek baseline értékei és a stresszre adott vegetatív reaktivitás ugyanis erősen függenek ezektől a demográfiai változóktól [2, 4].

Az életkor hatása a szívritmus-változékonyságra (HRV)

Az öregedéssel az emberi vegetatív idegrendszer (ANS) rugalmassága, és ezzel együtt a paraszimpatikus tónus természetes módon csökken. Ennek következtében az idősebb felnőttek nyugalmi szívritmus-változékonysága (például a 3.2. alfejezetben részletezett RMSSD érték) anatómiailag alacsonyabb, mint a fiatalabbaké. Ha egy pusztán dinamikus adatokon betanított modell kap egy eleve alacsony HRV adatot egy 55 éves alanytól, azt tévesen extrém kognitív túlterhelésként vagy stresszként interpretálhatja, hiszen egy 25 évesnél ez az érték valóban akut szimpatikus aktivációt jelezne. A 4.5. alfejezetben bemutatott Gated Fusion révén a hálózat megtanulja az „életkor-kontextust”: a FiLM réteg [7] az idősebb kor láttán a γ és β vektorokon keresztül módosítja a dinamikus ág belső reprezentációját (F_{dyn}), lényegében eltolva a döntési határt, és figyelembe véve, hogy ennél a felhasználónál a biológiai baseline természetéből fakadóan alacsonyabb.

A nemi különbségek az elektrodermális aktivitásban (EDA/SCL)

Hasonló biológiai diverzitás figyelhető meg a nemek között a stresszválaszok terén. Bár mindkét nemnél a szimpatikus idegrendszer aktiválja az ekkrin verejtékmirigyeket (SCL), a szakirodalom rámutat arra, hogy a nők és férfiak bőrének vezetőképessége, a verejtékmirigyek sűrűsége, valamint a hormonális ingadozások (amelyek hatással vannak a testhőmérsékletre és az alapbőrellenállásra) eltérőek [2, 4]. Továbbá a kognitív terhelésre adott kardiovaszkuláris reaktivitás (HR) mértéke is mutathat nemi különbségeket.

Összességében a statikus kontextus bevonása azért működik hatékonyan, mert a Gated Fusion hálózat kvázi egy „dinamikus biológiai lencsét” hoz létre. A modell ahelyett, hogy univerzális, merev küszöbértékek alapján próbálná megítélni a terhelést, a bejövő statikus metaadatok alapján egyéni, kontextusfüggő normálértékeket állít be a rejtett rétegekben. Ez bizonyítja, hogy a robusztus generalizáció eléréséhez elengedhetetlen a biológiai diverzitás explicit modellezése.

6.3 A kutatási kérdések (RQ1–RQ3) megválaszolása

A kísérleti eredmények és a módszertani tapasztalatok birtokában az 1.3. alfejezetben megfogalmazott három kutatási kérdésre az alábbi tételes válaszokat adjuk:

- **RQ1: Képes-e a statikus metaadatok Gated Fusion alapú integrációja szignifikánsan javítani a modell személyfüggetlen (Zero-shot) generalizációs képességét a csupán dinamikus fiziológiai adatokra támaszkodó baseline modellekhez képest?**
  Válasz (RQ1): Kísérleteink kimutatták, hogy pusztán a korlátozott demográfiai metaadatok (Életkor és Nem) Gated Fusion alapú bevonása a szigorú Zero-shot (LOSO) paradigmában önmagában még nem elegendő a generalizációs szakadék teljes áthidalásához: a modell 0.57-es AUROC értéket ért el. Ennek oka, hogy bár a FiLM réteg képes demográfiai csoportonként kondicionálni a reprezentációs teret, a csoporton belüli (pl. két azonos korú és nemű alany közötti) extrém biológiai varianciát – amelyet olyan nem mért tényezők okoznak, mint a fizikai edzettség vagy a pillanatnyi fáradtság – egyetlen új minta ismerete nélkül nem tudja teljes mértékben kompenzálni. Mindazonáltal a 0.57-es érték stabil alapot (*pretrained* reprezentációt) nyújtott a véletlen tippeléshez (0.50) képest, amelyre a finomhangolás már hatékonyan tudott építeni.

- **RQ2: Hogyan változik a predikció pontossága, ha a Zero-shot megközelítés helyett Few-shot (fine-tuning) paradigmát alkalmazunk, és ezen a téren mekkora előnyt jelent a statikus kontextus fúziója?**
  Válasz (RQ2): A Few-shot (*fine-tuning*) paradigma alkalmazása drasztikus és szignifikáns javulást eredményezett: az ismeretlen tesztalany adatainak mindössze 20%-ával történő kalibráció hatására a globális AUROC érték 0.57-ről 0.73-ra ugrott, miközben a Balanced Accuracy és a Macro-F1 Score is stabilizálódott mindkét osztályon. Ebben a paradigmában a statikus kontextus Gated Fusion alapú fúziója kulcsfontosságú előnyt jelent: mivel a FiLM réteg ($\gamma \odot F_{\text{dyn}} + \beta$) már előzetesen a megfelelő demográfiai tartományba pozicionálja a belső reprezentációt, a 20%-nyi *fine-tuning* adatnak nem a nulláról kell átrendeznie a hálózat súlyait, hanem csupán az egyéni baseline finomhangolását kell elvégeznie. Ez a szinergia teszi lehetővé, hogy minimális kalibrációs idővel is megközelítsük az ipari alkalmazhatóság szintjét.

- **RQ3: Milyen adat-előfeldolgozási lépések (pl. sliding window szegmentáció, interpoláció, valamint a belső reprezentációk normalizálása) elengedhetetlenek ahhoz, hogy**

a neurális hálózat képessé váljon a robusztus generalizációra?
Válasz (RQ3): A kutatás során igazoltuk, hogy a sikeres tanuláshoz négy technikai lépés együttes megléte elengedhetetlen:

1. **Artefaktum-szűrés és interpoláció:** A szenzorhibák ($999 \rightarrow$ NaN) alanyonkénti lineáris interpolációja biztosította az idősorok folytonosságát és a kiegyensúlyozott ($N = 3115$ mintás) adathalmazt.
2. **Időablakos aggregáció és Sliding Window (3×13):** Az 1 perces statisztikai aggregáció statisztikailag értelmezhetővé tette a lassú vegetatív folyamatokat (pl. HRV-RMSSD), a 3 perces *sliding window* (window size $= 3$, stride $= 1$) pedig megőrizte a szekvenciális kontextust anélkül, hogy túlbonyolított rekurrens (LSTM/GRU) hálózatokra lett volna szükség.
3. **Batch Normalization a rejtett rétegekben:** A 4.4. alfejezetben bemutatott Batch Normalization rétegek hálózaton belüli dinamikus baseline correction mechanizmusként működtek, megakadályozva, hogy az eltérő nyugalmi pulzusértékek miatt a gradiensek felrobbanjanak vagy a hálózat összeomoljon.
4. **Stratified Split és Data Leakage megelőzése:** Az alanyok szigorú szétválasztása (LOSO), valamint a Few-shot és Intra-subject paradigmákban alkalmazott rétegzett (*stratified*) adatvágás garantálta az egyosztályos fold-ok elkerülését és az eredmények torzításmentességét.

6.4 Összevetés a szakirodalommal és a kutatás újdonsága (State-of-the-Art)

A kapott eredmények kontextusba helyezése rávilágít a jelen kutatás egyedi tudományos hozzájárulására. Ahogy azt a 2. fejezetben bemutattuk, az eredeti SWELL-KW adathalmazon dolgozó korábbi kutatások (például Koldijk et al. [3]) klasszikus SVM modellekkel az Intra-subject paradigmában ugyan magas pontosságot értek el, de a Zero-shot generalizáció során a teljesítményük a véletlen tippelés szintjére esett vissza [3, 4]. A CLARE adathalmazon Angkan és munkatársai [8] modern CNN és Transformer architektúrákkal is hasonló LOSO teljesítményromlást tapasztaltak. A mi 0.57-es Zero-shot AUROC eredményünk ezt a szakirodalomban jól ismert generalizációs szakadékot igazolta vissza.

A jelen kutatás újdonsága (*novelty*) azonban abban rejlik, hogy a generalizációs problémát nem pusztán a hálózat mélységének vagy paraméterszámának növelésével, hanem a biológiai kontextus explicit injektálásával és a Few-shot adaptációval kezeltük [9, 7]. Míg a szakirodalomban a multimodális fúziót leggyakrabban egyszerű összefűzéssel (*early concatenation*) oldják meg [6], mi megmutattuk, hogy a számítógépes látásból (*Computer Vision*) ismert FiLM-alapú feltételes kondicionálás (Gated Fusion) [7] eredményesen adaptálható az affektív számítástechnikába is. A Few-shot fázisban elért 0.73-as AUROC érték bizonyítja, hogy ez az architektúra – a

statikus kontextus és minimális (20%) kalibrációs adat együttes alkalmazásával – érdemben képes felülmúlni a statikus kontextust figyelmen kívül hagyó baseline megközelítéseket, gyakorlati irányt mutatva a valós idejű kognitív állapotbecslés számára.

7. Összefoglalás és jövőbeli munkák

7.1 A kutatás összefoglalása

A jelen kutatás célja a kognitív terhelés objektív, perifériás élettani jeleken (HR, HRV-RMSSD, SCL) alapuló becslése volt, különös tekintettel a személyfüggetlen (Zero-shot) generalizációs szakadék áthidalására. A 2. fejezetben bemutatott szakirodalmi áttekintés és a `tdk_framework` keretrendszerben elvégzett empirikus tesztek során egyaránt bebizonyosodott, hogy a pusztán dinamikus fiziológiai adatokra támaszkodó Deep Learning modellek elbuknak az új felhasználókra történő általánosításban, mivel az emberi vegetatív idegrendszer (ANS) reakciói extrém inter-szubjektív varianciát mutatnak [2, 4].

Ezen probléma kezelésére a 4. fejezetben egy multimodális Gated Fusion (FiLM) [7] architektúrát dolgoztunk ki. A modell módszertani újdonsága (*novelty*) abban rejlik, hogy a statikus demográfiai metaadatok (Életkor és Nem) bevonásával nem egyszerűen újabb bemeneti paramétereket adtunk a hálózatnak, hanem – egy „dinamikus biológiai lencsét" képezve – feltételes kondicionálással ($\gamma \odot F_{\text{dyn}} + \beta$) áthangoltuk a Batch Normalization által stabilizált MLP ág belső élettani reprezentációját. A 6. fejezetben részletezett kísérleti eredmények egyértelműen választ adtak a kutatási kérdésekre (RQ1–RQ3): bár a szigorú Zero-shot (LOSO) generalizáció (0.57-es AUROC) korlátozott statikus metaadatokkal is komoly kihívás marad, a Few-shot (*fine-tuning*) paradigmában – mindössze 20%-nyi egyéni kalibrációs adat felhasználásával – a Gated Fusion modell 0.73-as AUROC értéket ért el. Ez a szignifikáns teljesítményugrás igazolja, hogy a statikus kontextus explicit modellezése és a rövid kalibráció szinergiája érdemben képes kompenzálni az egyéni biológiai baseline eltéréseket, ezáltal egy robusztus, ipari alkalmazásra is skálázható megoldást kínálva az ember-gép interfészek (HCI) számára [9].

7.2 A kísérlet limitációi és potenciális torzító tényezők

Bár az eredmények iránymutatóak, a tudományos objektivitás megköveteli a kísérleti keretrendszer korlátainak és a lehetséges torzító tényezőknek a kritikai elemzését. A kapott generalizációs eredményeket az alábbi három fő tényező befolyásolhatta:

- **Laboratóriumi környezet és mesterséges stresszorok:**
  A 3.1. alfejezetben bemutatott SWELL-KW [3] és CLARE [8] adathalmazok – bár a terület referenciaértékű benchmarkjai közé tartoznak – szigorúan kontrollált, laboratóriumi körülmények között készültek. Az e-mailes megszakítások vagy a MATB-II repülésszimulátor feladatai mesterséges stresszorok. A valós életben (*in-the-wild*) a kognitív terhelést olyan fizikai és pszichológiai tényezők is kísérik (például mozgásból fakadó szenzorzaj, beszéd vagy valós egzisztenciális tét), amelyek drasztikusan megváltoztathatják az élettani jelek morfológiáját [4]. A modell prediktív teljesítménye egy valós ipari környezetben

további zajszűrés nélkül vélhetően alacsonyabb lenne a laboratóriumiban mértnél.

- **Az elemszám (*Sample Size*) korlátai:**
  Az alkalmazott adathalmazok viszonylag alacsony alany-számmal (24–25 fő) rendelkeznek. Bár a 3.2. alfejezetben bemutatott *sliding window* szegmentáció révén több ezer ablakot ($N = 3115$ adatpontot) generáltunk, a Deep Learning architektúrák – különösen a Zero-shot generalizáció terén – jóval nagyobb demográfiai diverzitást igényelnek. Nem zárható ki, hogy a statikus kondicionáló ág bizonyos korcsoportok vagy nemek specifikus mintázataira túltanult (*overfitting*) a korlátozott alany-szám miatt.

- **Hiányzó kritikus statikus metaadatok:**
  A kutatás során az Életkor és a Nem paramétereket vontuk be a Gated Fusion hálózatba. Orvosbiológiai szempontból azonban a szívritmus-változékonyságra (HRV-RMSSD) és a bőrellenállásra (SCL) jelentős hatással van a napi koffeinfogyasztás, a krónikus szorongás, az aktuális alvásminőség, valamint a fizikai edzettségi szint (*fitness level*) [2, 4]. Mivel a vizsgált nyílt adatbázisok ezeket a változókat nem tartalmazzák, a FiLM réteg nem tudott rájuk kondicionálni, így ezek jelenleg modellezhetetlen biológiai zajként maradtak jelen a rendszerben.

7.3 Jövőbeli munkák

A kutatás eredményei és a feltárt limitációk egyértelmű irányt mutatnak a jövőbeli fejlesztések számára. Elsődleges célunk a Gated Fusion architektúra kiterjesztése további statikus és kvázi-statikus kontextuális adatokkal (például edzettségi szint, napszak, szubjektív fáradtság és alvásminőség), amivel hipotézisünk szerint már a tisztán személyfüggetlen (Zero-shot) generalizáció is megközelítheti a valós ipari alkalmazhatóság határát.

További kutatási irányt jelent a kimeneti címkék (*labels*) és a feladatmegfogalmazás finomhangolása. A jelenlegi bináris (0: alacsony, 1: magas terhelés) osztályozás helyett – a CLARE adathalmaz [8] sűrű, 1-től 9-ig terjedő valós idejű annotációit, valamint a gaze (szemkövetési) modalitást kihasználva – a modellt egy folytonos regressziós architektúrává kívánjuk továbbfejleszteni. Ez lehetővé tenné a kognitív terhelés *fine-grained* (finomszemcsés), folyamatos nyomon követését, amely elengedhetetlen a jövő adaptív, proaktív ember-gép interfészeinek kialakításához.

Irodalomjegyzék

[1] J. Sweller. „Cognitive load during problem solving: Effects on learning”. *Cognitive Science* 12.2 (1988), 257–285. old.

[2] R. W. Picard. *Affective Computing*. Cambridge, MA, USA: MIT Press, 1997.

[3] S. Koldijk és tsai. „The SWELL Knowledge Work Dataset for Stress and User Modeling Research”. *Proceedings of the 16th International Conference on Multimodal Interaction (ICMI)*. Istanbul, Turkey: ACM, 2014, 291–298. old.

[4] P. Schmidt és tsai. „Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection”. *Proceedings of the 20th ACM International Conference on Multimodal Interaction (ICMI)*. Boulder, CO, USA: ACM, 2018, 400–408. old.

[5] Y. Bengio, A. Courville és P. Vincent. „Representation Learning: A Review and New Perspectives”. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)* 35.8 (2013), 1798–1828. old.

[6] X. Yin és tsai. „Zero-shot learning and multimodal fusion for physiological emotion and cognitive state recognition”. *IEEE Access / Biomedical Signal Processing and Control* (2021).

[7] E. Perez és tsai. „FiLM: Visual Reasoning with a General Conditioning Layer”. *Proceedings of the AAAI Conference on Artificial Intelligence*. 32. köt. 1. 2018.

[8] P. Angkan, B. Bhatti és tsai. „CLARE: Cognitive Load Assessment in Realtime with Multimodal Data”. *IEEE Transactions on Affective Computing / ArXiv Preprint* (2024).

[9] Y. Wang és tsai. „Generalizing from a Few Examples: A Survey on Few-Shot Learning”. *ACM Computing Surveys (CSUR)* 53.3 (2020), 1–34. old.