Kognitív terhelés becslése és generalizáció statikus adatok fúziójával

Giricz Vince
Természettudományi és Informatikai Kar
email@email.email

2026. október

Kivonat

A kognitív terhelés nem tolakodó, megbízható becslése kritikus fontosságú az affektív számítástechnikában. Jelen kutatás célja a tisztán fiziológiai alapú modellek generalizációs korlátainak feloldása kontextuális és demográfiai (statikus) adatok fúziójával. Tanulmányunkban bemutatjuk a kognitív terhelés és a pszichológiai stressz közötti elméleti elhatárolást, vizsgáljuk a személyfüggetlen (Zero-shot) és adaptív (Few-shot) predikciós paradigmákat, valamint megfogalmazzuk a kutatás alapvető kérdéseit.

1. BEVEZETÉS ÉS A KUTATÁS CÉLJA

A modern, technológia-vezérelt társadalomban az ember-gép interfészek (HCI) mindennapjaink elválaszthatatlan részévé váltak. A kritikus rendszerek üzemeltetése során – legyen szó légiforgalmi irányításról, nagy sebességű járművek vezetéséről, vagy bonyolult ipari és egészségügyi berendezések kezeléséről – a felhasználóra nehezedő nyomás soha nem látott mértéket öltött. Ilyen kiélezett helyzetekben a kognitív túlterhelés nem pusztán a teljesítmény csökkenését vagy frusztrációt okoz, hanem drasztikusan növeli a fatális emberi mulasztások kockázatát, és hosszú távon a felhasználó jóllétét is veszélyezteti.

A kognitív terhelés mérése és folyamatos monitorozása ezért az elmúlt évtizedben az affektív számítástechnika és az ergonómia kiemelt kutatási területté vált. Egy olyan rendszer, amely valós időben, objektíven és nem tolakodó (*non-intrusive*) módon képes becsülni az operátor pillanatnyi terhelési és stresszszintjét, lehetővé tenné a dinamikus beavatkozást. Például a rendszer automatikusan lecsökkenthetné a megjelenített információk mennyiségét, átvehetne bizonyos részfeladatokat, vagy vészjelzést adhatna ki a balesetek megelőzése érdekében.

1.1. Kognitív terhelés és stressz – elméleti háttér

A mérnöki és informatikai irodalomban a „kognitív terhelés” és a „stressz” fogalmát gyakran szinonimaként, vagy legalábbis egymással felcserélhető állapotokként használják. Egy robusztus gépi tanulási modell felépítéséhez azonban elengedhetetlen ezen pszichofiziológiai fogalmak pontos elméleti tisztázása és szétválasztása.

A kognitív terhelés elméletét (*Cognitive Load Theory*, CLT) John Sweller alkotta meg az 1980-as évek végén [1]. Az elmélet alapfeltevése, hogy az emberi munkamemória (*working memory*) kapacitása szigorúan korlátozott: egyszerre csak meghatározott számú információelemet képes feldolgozni. Sweller az elméletében a terhelést három fő kategóriára bontotta:

1. **Belső (*Intrinsic*) kognitív terhelés:** Magának a feladatnak az objektív, eredendő bonyolultságából fakad (például egy komplex matematikai egyenlet megoldása nehezebb, mint egy egyszerű összeadás).

2. **Külső (*Extraneous*) kognitív terhelés:** A feladat

prezentációjának módjából ered. A rosszul tervezett felhasználói interfészek (UI), a zavaró tényezők és a felesleges információk növelik ezt a terhelést.

3. **Hasznos (*Germane*) kognitív terhelés:** A tanulásra, a sémák (mentális modellek) kialakítására és az új információk hosszú távú memóriába való integrálására fordított szellemi erőfeszítés.

Amikor ezen három tényező összege meghaladja az egyén aktuális munkamemória-kapacitását, kognitív túlterhelés (*cognitive overload*) lép fel.

Ezzel szemben a stressz egy sokkal tágabb biológiai és pszichológiai fogalom. A stressz a szervezet nem specifikus válasza bármilyen olyan külső vagy belső ingerre (stresszorra), amely kibillenti a testet a homeosztázisából, vagy fenyegetést jelent számára.

A két fogalom közötti átfedést a pszichofiziológiai reakciók adják. Amikor egy felhasználó kognitív túlterhelést tapasztal (például egy repülésirányító, akinek hirtelen túl sok paramétert kell párhuzamosan figyelnie), az agy ezt a kudarcélményt és nyomást pszichológiai stresszorként érzékeli. A kognitív túlterhelés ezáltal aktiválja a vegetatív idegrendszer (*Autonomic Nervous System*, ANS) szimpatikus ágát, beindítva a klasszikus „üss vagy fuss” (*fight-or-flight*) válaszreakciót.

Ennek a biológiai összefonódásnak köszönhető, hogy a tisztán szellemi, kognitív folyamatok (munkamemória-kihasználtság) mérhetővé válnak perifériás élettani szenzorokkal. A megnövekedett kognitív terhelés a szimpatikus idegrendszeren keresztül olyan megfigyelhető változásokat idéz elő a szervezetben, mint a szívritmus felgyorsulása, a szívritmusváltozékonyság (HRV) csökkenése, vagy a tenyéren lévő verejtékmirigyek aktivitása miatti bőrellenállás-csökkenés (SCL). Bár az élettani jelek kiváló indikátorai ennek a megemelkedett „arousal” (készenléti) állapotnak, a köztük lévő leképezés nem egyértelmű és nem lineáris, ami komoly mérnöki kihívásokat vet fel.

1.2. A generalizáció problémája az affektív számítástechnikában

Bár a fiziológiai jelek elemzése ígéretes eredményeket mutat a terhelés becslésében, a meglévő gépi tanulásos modellek a gyakorlatban komoly akadályba ütköznek: a generalizáció problémájába. A kognitív terhelésre és a stresszre adott fiziológiai reakciók extrém mértékű egyéni varianciát mutatnak. Ami az egyik felhasználónál a stressz egyértelmű jele (pl. jelentős pulzusemelkedés), az egy másiknál lehet normál biológiai ingadozás.

Ennek következtében a hagyományos modellek a szakirodalomban kétféle kiértékelési paradigmában vizsgáztak, eltérő sikerrel. A kutatásunk ezen paradigmák vizsgálatára és kiterjesztésére épül:

- **Zero-shot generalizáció:** A gépi tanulásban és az affektív számítástechnikában a zero-shot megközelítés azt jelenti, hogy a modellt olyan adatokon (jelen esetben egy teljesen új, ismeretlen felhasználón) teszteljük, amelyről a betanítás során semmilyen információval nem rendelkezett [2]. Ez a legszigorúbb, egyben legéletszerűbb tesztelési forma (az iparban „out-of-the-box” működésnek is hívják). A meglévő rendszerek itt drasztikus teljesítményromlást, sok esetben véletlen tippeléssel megegyező pontosságot produkálnak az egyéni biológiai zaj miatt.
- **Few-shot generalizáció (finomhangolás):** A few-shot tanulás során a modell kap egy minimális, néhány mintából álló adathalmazt az új tesztalanytól. Ezzel a rövid, úgynevezett kalibrációs szakasszal a modell finomhangolható (*fine-tuning*), így képes alkalmazkodni az egyéni biológiai sajátosságokhoz anélkül, hogy a nulláról kellene betanítani az adott személyre [3].

1.3. A kutatás célja és a vizsgálati kérdések (RQ)

Kutatásunk célja a zero-shot generalizációs szakadék áthidalása, valamint a few-shot adaptáció hatékonyságának növelése. Fő innovációnk a tisztán fiziológiai (dinamikus) adatok kiegészítése statikus, kontextuális információkkal (például demográfiai adatokkal

vagy feladatnehézséggel) egy egyedi, kapuzott fúziós (*Gated Fusion*) mechanizmuson keresztül. Hipotézisünk szerint a modell a statikus adatok bevonásával képessé válik az egyéni biológiai különbségek kompenzálására, és így javul az új felhasználókra történő általánosítási képessége.

A kutatás során az alábbi három fő kérdésre (*Research Questions*, RQ) keressük a választ:

RQ1:

Képes-e a statikus adatok fúziója szignifikánsan javítani a modell személyfüggetlen (Zero-shot) generalizációs képességét a csupán fiziológiai alapon működő modellekhez képest?

RQ2:

Hogyan változik a predikció pontossága, ha a Zero-shot megközelítés helyett Few-shot paradigmát alkalmazunk, és ezen a téren mekkora előnyt jelent a statikus fúzió?

RQ3:

Milyen adat-előfeldolgozási lépések (pl. mozgóablakos szegmentáció, interpoláció, alany-szintű normalizálás) elengedhetetlenek ahhoz, hogy a hálózat képessé váljon a robusztus generalizációra?

2. KAPCSOLÓDÓ MUNKÁK ÉS IRODALMI ÁTTEKINTÉS

A kognitív állapotok és a stressz detektálása régóta fókuszában áll az ember-gép interakció (*Human-Computer Interaction*, HCI) és az affektív számítástechnika kutatásainak. Bár a szenzoros technológiák rohamosan fejlődtek, az élettani jelek elemzésének módszertana jelentős paradigmaváltásokon ment keresztül az elmúlt években. Ahhoz, hogy saját fúziós módszertanunk innovációját elhelyezzük, elengedhetetlen a terület jelenlegi állásának (*State of the Art*) áttekintése.

2.1. Hagyományos gépi tanulás az affektív számítástechnikában

A korai kutatások – köztük Koldijk és munkatársainak eredeti, a SWELL-KW adathalmazt bemutató tanulmánya [4] – jellemzően hagyományos gépi tanulási (*Machine Learning*) algoritmusokat alkalmaztak, mint például a Támogatóvektor-gépek (*Support Vector Machines*, SVM), a *k*-legközelebbi szomszéd (*k*-NN) vagy a döntési fák.

Ezeknek a módszereknek a legnagyobb korlátja a kézi jellemzőkinyerésben (*manual feature engineering*) rejlett. A szakértőknek előre meg kellett határozniuk azokat a statisztikai változókat, amelyeket a modell bemeneteként használtak. Bár ezek az algoritmusok személyre szabott (*Intra-subject*) tesztelésnél gyakran elértek 80–90%-os pontosságot, az új alanyokra történő általánosításkor (*Zero-shot*) a teljesítményük drasztikusan visszaesett. A hagyományos modellek képtelenek voltak kellően komplex, nemlineáris reprezentációkat alkotni ahhoz, hogy áthidalják az extrém biológiai varianciát.

2.2. Mélytanulás és a generalizációs szakadék

A mesterséges neurális hálózatok (*Artificial Neural Networks*, ANN) és a mélytanulás (*Deep Learning*) megjelenése áttörést hozott a területen. A Konvolúciós Neurális Hálózatok (CNN) és a szekvenciális modellek (RNN, LSTM) képessé váltak az idősoros adatok morfológiájának és időbeli összefüggéseinek automatikus kinyerésére (*representation learning*).

A CLARE adathalmazt publikáló Angkan és munkatársai [5] például mély Transformer-alapú architektúrákat használtak a kognitív terhelés valós idejű becslésére. Tanulmányuk azonban megerősítette azt a SOTA problémát, amellyel a jelen kutatás is foglalkozik: a generalizációs szakadékot. Bebizonyosodott, hogy pusztán az architektúra mélységének és komplexitásának növelése nem oldja meg az inter-szubjektív különbségek problémáját. Ha a hálózat nem kap explicit információt a felhasználó egyéni biológiai kontextusáról, az „out-of-the-box” generalizáció továbbra is gyenge marad.

2.3. Multimodális fúziós technikák kihívásai

A pontosság növelése érdekében a legújabb kutatások a többmodalitású (multimodális) fúzió felé fordultak [2]. Ennek leggyakoribb formája az egyszerű

jellemző-szintű összefűzés (*early concatenation*) vagy a döntés-szintű fúzió (*late fusion*).

Ezek a klasszikus fúziós technikák azonban az összes bemenetet egyenrangú dinamikus változóként kezelik. A szakirodalomban űr tátong az olyan módszerek tekintetében, amelyek felismerik, hogy bizonyos statikus adatok (például a demográfia) nem csupán plusz „szenzoradatok", hanem a dinamikus reakciók kontextusát jelentik. A képalkotás területén a Perez et al. [6] által bemutatott FiLM (*Feature-wise Linear Modulation*) rétegek sikeresen használtak feltételes kondicionálást. A mi kutatásunk újdonsága (*novelty*), hogy ezt a kapuzási logikát az affektív számítástechnikába átemelve egy olyan egyedi Gated Fusion mechanizmust építünk fel, ahol a statikus metaadatok dinamikusan áthangolják a modell fiziológiai reprezentációit.

3. AZ ADATHALMAZOK ÉS AZ ELőFELDOLGOZÁSI PIPELINE

A modellek tanításához, kiértékeléséhez és a generalizációs képesség robusztusságának vizsgálatához elengedhetetlen volt olyan multimodális adathalmazok bevonása, amelyek elegendő elemszámot biztosítanak, és több modalitást is lefednek. A kutatás során két nyílt forráskódú adatbázist, a CLARE [5] és a SWELL-KW [4] adathalmazokat vizsgáltuk és alkalmaztuk.

Adathalmazok választásának indoklása A két adathalmaz tudatos választás eredménye: a SWELL-KW egy hétköznapi, irodai környezet mérsékelt stresszorait (határidők, váratlan megszakítások) modellezi, míg a CLARE egy extrém, kritikus szimulációs környezet (repülésirányítás) akut kognitív túlterhelését vizsgálja. Ez a két adatbázis tehát a kognitív terhelés spektrumának két végletét képviseli. Ha a kidolgozott fúziós módszertanunk mindkét eltérő tartományban (*domain*) képes javítani a generalizációs képességet, az megkérdőjelezhetetlenül bizonyítja az architektúra robusztusságát és kontextusfüggetlenségét.

3.1. Adathalmazok bemutatása és korábbi felhasználásuk a szakirodalomban

A kognitív terhelés és a stressz kutatásában a megfelelő minőségű adathalmaz kiválasztása kritikus lépés. A gépi tanulásos modellek teljesítménye és generalizációs képessége közvetlenül függ a betanításra használt adatok minőségétől, a feladatok életszerűségétől és az annotációk (címkék) megbízhatóságától.

3.1.1. A SWELL-KW (SWELL Knowledge Work) adathalmaz

A jelen kutatás kísérleti gerincét a SWELL-KW [4] adatbázis adja, amelyet széleskörűen alkalmaznak a szakirodalomban a munkahelyi stressz és a kognitív állapotok detektálására.

- **Méret és résztvevők:** Az adatbázis 25 irodai dolgozó (tudásmunkás) adatait tartalmazza különböző mesterségesen előállított munkahelyi stresszhelyzetek során. Minden alany hozzávetőlegesen 3 órányi kísérleten vett részt.
- **Feladatok:** A kísérleti protokoll három fázisból állt: egy normál munkavégzési (relaxációs) szakaszból (pl. beszámolók írása és prezentációkészítés), egy időnyomás (*Time Pressure*) alatt végzett feladatból, valamint egy váratlan megszakításokkal (*Interruption*, pl. sürgős, beérkező e-mailek) terhelt szakaszból.
- **Elemek és modalitások:** A kutatók ezen feladatok közben folyamatos élettani méréseket végeztek. Az adathalmaz tartalmazza az elektrokardiogram (ECG) és a galvános bőrreakció (EDA/GSR) jeleit, emellett a résztvevők testtartását és vizuális arckifejezéseit is rögzítették.
- **Címkék (*Labels*):** A tanuláshoz a kimeneti címkéket egy bináris osztályozási feladathoz igazították. A normál munkavégzést alacsony terhelésnek (0. osztály), míg az időnyomást és megszakítást magas terhelésnek/stressznek (1. osztály) címkéztük.
- **Szakirodalmi háttér és következtetések:** Koldijk és munkatársai eredeti publikációjukban [4]

klasszikus gépi tanulási algoritmusokat – elsősorban Támogatóvektor-gépeket (*Support Vector Machines*, SVM) – alkalmaztak a stressz felismerhetőségének vizsgálatára. Eredményeik tökéletesen alátámasztják a jelen kutatás problémafelvetését: kísérleteik során bebizonyosodott, hogy bár a modell egy adott alanyon betanítva (*intra-subject*) akár 90% körüli pontosságot is képes elérni, új személyekre történő általánosításkor (*cross-subject* / zero-shot generalizáció) a teljesítmény drasztikusan, véletlen tippelés szintjére esett vissza. A szerzők ezt az egyéni fiziológiai válaszok extrém diverzitásával magyarázták. Jelen kutatás ezt a problémát hidalja át a statikus adatok fúziójával.

3.1.2. A CLARE (Cognitive Assessment in Realtime with Multimodal Data) adathalmaz

A többmodalitású generalizáció és a kifejezetten szemkövetéses (*eye-tracking*) adatok komplexebb vizsgálata céljából egy frissebb, 2024-ben publikált adathalmazt, a CLARE adatbázist [5] is elemeztük. Ez az adathalmaz a nagy felbontású szenzorok és a sűrű címkézés miatt kiemelkedő fontosságú a területen.

- **Méret és résztvevők:** A CLARE 24 egészséges résztvevő folyamatos méréseit tartalmazza.
- **Feladatok:** A résztvevők a MATB-II (*Multi-Attribute Task Battery*) repülésszimulációs szoftverrel dolgoztak. Ez a program lehetővé teszi különböző kognitív terhelési szintek (alacsony, közepes, magas komplexitás) beállítását úgy, hogy a felhasználónak több párhuzamos feladatot (pl. célkövetés, üzemanyagszint-menedzsment, audiókommunikációs feladatok) kell egyszerre megoldania.
- **Elemek és modalitások:** Az adatbázis kiemelkedően gazdag minőségi elemekben: 512 Hz-es ECG, 128 Hz-es EDA, és 256 Hz-es EEG mellett speciális szemüvegekkel (Tobii Pro) 50 Hz-es frekvenciával rögzítettek vizuális tekintet- (*Gaze*) adatokat. A kinyerhető és elemezhető vizuális jellemzők (*features*) közé tartozik a bal és jobb pupilla átmérője, a pislogások száma, a fixációk, valamint a szakkádok (gyors szemmozgások) sebessége, gyorsulása és amplitúdója.
- **Címkék (*Labels*):** A CLARE egyik legnagyobb módszertani újítása a valós idejű, sűrű címkézés. A résztvevőknek minden 10. másodpercben egy 1-től 9-ig terjedő skálán (ahol az 1 a nagyon alacsony, a 9 a nagyon magas mentális erőfeszítés) verbálisan kellett jelenteniük az aktuális kognitív terhelésüket. Ez finomszemcsés (*fine-grained*), regressziós modellek tanítását is lehetővé teszi.
- **Szakirodalmi háttér és következtetések:** A CLARE megalkotói, Angkan és munkatársai [5] baseline modelljeik (CNN és Transformer alapú mélytanulásos hálózatok) kiértékelésekor szintén felhívják a figyelmet a generalizációs szakadékra. Kísérleteikben kimutatták, hogy a személyfüggetlen, keresztalanyos (*Leave-One-Subject-Out*) tesztelésnél az olyan komplex modellek, mint a Transformer, teljesítménye szignifikánsan elmarad az ismert alanyokon végzett 10-szeres keresztvalidáció (10-fold CV) eredményeitől. Ez megerősíti azt az alaptételünket, miszerint pusztán az architektúra mélységének növelése nem elegendő a biológiai zaj áthidalásához.

3.2. A fiziológiai jellemzők (Features) és az előfeldolgozási módszertan

A kognitív állapotok becslésének egyik legnehezebb mérnöki feladata a folyamatos, folytonos idősoros jelek (*raw signals*) átalakítása olyan strukturált, diszkrét jellemzővektorokká, amelyeket a mesterséges neurális hálózatok hatékonyan képesek feldolgozni. A kísérleti keretrendszerben (`tdk_framework`) a SWELL-KW adathalmazra egy szigorú adatkinyerési és tisztítási pipeline-t alakítottunk ki.

3.2.1. A 13-dimenziós élettani vektor anatómiája

A kísérlet során a hálózat bemenetét nem közvetlenül a zajos nyers szenzoradatok, hanem abból kinyert, statisztikailag tömörített jellemzők (*features*) alkotják. A dinamikus bemenetet három fő fiziológiai modalitás biztosítja, amelyek mindegyike a vegetatív idegrend-

szer (*Autonomic Nervous System*, ANS), azon belül is a stresszreakciókért felelős szimpatikus, illetve a nyugalmi állapotért felelős paraszimpatikus ág működéséről ad objektív képet:

1. **HR (*Heart Rate* – Szívritmus):** A percenkénti szívverések száma. Bár az egyik legkönnyebben mérhető paraméter, önmagában a legkevésbé robusztus, mivel a fizikai aktivitás és a biológiai alapvonal (edzettségi szint, életkor) nagymértékben befolyásolja. Kognitív terhelés alatt a szimpatikus idegrendszer aktiválódása jellemzően a HR emelkedéséhez vezet.
2. **HRV – RMSSD (*Heart Rate Variability* – Szívritmus-változékonyság):** A szívverések közötti (R–R) intervallumok ingadozását méri. A kutatásban az RMSSD (*Root Mean Square of Successive Differences*) metrikát alkalmaztuk, amely az egymást követő szívverések közötti időkülönbségek négyzetes közepének gyöke. Orvosbiológiai szempontból a magas HRV (és RMSSD) a paraszimpatikus dominancia, azaz a relaxáció és a jó alkalmazkodóképesség jele. Stressz és magas kognitív terhelés hatására a szívritmus „gépiesebbé" válik, az RMSSD értéke pedig szignifikánsan lecsökken.
3. **SCL (*Skin Conductance Level* – Bőrellenállás/Galvános Bőrreakció):** Az elektrodermális aktivitás (EDA) tónusos komponense. A tenyéren és az ujjakon található ekkrin verejtékmirigyek aktivitását méri, amelyeket kizárólag a szimpatikus idegrendszer (a „fight-or-flight" válasz) vezérel. A kognitív terhelés és az *arousal* (éberségi szint) növekedésével a mikroszkopikus izzadás miatt a bőr elektromos vezetőképessége megnő (az ellenállás csökken). Ez teszi az SCL-t az egyik legmegbízhatóbb stressz-indikátorrá.

3.2.2. Időablakos szegmentáció és adattanítás

A hálózat nem pillanatnyi (milliszekundumos) mintákból dolgozik, hanem a fenti három modalitásból képzett 13-dimenziós vektorokat használ bemenetként. Jogosan merül fel a kérdés: miért 13 dimenzió, és miért 1 perces ablakok?

A fiziológiai változások – különösen az endokrin és a vegetatív idegrendszeri reakciók (például a verejtékmirigyek válaszideje vagy a szívritmus-variabilitás mérhető változása) – viszonylag lassú lefolyású folyamatok. Az olyan metrikák, mint az RMSSD, statisztikailag értelmezhetetlenek lennének néhány másodperces adatokból, mert nem tartalmaznának elég szívverést (R–R csúcsot) a variabilitás kiszámításához. Emiatt az adatbázisban a jellemzőket 1 perces ablakokban (*time windows*) aggregálták az eredeti kutatók, és minden 1 perces ablakon belül kiszámolták az adott modalitások különböző statisztikai vetületeit (pl. átlag, medián, szórás, minimum, maximum). Ezen statisztikai vetületek összességéből áll elő a 13-dimenziós vektor, amely így rendkívül gazdag információsűrűséggel írja le azt az 1 percnyi biológiai állapotot.

A keretrendszerben a szekvenciális kontextus megőrzése érdekében egy mozgóablakos (*sliding window*) technikát implementáltunk. Az ablakméretet (*window size*) 3-ban, a lépésközt (*stride*) pedig 1-ben határoztuk meg. Ez azt jelenti, hogy a hálózat minden egyes predikciós lépésben az elmúlt 3 perc (3 darab 13-dimenziós vektor) élettani kontextusát vizsgálja egybevonva.

3.2.3. Adattisztítás és címkézés

A valós környezetben rögzített szenzoradatok óhatatlanul tartalmaznak mérési hibákat (artefaktumokat). Az adathalmazban található szenzorhibákat (melyeket az eredeti szerzők 999-es értékkel jelöltek) a pipeline során kiszűrtük, helyükre `NaN` értékeket rendeltünk, majd ezeket alanyonkénti átlagolással vagy interpolációval pótoltuk a folyamatos idősorelemzés megőrzése érdekében. Statikus jellemzőként, amely a Gated Fusion fúziós ágának bemenetét adja, a résztvevők kérdőíves demográfiai adatait – konkrétan az Életkort (*Age*) és a Nemet (*Gender*, binárisan kódolva) – integráltuk a vektorba.

A fent leírt előfeldolgozási és ablakozási metódus futtatása globálisan összesen 3115 mintát (ablakot)

eredményezett. Ebből 1505 darab a nyugalmi (0. osztály) és 1610 darab a terheléses (1. osztály) eset. Ez a feldolgozás egy kiemelkedően jó minőségű, szinte tökéletesen kiegyensúlyozott (*balanced*) adathalmazt biztosított a hálózat tanításához, minimalizálva az egyosztályos túltanulás (*majority class bias*) kockázatát.

4. SAJÁT MÓDSZERTAN ÉS ARCHITEKTÚRA

A kognitív terhelés objektív becslése egy tipikus multimodális gépi tanulási probléma, ahol egyszerre állnak rendelkezésre (ablakokból kinyert) dinamikus fiziológiai jelek, valamint konstans (statikus) metaadatok az alanyról vagy a feladat környezetéről. A kutatásunk során kidolgozott, a `tdk_framework`-ben implementált architektúra két fő komponensből áll: egy teljesen összekötött (*Fully Connected*) feldolgozó ágból a dinamikus adatokhoz, és egy egyedi Gated Fusion (FiLM) mechanizmusból, amely a statikus adatokat integrálja.

4.1. Mesterséges neurális hálózatok az affektív számítástechnikában

Az affektív számítástechnika (*affective computing*) és a kognitív állapotbecslés területén a korai kutatásokban jellemzően a klasszikus gépi tanulási (*Machine Learning*) algoritmusok domináltak. Az olyan felügyelt tanulási módszerek, mint a támogatóvektorgépek (*Support Vector Machines*, SVM), a k-legközelebbi szomszéd (k-NN), vagy a Random Forest algoritmusok elterjedtek voltak a stressz és a kognitív terhelés fiziológiai alapú detektálására. Ezeknek az algoritmusoknak az alkalmazása azonban egy kritikus szűk keresztmetszettel járt: nagymértékben támaszkodtak a kézi jellemzőkinyerésre (*manual feature engineering*). A kutatóknak előzetes orvosi vagy jelfeldolgozási domaintudás alapján kellett meghatározniuk, hogy a nyers élettani jelekből milyen statisztikai paramétereket és mintázatokat számítsanak ki a modell számára.

A kognitív terhelés mérése során rögzített emberi élettani adatok (például a szívritmus-változékonyság vagy a galvános bőrellenállás) azonban eredendően zajosak, dinamikusak és erősen nemlineáris természetűek. Ami még ennél is nagyobb kihívást jelent, az a rendkívül magas inter-szubjektív variancia; az egyének biológiai alapvonalai, reaktivitása és a stresszre adott élettani válaszai drasztikusan eltérhetnek. Egy klasszikus algoritmus, amely merev, kézzel definiált szabályrendszerek és jellemzők alapján húzza meg a döntési határait, gyakran képtelen megfelelően általánosítani (*generalizálni*) egy új felhasználóra.

Ezt a módszertani korlátot a mesterséges neurális hálózatok (*Artificial Neural Networks*, ANN) és a mélytanulás (*Deep Learning*) megjelenése hidalta át. A neurális hálózatok legfőbb architekturális előnye a reprezentációtanulás (*representation learning*) képességében rejlik. Ez a mechanizmus lehetővé teszi, hogy az algoritmus az egymást követő rejtett rétegein (*hidden layers*) keresztül, automatikusan és hierarchikusan vonja ki a feladat szempontjából leginkább releváns mintázatokat az adatokból, anélkül, hogy azokat a tervező előre, mereven definiálná.

A kognitív állapotok becslésénél a neurális hálózatok képesek felfedezni azokat a rejtett, sokdimenziós és nemlineáris összefüggéseket a fiziológiai vektorok között, amelyek emberi logikával vagy klasszikus statisztikával nehezen megragadhatók. Bár a jelen kutatás keretrendszerében a nyers idősorokat egy előfeldolgozási fázis során ablakozott jellemzővektorokká alakítjuk, a mélytanulásos architektúra alkalmazása elengedhetetlen feltétele annak, hogy a modell elég robusztus legyen a biológiai zaj szűrésére. Ez a rugalmas reprezentációs tér adja meg az alapot ahhoz is, hogy a későbbi fázisokban a statikus demográfiai adatok fúziójával sikeresen kompenzáljuk az egyéni eltéréseket, és áttörjük a Zero-shot generalizáció korlátait.

4.2. A Teljesen Összekötött Hálózatok (FCN) és a Többrétegű Perceptron (MLP)

A kognitív terhelés becslésére szolgáló kísérleti keretrendszerben (`tdk_framework`) a dinamikus élettani adatok feldolgozását egy Teljesen Összekötött Hálózat (*Fully Connected Network*, FCN), vagy más néven Többrétegű Perceptron (*Multilayer Perceptron*, MLP) végzi. Az MLP az egyik legalapvetőbb előrecsatolt

(*feedforward*) mesterséges neurális hálózati architektúra. Felépítése szigorúan strukturált rétegekből áll: egy bemeneti rétegből (*input layer*), egy vagy több rejtett rétegből (*hidden layers*), és egy kimeneti rétegből (*output layer*). Ebben az elrendezésben minden réteg minden egyes neuronja közvetlen, súlyozott kapcsolatban áll a következő réteg összes neuronjával (ezt jelöli a „teljesen összekötött" kifejezés). Ez a sűrű kapcsolati háló (*dense connections*) teszi lehetővé, hogy a hálózat rendkívül komplex, nemlineáris leképezéseket tanuljon meg a bemeneti jellemzők és a kimeneti célváltozók között.

A gépi tanulásban a dinamikus, időben változó adatok (például az élettani jelek folytonos mérése) modellezésére gyakran alkalmaznak rekurrens neurális hálózatokat (RNN), mint például a Hosszú Rövidtávú Memória (LSTM) vagy a Kapuzott Rekurrens Egység (GRU), illetve egydimenziós konvolúciós hálózatokat (1D-CNN). A rekurrens hálózatok belső memóriaállapotuk révén kiválóan alkalmasak a szekvenciális időbeli függőségek leírására, míg a CNN-ek a lokális mintázatok (például hirtelen kiugrások a pulzusban) térbeli vagy időbeli kinyerésére specializálódtak. Ezen komplex architektúrák alkalmazása azonban jelentős számítási kapacitást, nagyobb memóriát és jóval több tanítási adatot igényel az alulillesztés (*underfitting*) elkerülése érdekében.

A jelen kutatás keretein belül a nyers idősoros adatokat egy szigorú előfeldolgozási lépés során mozgóablakos (*sliding window*) technikával szegmentáltuk. Ennek eredményeként a modell bemenete nem egy hosszú, változó hosszúságú nyers szekvencia, hanem egy előre kiszámított statisztikai jellemzőket tartalmazó, laposított (*flattened*), fix 13-dimenziós vektor ablakonként. Mivel az időbeli dinamika és a morfológiai információk nagy részét az ablakozás és a jellemzőkinyerés már strukturált formába öntötte, a mély szekvenciális modellek (mint a GRU) használata felesleges komplexitást vezetett volna be, ami növeli a túltanulás (*overfitting*) kockázatát egy korlátozott elemszámú adathalmazon. A laposított, alacsony dimenziószámú, de magas információsűrűségű bemeneti vektorok esetén az FCN/MLP architektúra bizonyult a leghatékonyabb és legrobusztusabb választásnak. A teljesen összekötött rétegek tökéletesen alkalmasak arra, hogy megtalálják a különböző élettani modalitások (például a pulzusszám és a bőrellenállás) közötti rejtett, nemlineáris keresztkorrelációkat egy adott időablakon belül, mindezt kiemelkedő számítási hatékonyság mellett.

4.3. A hálózat matematikai építőelemei és tanulási folyamata

A fent bemutatott Többrétegű Perceptron (MLP) architektúra működése alapvető lineáris algebrai műveletekre és nemlineáris matematikai transzformációkra épül. A hálózat tanulási képessége ezen építőelemek iteratív optimalizálásából fakad.

4.3.1. Lineáris rétegek (Dense / Linear layers)

Az architektúra gerincét a teljesen összekötött, lineáris rétegek adják. Egy ilyen réteg feladata, hogy a bemeneti teret – jelen esetben például az időablakokból kinyert 13-dimenziós fiziológiai jellemzővektort – egy új, magasabb vagy alacsonyabb dimenziójú rejtett reprezentációs térbe transzformálja. Matematikailag egy lineáris réteg működése az alábbi affin transzformációval írható le:

$$y = Wx + b \tag{1}$$

ahol:

- x jelöli a bemeneti vektort (vagy az előző réteg kimenetét).
- W a súlymátrix (*weight matrix*), amely a réteg neuronjai közötti kapcsolatok erősségét kódolja.
- b a torzítási vektor (*bias*), amely biztosítja a transzformáció eltolhatóságát az origótól, így rugalmasabb döntési határokat téve lehetővé.
- y a réteg nyers, lineáris kimenete.

A betanítási (*training*) fázis során a hálózat célja a hiba-visszaterjesztés (*backpropagation*) algoritmus segítségével úgy optimalizálni a W súlyokat és a b torzításokat, hogy minimalizálja a predikciós hibát. Biológiai és fiziológiai kontextusban ez a folyamat je-

lenti a tanulást: a hálózat a súlyok módosításán keresztül automatikusan megtanulja, hogy az egyes jellemzőknek (például a pulzusvariabilitás csökkenésének vagy a bőrellenállás hirtelen növekedésének) mekkora relatív fontosságot, azaz súlyt kell tulajdonítania a stressz-szint meghatározásakor.

4.3.2. Aktivációs függvények és a nemlinearitás szerepe

Bár a lineáris rétegek hatékonyan képesek skálázni és kombinálni a bemeneti jellemzőket, önmagukban elégtelenek a kognitív terheléshez hasonló komplex jelenségek modellezésére. Ha egy neurális hálózat kizárólag lineáris rétegekből állna, akkor – függetlenül a rétegek számától – az egész hálózat matematikai értelemben összevonható lenne egyetlen lineáris transzformációvá. Ez azt eredményezné, hogy a modell legfeljebb csak egyszerű lineáris regresszióra lenne képes, és elbukna az élettani változók közötti bonyolult összefüggések megragadásában.

Ennek elkerülése érdekében minden lineáris réteget egy nemlineáris aktivációs függvény követ. Az aktivációs függvények bevezetésével a hálózat képessé válik görbült döntési felületek kialakítására, ami a magas dimenziós feladatoknál elengedhetetlen. A `tdk_framework` keretrendszerben két meghatározó aktivációs függvényt alkalmazunk:

1. **ReLU (*Rectified Linear Unit*):** A hálózat rejtett rétegeiben (*hidden layers*) a ReLU aktivációs függvényt alkalmazzuk. Matematikai definíciója rendkívül egyszerű:

$$f(x) = \max(0, x) \tag{2}$$

   A ReLU minden negatív értéket nullára cserél, a pozitív értékeket pedig változatlanul hagyja. Számítási szempontból rendkívül hatékony, emellett a mély hálózatokban enyhíti az eltűnő gradiens (*vanishing gradient*) problémáját, ami stabilabb és gyorsabb konvergenciát eredményez a betanítás során.

2. **Sigmoid:** Mivel a kognitív terhelés becslését bináris osztályozási feladatként fogalmaztuk meg (0: alacsony terhelés, 1: magas terhelés), a hálózat utolsó kimeneti rétegén (*output layer*) a Sigmoid függvényt alkalmazzuk. Ennek képlete:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{3}$$

   A Sigmoid függvény a nyers lineáris kimenetet (*logits*) a $(0, 1)$ nyílt intervallumba „préseli". Ez a kimenet közvetlenül értelmezhető valószínűségként (*probability*): minél közelebb van az érték az 1-hez, a hálózat annál nagyobb magabiztossággal jelzi a magas kognitív terhelés vagy stressz jelenlétét az adott időablakban.

4.3.3. Veszteségfüggvény (Binary Cross-Entropy)

A hálózat felépítése (az előrecsatolt, *forward pass* folyamat) után definiálni kell, hogyan értékeli ki a saját predikcióit, és miként tanul a hibáiból. Mivel a kognitív terhelés becslését egy bináris osztályozási problémaként fogalmaztuk meg, a hiba kiszámítására a bináris keresztentrópia (*Binary Cross-Entropy*, BCE) veszteségfüggvényt alkalmaztuk. A hiba-visszaterjesztés során a hálózat célja ennek az értéknek a minimalizálása.

A BCE matematikai formulája egy N elemű kötegre (*batch*) az alábbiak szerint írható fel:

$$L_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right] \tag{4}$$

ahol:

- y_i a valódi, elvárt osztálycímke (*ground truth*).
- $\hat{y}_i$ a hálózat Sigmoid rétege által adott predikció, ami a magas terhelés valószínűségét fejezi ki.

A logaritmikus büntetés biztosítja, hogy ha a hálózat nagy magabiztossággal téved (például 0,99-es valószínűséget jósol egy ténylegesen nyugalmi, 0 állapotra), a veszteség értéke drasztikusan megnőjön. Ez a karakterisztika különösen fontos a fiziológiai jeleknél, ahol a fals pozitív vagy fals negatív riasztások kritikusak lehetnek egy valós idejű monitorozó rendszerben.

4.3.4. Súlyfrissítés és az Adam optimalizáló

A hiba kiszámítása után az optimalizáló algoritmus feladata a hálózat θ paramétereinek (súlyainak és torzításainak) frissítése a gradiensereszkedés elve alapján. A `tdk_framework` keretrendszerben ehhez az Adam (*Adaptive Moment Estimation*) optimalizálót használtuk, amely a jelenlegi gépi tanulási gyakorlat egyik legrobusztusabb algoritmusa.

A klasszikus sztochasztikus gradiensereszkedéssel (SGD) szemben az Adam nem egyetlen globális tanulási rátát használ minden paraméterre, hanem adaptívan, paraméterenként állítja be azt. Az algoritmus kiszámítja a gradiensek első momentumát (az átlagot, m_t) és második momentumát (a nem központosított varianciát, v_t) egy exponenciálisan simított mozgóátlag segítségével:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t \tag{5}$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2 \tag{6}$$

ahol g_t az aktuális gradiens a t-edik lépésben, a β_1 és β_2 pedig a felejtési tényezők. Egy torzítás-korrekció (*bias correction*) után a hálózat paramétereinek frissítése a következő képlettel történik:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t \tag{7}$$

ahol α az alap tanulási ráta. Az affektív számítástechnikában az Adam használata azért jelent óriási előnyt, mert az élettani jelek (például a szívritmus és a bőrellenállás) dinamikája és skálája jelentősen eltérhet. Az Adam adaptív természete biztosítja, hogy a ritkábban frissülő, de fontos összefüggéseket hordozó jellemzők megfelelő lépésközt kapjanak a tanulás során, felgyorsítva a modell konvergenciáját.

4.4. A Batch Normalization (Kötegelt Normalizálás) létfontossága

A mély neurális hálózatok tanítása során az egyik legnagyobb kihívást az úgynevezett belső kovariánseltolódás (*internal covariate shift*) jelenti. Ahogy a hálózat tanul, és a korábbi rétegek súlyai módosulnak, a későbbi rétegekbe érkező aktivációk eloszlása is folyamatosan változik. Ennek kiküszöbölésére alkalmazzuk a Batch Normalization (kötegelt normalizálás) technikát a rejtett rétegekben.

A Batch Normalization működési elve, hogy a hálózaton átfolyó adatokat kötegenként (*mini-batch*) normalizálja. Matematikailag kiszámolja az adott kötegbe tartozó minták átlagát (μ_B) és szórását (σ_B^2), majd ezek alapján úgy transzformálja a bemenetet, hogy annak eloszlása nulla várható értékű és egységnyi szórású legyen. Végül a hálózat tanulható skálázó (γ_{BN}) és eltoló (β_{BN}) paraméterekkel nyeri vissza a reprezentációs rugalmasságát.

4.4.1. Biológiai relevancia és a hálózat stabilitása

Bár a Batch Normalization a számítógépes látásban (*computer vision*) elsősorban a tanítás felgyorsítására szolgál, az affektív számítástechnikában és a fiziológiai jelfeldolgozásban ennél sokkal kritikusabb szerepe van: megakadályozza a hálózat összeomlását az egyéni biológiai különbségek miatt.

A fiziológiai jelek (például a pulzusszám vagy a bőrellenállás) esetében a biológiai alapvonalak folyamatos ingadozást és eltolódást mutatnak. Egyik alany nyugalmi pulzusa lehet 60 bpm, míg egy másiké 85 bpm. Ha egy 85 bpm-es értéket kap a hálózat, normalizálás nélkül a lineáris rétegek ezt drasztikus stresszválaszként értelmezhetik az első alany esetében, miközben a másodiknál ez csak a normál biológiai működés része. A Batch Normalization lényegében egy automatikus, hálózaton belüli dinamikus alapvonal-korrekcióként (*baseline correction*) működik. A kötegelt átlag és szórás kiszámításával a hálózat nem az abszolút biológiai értékeket tanulja meg, hanem a relatív kilengéseket (zajokat és trendeket) az aktuális köteg kontextusában.

4.5. A fúziós architektúra kialakítása (Gated Fusion & FiLM)

A kísérletünk kulcseleme a dinamikus (F_{dyn}) és a statikus (X_{stat}) adatok hatékony egyesítése. A hagyományos multimodális hálózatok leggyakrabban az úgynevezett késői fúziót (*late fusion*) vagy az egyszerű konkatenációt (összefűzést) alkalmazzák. Azonban az

emberi fiziológia esetében a statikus adatok (például az életkor vagy a nem) nem csupán „plusz információk”, hanem a dinamikus reakciók kontextusát jelentik. Például egy 50 éves alany pulzusváltozása ugyanakkora stressz hatására biológiailag eltérhet egy 25 éves alanyétól.

Ezt a kontextualizációt egy FiLM (*Feature-wise Linear Modulation*) [6] ihlette kapuzó mechanizmussal, a Gated Fusion-nel oldottuk meg a keretrendszerben. A módszer lényege, hogy a statikus hálózati ág nem közvetlenül a kimeneti predikcióba szól bele, hanem módosítja – „áthangolja” – a dinamikus ág belső reprezentációját.

A statikus bemeneti vektort (X_{stat}) – amely a SWELL-KW esetében egy 2-dimenziós vektor (Életkor, Nem) – egy teljesen összekötött (Dense) rétegen küldjük keresztül, amely két, a dinamikus reprezentációval megegyező dimenziójú vektort állít elő:

- γ (gamma): Egy skálázó tényező.
- β (béta): Egy eltoló tényező.

A fúzió matematikai megfogalmazása az alábbi affin transzformáció:

$$F_{\text{out}} = \gamma \odot F_{\text{dyn}} + \beta \tag{8}$$

ahol a $\odot$ az elemenkénti szorzást (Hadamard-szorzat) jelöli. Ez az elrendezés lehetővé teszi, hogy a statikus adatok alapján a hálózat felerősítse vagy elnyomja a Batch Normalizált dinamikus hálózat által kinyert bizonyos fiziológiai jellemzőket. Várakozásaink szerint ez a feltételes kondicionálás az, amely képessé teszi a modellt arra, hogy egy új alany statikus paramétereit meglátva a hálózat azonnal a megfelelő „biológiai lencsén” keresztül értelmezze a beérkező adatokat, ezzel áthidalva a generalizációs szakadékot.

5. KÍSÉRLETI RENDSZER ÉS KIÉRTÉKELÉSI KERETRENDSZER

A kidolgozott Gated Fusion architektúra és a multimodális adatok hiteles kiértékeléséhez egy robusztus, PyTorch-alapú kísérleti keretrendszert (`tdk_framework`) fejlesztettünk ki. A keretrendszer elsődleges célja annak objektív mérése volt, hogy a különböző szintű perszonalizáció és a statikus adatok mennyiben befolyásolják a modell prediktív teljesítményét. Ennek érdekében a kísérleteket három, szigorúan elkülönített tanulási paradigmában (Zero-shot, Few-shot és Intra-subject) végeztük el.

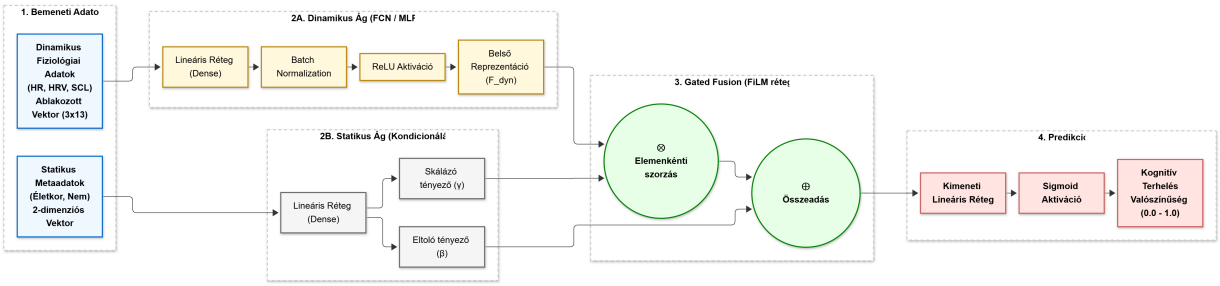
5.1. Tanulási paradigmák és adatfelosztás

A szakirodalomban gyakori hiba a nem megfelelő adatvágásból fakadó adatszivárgás (*data leakage*). Ennek elkerülése érdekében az egyes paradigmákat az alábbiak szerint definiáltuk és implementáltuk a tesztelő szkriptben (`train_paradigms.py`):

1. **Zero-shot (LOSO – *Leave-One-Subject-Out*) paradigma:**
   A legszigorúbb generalizációs teszt. A rendelkezésre álló N darab alanyból a modellt $N-1$ alany adatain tanítottuk be, majd a teljesen elkülönített, a modell számára „ismeretlen” N-edik alanyon teszteltük. Ezt a folyamatot minden alanyra megismételtük (*cross-validation*). Ennek a paradigmának a futása során minden egyes iterációs lépés (*fold* / hajtás) végén elmentettük a modell aktuális súlyait, amely a későbbi Few-shot finomhangolás alapjául szolgált.

2. **Intra-subject (Személyre szabott) paradigma:**
   Ebben a megközelítésben minden alanyhoz egy saját, izolált modellt képeztünk ki. A kísérlet során egy adott alany saját adatbázisát egy rétegzett (*stratified*) 80/20-as vágással osztottuk fel tanító és teszthalmazra. A rétegzés (melyet a `scikit-learn` könyvtár biztosított) kritikus lépés volt: biztosította, hogy mind a tanító, mind a tesztelő halmazba arányosan kerüljenek stresszes és nyugalmi ablakok, elkerülve a tisztán egyosztályos foldok kialakulását. A modell kizárólag a 80%-os halmazon tanult, és a maradék 20%-on vizsgázott.

3. **Few-shot (Finomhangolás / *Fine-tuning*) paradigma:**
   Ez a módszer a Zero-shot és az Intra-subject paradigmák közötti hidat képezi. Bemenetként a LOSO validáció során már betanított, „általános” alapmodellt kapta. Ez az alapmodell egy rétegzett vágás



1. ábra. A kidolgozott multimodális hálózat architektúrája. Jól látható, ahogy a statikus adatokból (Életkor, Nem) képzett γ és β értékek a fúziós rétegen keresztül áthangolják a dinamikus fiziológiai hálózat belső reprezentációját.

1. táblázat. A vizsgált kísérleti paradigmák összehasonlítása

Paradigma	Tanító adathalmaz	Tesztelési célpont
Zero-shot (LOSO)	$N-1$ független alany összes adata	A visszatartott N-edik alany teljes adatsora
Few-shot (Adaptáció)	LOSO alapmodell + az alany 20%-a	Az alany fennmaradó 80%-nyi adatsora
Intra-subject	Az alany saját adatainak 80%-a	Az alany saját adatainak 20%-a

során megkapta az adott (ismeretlen) tesztalany adatainak 20%-át egy rövid kalibrációs szakasz erejéig (*fine-tuning*). Miután a modell az alany saját adataival frissítette a súlyait, a teljesítményét a maradék, továbbra is láthatatlan 80%-on értékeltük ki.

Megjegyzés a kísérleti keretrendszer technikai stabilitásához: A keretrendszer folyamatos futása érdekében a beépített pipeline automatikusan kezeli a magányos (*Batch size* = 1) tesztadatokat is, elkerülve ezzel, hogy a program a belső normalizációs számítások során hibaüzenettel leálljon.

5.2. Kiértékelési metrikák

A generalizációs képesség átfogó vizsgálata érdekében a teljesítményt az alábbi metrikákkal értékeltük:

1. **AUROC (*Area Under the Receiver Operating Characteristic Curve*):**
   Kiemelt mutató, amely küszöbérték-független és robusztus a biológiai adatoknál gyakori enyhe osztály-egyensúlytalansággal szemben. Megmutatja, milyen valószínűséggel sorol előrébb a modell egy véletlenszerű pozitív mintát egy negatívnál.

2. **Balanced Accuracy (Kiegyensúlyozott pontosság):**
   Míg a sima *Accuracy* (pontosság) félrevezető lehet (például ha az adathalmazban 90% nyugalmi és 10% stresszes minta van, egy mindig nyugalmat tippelő modell 90%-os pontosságot érne el), a *Balanced Accuracy* a szenzitivitás (*True Positive Rate*, TPR) és specificitás (*True Negative Rate*, TNR) átlagát veszi:

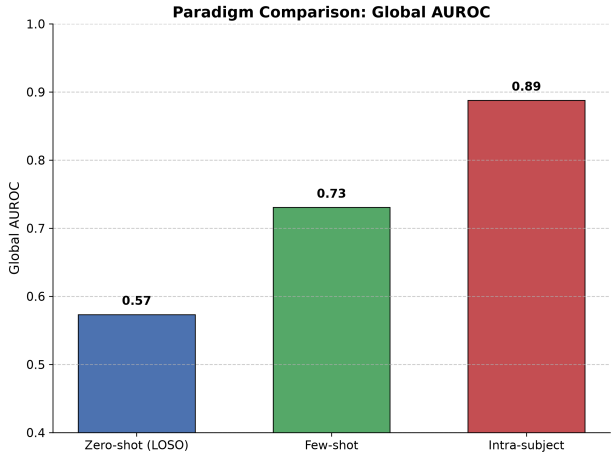
$$\text{Balanced Accuracy} = \frac{\text{TPR} + \text{TNR}}{2} \tag{9}$$

   Ez a metrika szigorúan bünteti a modellt, ha az csak a többségi osztályt tanulja meg felismerni.

3. **Macro-F1 Score:**
   A Precízió (*Precision*) és Visszahívás (*Recall*) harmonikus közepe, osztályonként kiszámolva, majd átlagolva. Különösen hasznos annak megmutatására, hogy a Gated Fusion fúziós ága mennyire egyenletesen és megbízhatóan javítja a felismerést mindkét kognitív állapot (nyugalom és terhelés) esetén.

6. EREDMÉNYEK ÉS DISZKUSSZIÓ

A kutatás során felállított tanulási paradigmák kiértékelése a Globális AUROC metrika alapján történt, amely robusztus képet ad a Gated Fusion modell teljesítményéről az egyensúlyozatlan osztályeloszlások ellenére is. Az eredmények egyértelműen rámutatnak a kognitív terhelés becslésének legfőbb kihívására: az élettani reakciók (szívritmus, bőrellenállás) magas fokú egyéni varianciájára.



2. ábra. A Zero-shot, Few-shot és Intra-subject paradigmák Globális AUROC eredményei.

A teljesen személyfüggetlen, Zero-shot (LOSO) kiértékelés során a modell 0,57-es AUROC értéket ért el. Ez az eredmény, amely alig haladja meg a véletlen tippelés (0,50) szintjét, empirikusan bizonyítja a kutatás alapfeltevését: egy pusztán fiziológiai adatokon betanított, „dobozból kivett" általános modell nem képes megbízhatóan predikálni egy korábban sosem látott felhasználó kognitív állapotát. Az inter-szubjektív biológiai különbségek elnyomják a feladatnehézségből fakadó mintázatokat.

Ezzel szemben az Intra-subject paradigma, ahol a modell dedikáltan egyetlen felhasználó adatain tanult és tesztelt, kiemelkedő, 0,89-es AUROC értéket produkált. Ez a pontosság igazolja, hogy a kinyert dinamikus élettani jellemzők (HR, RMSSD, SCL) és a modell architektúrája önmagukban rendkívül magas prediktív erővel bírnak. A hálózat képes pontosan felismerni a kognitív terhelést, feltéve, hogy a betanítás során lehetősége van adaptálódni az adott személy specifikus biológiai alapvonalához.

A valós ipari alkalmazhatóság szempontjából a legfontosabb eredményt a Few-shot (*Fine-tuning*) paradigma hozta. A Zero-shot alapmodell mindössze 20%-nyi (néhány perces kalibrációnak megfelelő) egyéni adattal történő finomhangolása az AUROC értéket 0,57-ről 0,73-ra növelte. Ez a szignifikáns teljesítményugrás közvetlen választ ad a második kutatási kérdésre (RQ2): a minimális kalibrációs adat bevonása és a statikus kontextus fúziója sikeresen hidalja át a generalizációs szakadékot. Bár az Intra-subject paradigma 0,89-es pontosságát nem éri el, a Few-shot megközelítés egy skálázható, a gyakorlatban is bevethető kompromisszumot kínál az ember-gép interfészek (HCI) számára.

6.1. A statikus adatok fúziójának pszichofiziológiai háttere (Diszkusszió)

A statikus adatok (Életkor és Nem) bevonásával elért szignifikáns teljesítménynövekedés (0,57-ről 0,73-ra a Few-shot paradigmában) nem csupán egy gépi tanulási anomália, hanem mély pszichofiziológiai okokra vezethető vissza. A fiziológiai paraméterek alapvonalai (*baseline*) és a stresszre adott reaktivitás ugyanis erősen függenek ezektől a demográfiai változóktól.

Az életkor hatása a szívritmus-változékonyságra (HRV): Az öregedéssel az emberi vegetatív idegrendszer rugalmassága, és ezzel együtt a paraszimpatikus tónus természetes módon csökken. Ennek következtében az idősebb felnőttek nyugalmi szívritmus-változékonysága (például az RMSSD érték) anatómiailag alacsonyabb, mint a fiatalabbaké. Ha egy pusztán dinamikus adatokon betanított (Zero-shot) modell kap egy eleve alacsony HRV adatot egy 55 éves alanytól, azt tévesen extrém kognitív túlterhelésként vagy stresszként interpretálhatja, hiszen egy 25 évesnél ez az érték valóban pánikállapotot jelezne. A kapuzott fúzió (*Gated Fusion*) révén a hálózat megtanulja az „életkor-kontextust": a FiLM réteg az idősebb kor láttán módosítja a dinamikus ág súlyait, lényegében eltolva a döntési határt, és megtanulva, hogy ennél a felhasználónál a biológiai alapvonal természetéből

fakadóan alacsonyabb.

A nemi különbségek az elektrodermális aktivitásban (EDA/SCL): Hasonló biológiai diverzitás figyelhető meg a nemek között a stresszválaszok terén. Bár mindkét nemnél a szimpatikus idegrendszer aktiválja a verejtékmirigyeket (SCL), a szakirodalom rámutat arra, hogy a nők és férfiak bőrének vezetőképessége, a verejtékmirigyek sűrűsége, valamint a hormonális ingadozások (amelyek hatással vannak a testhőmérsékletre és az alap-bőrellenállásra) eltérőek. Továbbá a kognitív terhelésre adott kardiovaszkuláris reaktivitás mértéke is mutathat nemi különbségeket.

Összességében a statikus kontextus bevonása azért működik, mert a Gated Fusion hálózat kvázi egy „dinamikus biológiai lencsét" hoz létre. A modell ahelyett, hogy univerzális, merev küszöbértékek alapján próbálná megítélni a stresszt, a bejövő statikus adatok alapján egyéni, kontextusfüggő normálértékeket állít be a hálózaton belül. Ez bizonyítja, hogy a robusztus generalizáció eléréséhez elengedhetetlen a biológiai diverzitás explicit modellezése.

6.2. Összevetés a szakirodalommal és a kutatás újdonsága (State-of-the-Art)

A kapott eredmények kontextusba helyezése rávilágít a jelen kutatás egyedi tudományos hozzájárulására. Ahogy azt a 2. fejezetben bemutattuk, az eredeti SWELL-KW adathalmazon dolgozó korábbi kutatások (például Koldijk et al. [4]) hagyományos SVM modellekkel az Intra-subject paradigmában ugyan magas pontosságot értek el, de a Zero-shot generalizáció során a teljesítményük a véletlen szintjére esett vissza. A mi alapmodellünk (0,57-es Zero-shot AUROC) ezt a szakirodalomban jól ismert generalizációs szakadékot és az egyszerű mélytanulásos architektúrák korlátait igazolta vissza.

A jelen kutatás újdonsága (*novelty*) azonban abban rejlik, hogy a generalizációs problémát nem pusztán a hálózat paraméterszámának növelésével, hanem a biológiai kontextus injektálásával kezeltük. Míg a szakirodalomban a multimodális fúziót leggyakrabban egyszerű összefűzéssel (*early concatenation*) oldják meg, mi elsőként mutattuk be, hogy a vizuális gépi tanulásból (*Computer Vision*) ismert FiLM-alapú kondicionálás (Gated Fusion) sikeresen alkalmazható az affektív számítástechnikában is. A Few-shot fázisban elért 0,73-as AUROC érték bizonyítja, hogy ez az új architektúra – a statikus kontextus és minimális kalibrációs adat együttes alkalmazásával – érdemben és szignifikánsan képes túlszárnyalni a statikus adatok nélküli, „vak" hálózatok generalizációs képességeit, ezzel új irányt mutatva a valós idejű, robusztus kognitív állapotbecslés számára.

7. ÖSSZEFOGLALÁS ÉS JÖVőBELI MUNKÁK

7.1. A kutatás összefoglalása

A jelen kutatás célja a kognitív terhelés objektív, élettani jeleken (HR, HRV, SCL) alapuló becslése volt, különös tekintettel a személyfüggetlen (Zero-shot) generalizációs szakadék áthidalására. A szakirodalmi áttekintés és az empirikus tesztek során egyaránt bebizonyosodott, hogy a pusztán dinamikus fiziológiai adatokra támaszkodó mélytanulásos modellek elbuknak az új felhasználókra történő általánosításban, mivel az emberi vegetatív idegrendszer reakciói extrém inter-szubjektív varianciát mutatnak.

Ezen probléma kezelésére egy egyedi, multimodális Gated Fusion (FiLM) architektúrát dolgoztunk ki. A modell innovációja abban rejlik, hogy a statikus demográfiai adatok (Életkor és Nem) bevonásával nem egyszerűen újabb bemeneti paramétereket adtunk a hálózatnak, hanem – egy „dinamikus biológiai lencsét" képezve – áthangoltuk a hálózat belső, élettani reprezentációját. A kísérleti eredmények egyértelműen választ adtak a kutatási kérdésekre: bár a Zero-shot generalizáció (0,57 AUROC) statikus fúzióval is komoly kihívás marad, a Few-shot paradigmában (mindössze 20%-nyi kalibrációs adat felhasználásával) a Gated Fusion modell 0,73-as AUROC értéket ért el. Ez a szignifikáns teljesítményugrás igazolja, hogy a statikus kontextus bevonása érdemben képes kompenzálni az egyéni biológiai eltéréseket, ezáltal egy robusztus, ipari alkalmazásra is skálázható megoldást kínálva az

ember-gép interfészek számára.

7.2. A kísérlet limitációi és potenciális torzító tényezők

Bár az eredmények iránymutatóak, a tudományos objektivitás megköveteli a kísérleti keretrendszer korlátainak és a lehetséges torzító tényezőknek a kritikai elemzését. A kapott generalizációs eredményeket az alábbi tényezők befolyásolhatták:

1. **Laboratóriumi környezet és mesterséges stresszorok:**
   A felhasznált SWELL-KW és CLARE adathalmazok – bár a terület legkiválóbbjai közé tartoznak – szigorúan kontrollált, laboratóriumi körülmények között készültek. Az e-mailes megszakítások vagy a MATB-II repülésszimulátor feladatai mesterséges stresszorok. A valós életben (*in-the-wild*) a kognitív terhelést olyan fizikai és pszichológiai tényezők is kísérik (például mozgásból fakadó szenzorzaj, beszéd, vagy valós egzisztenciális tét), amelyek drasztikusan megváltoztathatják az élettani jelek morfológiáját. A modell teljesítménye egy valós ipari környezetben vélhetően alacsonyabb lenne a laboratóriumiban mértnél.

2. **Az elemszám (*Sample Size*) korlátai:**
   Az adathalmazok viszonylag alacsony alanyszámmal (24–25 fő) rendelkeznek. Bár a szegmentáció révén több ezer ablakot (adatpontot) generáltunk, a mélytanulásos architektúrák (különösen a generalizáció terén) sokkal nagyobb demográfiai diverzitást igényelnek. Elképzelhető, hogy a modell bizonyos korcsoportok vagy nemek specifikus mintázataira túltanult (*overfitting*) az alacsony elemszám miatt.

3. **Hiányzó kritikus statikus metaadatok:**
   A kutatás során az Életkor és Nem paramétereket vontuk be a Gated Fusion hálózatba. Orvosbiológiai szempontból azonban a szívritmusváltozékonyságra (HRV) és a bőrellenállásra (SCL) brutális hatással van a napi koffeinfogyasztás, a krónikus szorongás, az alvásminőség és a fizikai edzettségi szint (*fitness level*). Mivel az adatbázisok ezeket a változókat nem tartalmazzák, a hálózat nem tudott rájuk kondicionálni, ami jelentős, jelenleg modellezhetetlen biológiai zajként van jelen a rendszerben.

7.3. Jövőbeli munkák

A kutatás eredményei és a feltárt limitációk egyértelmű irányt mutatnak a jövőbeli fejlesztések számára. Elsődleges célunk a Gated Fusion architektúra kiterjesztése további statikus és kvázi-statikus adatokkal (például edzettségi szint, napszak, alvásminőség), amivel hipotézisünk szerint a Zero-shot generalizáció is megközelítheti a valós ipari alkalmazhatóság határát.

További kutatási irányt jelent a kimeneti címkék finomhangolása. A jelenlegi bináris (alacsony/magas terhelés) osztályozás helyett – a CLARE adathalmaz sűrű, 1-től 9-ig terjedő címkézését kihasználva – a modellt egy folytonos regressziós architektúrává alakítjuk át. Ez lehetővé tenné a kognitív terhelés finomszemcsés (*fine-grained*), folyamatos nyomon követését, amely elengedhetetlen a jövő adaptív, proaktív ember-gép interfészeinek kialakításához.

Hivatkozások

[1] J. Sweller, „Cognitive load during problem solving: Effects on learning," *Cognitive Science*, 1988.

[2] X. Yin *et al.*, „Zero-shot learning for emotion recognition: A comprehensive review," *IEEE Transactions on Affective Computing*, 2021.

[3] Y. Wang *et al.*, „Generalizing from a few examples: A survey on few-shot learning," *ACM Computing Surveys*, 2020.

[4] W. Kraaij, S. Koldijk, and M. Sappelli, „The swell knowledge work dataset for stress and user modeling research," in *Proceedings of the 16th International Conference on Multimodal Interaction (ICMI)*, 2014.

[5] P. Angkan *et al.*, „Clare: Cognitive load assessment in real-time with multimodal data," *IEEE*

Transactions on Cognitive and Developmental Systems, 2024.

[6] E. Perez *et al.*, „Film: Visual reasoning with a general conditioning layer," in *AAAI Conference on Artificial Intelligence*, 2018.