

Kognitív terhelés becslése és generalizáció statikus adatok fúziójával

1. Bevezetés és a kutatás célja

A kognitív terhelés mérése és folyamatos monitorozása az elmúlt évtizedben kiemelt kutatási területté vált az ember-gép interfészek (Human-Computer Interaction, HCI), az affektív számítástechnika és az ergonómia területén. A kognitív túlterhelés nemcsak a teljesítmény csökkenéséhez és a hibázási arány növekedéséhez vezet kritikus rendszerek üzemeltetése során, hanem hosszú távon a felhasználó jóllétét is veszélyezteti. Emiatt egyre nagyobb az igény olyan objektív, nem tolakodó módszerekre, amelyek valós időben képesek becslni az aktuális terhelési és stressz-szintet.

Bár a fiziológiai jelek – mint például a pupillaméret, a szívritmus-változékonyság (HRV), vagy a bőrellenállás (SCL) – elemzése ígéretes eredményeket mutat a terhelés becslésében, a meglévő gépi tanulási modellek a gyakorlatban komoly akadályba ütköznek: a generalizáció problémájába. A kognitív terhelésre és a stresszre adott fiziológiai reakciók extrém mértékű egyéni variációt mutatnak. Ami az egyik felhasználónál a stressz egyértelmű jele (pl. jelentős pulzusemelkedés), az egy másikinál lehet normál ingadozás.

Ennek következtében a hagyományos modellek a szakirodalomban kétféle kiértékelési paradigmában vizsgáztak, eltérő sikerrel. A kutatásunk ezen paradigmák vizsgálatára és kiterjesztésére épül:

- **Zero-shot generalizáció:** A gépi tanulásban és az affektív számítástechnikában a *zero-shot* megközelítés azt jelenti, hogy a modellt olyan adatokon (jelen esetben egy teljesen új, ismeretlen felhasználón) teszteljük, amelyről a betanítás során semmilyen információval nem rendelkezett [3]. Ez a legszigorúbb, egyben legéletszerűbb tesztelési forma (az iparban "out-of-the-box" működésnek is hívják). A meglévő rendszerek itt drasztikus teljesítményromlást, sok esetben véletlen tippeléssel megegyező pontosságot produkálnak az egyéni biológiai zaj miatt.
- **Few-shot generalizáció (finomhangolás):** A *few-shot* tanulás során a modell kap egy minimális, néhány mintából álló adathalmazt az új tesztalanytól. Ezzel a rövid, úgynevezett kalibrációs szakasszal a modell finomhangolható (fine-tuning), így képes alkalmazkodni az egyéni biológiai sajátosságokhoz anélkül, hogy a nulláról kellene betanítani az adott személyre [4].

Kutatásunk célja a zero-shot generalizációs szakadék áthidalása, valamint a few-shot adaptáció hatékonyságának növelése. Fő innovációnk a tisztán fiziológiai (dinamikus) adatok kiegészítése statikus, kontextuális információkkal (például demográfiai adatokkal vagy feladatnehézséggel) egy egyedi, kapuzott fúziós (Gated Fusion) mechanizmuson keresztül. Hipotézisünk szerint a modell a statikus adatok bevonásával képessé válik az egyéni biológiai különbségek

kompenzálására, és így javul az új felhasználókra történő általánosítási képessége.

A kutatás során az alábbi három fő kérdésre (Research Questions, RQ) keressük a választ:

- **RQ1:** Képes-e a statikus adatok fúziója szignifikánsan javítani a modell személyfüggetlen (Zero-shot) generalizációs képességét a csupán fiziológiai alapon működő modellekhez képest?
- **RQ2:** Hogyan változik a predikció pontossága, ha a Zero-shot megközelítés helyett Few-shot paradigmát alkalmazunk, és ezen a téren mekkora előnyt jelent a statikus fúzió?
- **RQ3:** Milyen adat-előfeldolgozási lépések (pl. mozgóablakos szegmentáció, interpoláció, alany-szintű normalizálás) elengedhetetlenek ahhoz, hogy a hálózat képessé váljon a robusztus generalizációra?

2. Az adathalmazok és az előfeldolgozási pipeline

A modellek tanításához, kiértékeléséhez és a generalizációs képesség robusztusságának vizsgálatához elengedhetetlen volt olyan multimodális adathalmazok bevonása, amelyek elegendő elemszámot biztosítanak, és több modalitást is lefednek. A kutatás során két nyílt forráskódú adatbázist, a CLARE [1] és a SWELL-KW [2] adathalmazokat alkalmaztuk.

2.1. Adathalmazok bemutatása és korábbi felhasználásuk a szakirodalomban

A **SWELL-KW (SWELL Knowledge Work)** [2] adatbázist széleskörűen alkalmazzák a szakirodalomban a munkahelyi stressz és a kognitív terhelés detektálására. Koldijk és munkatársai eredeti publikációjukban [2] klasszikus gépi tanulási algoritmusokkal (pl. SVM) vizsgálták a stressz felismerhetőségét. Kísérleteik rávilágítottak arra, hogy az egyéni különbségek jelentősen rontják a modellek pontosságát, ha a tanítás nem alanyonként (intra-subject) történik. A jelen kutatás ezen a felismerésen alapulva kísérli meg a biológiai variancia áthidalását statikus demográfiai adatok fúziójával. A SWELL-KW adatbázis 25 irodai dolgozó adatait tartalmazza különböző munkahelyi stresszhelyzetek (relaxáció, időnyomás, megszakítás) során, ahonnan percenkénti bontásban állnak rendelkezésre élettani jelek.

A **CLARE (Cognitive Assessment in Realtime with Multimodal Data)** adatbázis [1] egy frissebb, kifejezetten a szemkövetésre és multimodális kognitív terhelésre fókuszáló adathalmaz. A CLARE megalkotói [1] baseline modelljeik kiértékelésekor szintén felhívják a figyelmet arra, hogy a tisztán vizuális és fiziológiai alapú modellek validációja kereszt-alanyos (cross-subject) tesztelésnél nehézségekbe ütközik. Az adatbázis 24 résztvevő folyamatos méréseit tartalmazza. Jelen kutatás szempontjából a legfontosabbak a dinamikus szemkövetési adatok (pupillaméret, tekintetkoordináta), valamint a statikus kontextust biztosító feladatnehézségi szintek.

2.2. Előfeldolgozási módszertan és adatkinyerés

A nyers adatok gépi tanulásra alkalmassá tétele érdekében szigorú előfeldolgozási folyamatot (pipeline-t) alakítottunk ki a kísérleti keretrendszerben (tdk_framework), biztosítva a

PyTorch-kompatibilis, egységes adatstruktúrát.

A **SWELL-KW** adatbázis esetében a statikus és dinamikus adatok szinkronizációja volt az elsődleges feladat. A dinamikus bemenetet a fiziológiai szenzorokból (szívritmus - HR, szívritmus-változékonyság - RMSSD, bőrellenállás - SCL) származó percenkénti jellemzők adták. Az adathalmazban található mérési hibákat (melyeket az eredeti szerzők 999-es értékkel jelöltek) kiszűrtük, helyükre NaN értékeket rendeltünk, majd ezeket alanyonkénti átlagolással (vagy interpolációval) pótoltuk a folytonosság megőrzése érdekében. Statikus jellemzőként a résztvevők kérdőíves demográfiai adatait (Életkor, Nem) használtuk fel. A kategorikus nemet (férfi/nő) binárisan kódoltuk.

A kimeneti címkéket (labels) a bináris osztályozási feladathoz igazítottuk: a nyugalmi (Relaxation - R és Neutral - N) fázisokat alacsony terhelésként (0), míg az időnyomás (Time Pressure - T) és megszakítás (Interruption - I) alatt rögzített adatokat magas terhelési/stresszállapotként (1) kódoltuk. A keretrendszerben mozgóablakos (sliding window) technikát alkalmaztunk (ablakméret: 3, lépésköz: 1). Ez az előfeldolgozás globálisan összesen **3115 mintát (ablakot)** eredményezett, ebből 1505 a nyugalmi (0. osztály) és 1610 a terheléses (1. osztály) eset, amely szinte tökéletesen kiegyensúlyozott adathalmazt biztosított a hálózat tanításához. A kinyert dinamikus jellemzővektor ablakonként 13 dimenziós bemenetet biztosít a hálózat számára.

A **CLARE** adathalmaz feldolgozásánál a biológiai variancia csökkentése érdekében a fiziológiai adatokon alapvonalis korrekciót (TEPR - Task-Evoked Pupillary Response) hajtottunk végre. Ez a lépés a nyugalmi mérések kivonását jelenti, kiegyenlítve ezáltal az alanyok közötti természetes pupillaméret-különbségeket. Az adathalmaz 10 másodperces (50 Hz-es mintavételezésű) ablakait binarizált szubjektív terhelési pontszámokkal (alacsony vs. magas terhelés) láttuk el.

3. Saját módszertan és architektúra

A kognitív terhelés objektív becslése egy tipikus multimodális gépi tanulási probléma, ahol egyszerre állnak rendelkezésre (ablakokból kinyert) dinamikus fiziológiai jelek, valamint konstans (statikus) metaadatok az alanyról vagy a feladat környezetéről. A kutatásunk során kidolgozott, a tdk_framework-ben implementált architektúra két fő komponensből áll: egy teljesen összekötött (Fully Connected) feldolgozó ágból a dinamikus adatokhoz, és egy egyedi Gated Fusion (FiLM) mechanizmusból, amely a statikus adatokat integrálja.

3.1. A dinamikus adat feldolgozása (FCN és Batch Normalization)

A hálózat dinamikus ága egy mély, teljesen összekötött neurális hálózatra (Multi-Layer Perceptron / FCN) épül, amely közvetlenül az előfeldolgozó pipeline által kinyert (ablakonként 13-dimenziós) jellemzővektorokat fogadja. Bár a szekvenciális adatok elemzésénél gyakori a rekurrens hálózatok (RNN/GRU) használata, empirikus vizsgálataink során bebizonyosodott, hogy a megfelelő méretűre tömörített mozgóablakos jellemzők esetében az FCN egy jóval

gyorsabb és kevésbé túltanuló (overfitting) reprezentációt biztosít.

A dinamikus ág specifikus felépítése a következő:

1. **Lineáris rétegek (Linear / Dense):** A hálózat a laposított (flattened) bemeneti jellemzővektorokat egyre mélyebb, nemlineáris reprezentációkká alakítja.
2. **Kötegelt normalizálás (Batch Normalization):** A hálózat kritikus eleme. A fiziológiai paraméterek – egyénenként és modalitásonként (HR vs. SCL) is – radikálisan eltérő skálán mozoghatnak. A Batch Normalization rétegek beépítése a lineáris transzformációk közé biztosítja a rejtett aktivációk stabilitását, megakadályozza a kovariáns eltolódást (internal covariate shift), és elengedhetetlen a fúziós lépés hatékonyságához.

Ennek a dinamikus ágnak a kimenete a F_{dyn} (dinamikus) rejtett állapotvektor, amely tömörítve tartalmazza az adott időablak élettani folyamatait. Kutatásunk Baseline modellje kizárólag ebből az ágból áll.

3.2. A fúziós architektúra kialakítása (Gated Fusion & FiLM)

A kísérletünk kulcseleme a dinamikus (F_{dyn}) és a statikus (x_s) adatok hatékony egyesítése. A hagyományos multimodális hálózatok leggyakrabban az úgynevezett késői fúziót (late fusion) vagy az egyszerű konkatenációt (összefűzést) alkalmazzák. Azonban az emberi fiziológia esetében a statikus adatok (például az életkor vagy a nem) nem csupán "plusz információk", hanem a dinamikus reakciók *kontextusát* jelentik. Például egy 50 éves alany pulzusváltozása ugyanakkora stressz hatására biológiailag eltérhet egy 25 éves alanyétól.

Ezt a kontextualizációt egy FiLM (Feature-wise Linear Modulation) [5] ihlette kapuzó mechanizmussal, a Gated Fusion-nel oldottuk meg a keretrendszerben. A módszer lényege, hogy a statikus hálózati ág nem közvetlenül a kimeneti predikcióba szól bele, hanem módosítja – "áthangolja" – a dinamikus ág belső reprezentációját.

A statikus bemeneti vektort (x_s) – amely a SWELL-KW esetében egy 2-dimenziós vektor (Életkor, Nem) – egy teljesen összekötött (Dense) rétegen küldjük keresztül, amely két, a dinamikus reprezentációval megegyező dimenziójú vektort állít elő:

- γ (gamma): Egy skálázó tényező.
- β (béta): Egy eltoló tényező.

A fúzió matematikai megfogalmazása az alábbi affin transzformáció:

$$F_{\text{out}} = \gamma \odot F_{\text{dyn}} + \beta$$

ahol a $\odot$ az elemenkénti szorzást jelöli. Ez az elrendezés lehetővé teszi, hogy a statikus adatok alapján a hálózat felerősítse vagy elnyomja a Batch Normalizált dinamikus hálózat által kinyert bizonyos fiziológiai jellemzőket. Várakozásaink szerint ez a feltételes kondicionálás az, amely képessé teszi a modellt arra, hogy egy új alany statikus paramétereit meglátva a hálózat azonnal a megfelelő biológiai lencsén keresztül értelmezze a beérkező adatokat, ezzel áthidalva a generalizációs szakadékot.

4. Kísérleti rendszer és kiértékelési keretrendszer

A kidolgozott Gated Fusion architektúra és a multimodális adatok hiteles kiértékeléséhez egy robusztus, PyTorch-alapú kísérleti keretrendszert (tdk_framework) fejlesztettünk ki. A keretrendszer elsődleges célja annak objektív mérése volt, hogy a különböző szintű personalizáció és a statikus adatok mennyiben befolyásolják a modell prediktív teljesítményét. Ennek érdekében a kísérleteket három, szigorúan elkülönített tanulási paradigmában (Zero-shot, Few-shot és Intra-subject) végeztük el.

[Tanulas Keretrendszer Tablazat]

4.1. Tanulási paradigmák és adatfelosztás

A szakirodalomban gyakori hiba a nem megfelelő adatvágásból fakadó adatszivárgás (data leakage). Ennek elkerülése érdekében az egyes paradigmákat az alábbiak szerint definiáltuk és implementáltuk a tesztelő szkriptben (train_paradigms.py):

1. **Zero-shot (LOSO - Leave-One-Subject-Out) paradigma:**

A legszigorúbb generalizációs teszt. A rendelkezésre álló N darab alanyból a modellt $N-1$ alany adatain tanítottuk be, majd a teljesen elkülönített, a modell számára "ismeretlen" N -edik alanyon teszteltük. Ezt a folyamatot minden alanyra megismételtük (cross-validation). Ennek a paradigmának a futása során minden egyes fold (hajtás) végén elmentettük a modell aktuális súlyait, amely a későbbi Few-shot finomhangolás alapjául szolgált.

2. **Intra-subject (Személyre szabott) paradigma:**

Ebben a megközelítésben minden alanyhoz egy saját, izolált modellt képeztünk ki. A kísérlet során egy adott alany saját adatbázisát egy **rétegzett (stratified) 80/20-as vágással** osztottuk fel tanító és tesztalmazra. A rétegzés (melyet a scikit-learn könyvtár biztosított) kritikus lépés volt: biztosította, hogy mind a tanító, mind a tesztelő halmazba arányosan kerüljenek stresszes és nyugalmi ablakok, elkerülve a tisztán egyosztályos foldok kialakulását. A modell kizárólag a 80%-os halmazon tanult, és a maradék 20%-on vizsgázott.

3. **Few-shot (Finomhangolás / Fine-tuning) paradigma:**

Ez a módszer a Zero-shot és az Intra-subject paradigmák közötti hidat képezi. Bemenetként a LOSO validáció során már betanított, "általános" alapmodellt kapta. Ez az alapmodell egy rétegzett vágás során megkapta az adott (ismeretlen) tesztalany adatainak 20%-át egy rövid kalibrációs szakasz erejéig (fine-tuning). Miután a modell az alany saját adataival frissítette a súlyait, a teljesítményét a maradék, továbbra is láthatatlan 80%-on értékeltük ki.

4.2. Technikai implementáció és hálózatstabilitás

A keretrendszer implementációja során különös figyelmet kellett fordítani a dinamikus dimenziók stabilitására. Mivel az architektúra dinamikus ága nagymértékben támaszkodik a Batch Normalization (kötegetelt normalizáció) rétegekre, technikai problémát jelentett a túl kicsi teszt

vagy kalibrációs batch-ek (kötegek) mérete (például ha egy foldban csak 1 darab minta maradt egy adott osztályból).

Ennek orvoslására a kísérleti pipeline-ba beépítettünk egy dinamikus padding (kitöltő) és egy "single-sample duplication" (egyedi minta duplikáció) mechanizmust. Ez a lépés kizárólag a tanítási és finomhangolási fázisokban aktív, és garantálja, hogy a Batch Normalization statisztikái extrém kevés minta esetén (pl. a Few-shot kalibráció során) is robusztusan kiszámíthatók maradjanak, megelőzve a tanulási folyamat összeomlását.

4.3. Kiértékelési metrika (Globális AUROC)

A modellek teljesítményének mérésére az **AUROC (Area Under the Receiver Operating Characteristic curve)** metrikát alkalmaztuk. Ez a mérőszám azért előnyös az egyszerű pontossághoz (Accuracy) képest, mert robusztus a kiegyensúlyozatlan osztályokkal szemben, és megbízható képet ad a modell bináris osztályozó képességéről függetlenül a beállított küszöbértéktől (threshold). Az 0.5-ös érték felel meg a véletlen tippelésnek, míg az 1.0 a tökéletes predikciónak.

A fejlesztés során kiderült, hogy az alanyonként (lokálisan) számított, majd átlagolt AUROC értékek instabilak lehetnek. Előfordulhat, hogy egy-egy alany tesztalmazában – a rétegzés ellenére is, különösen kis elemszámú mintáknál – csak az egyik osztály képviselteti magát, ami matematikailag kiszámíthatatlanná (NaN értékűvé) teszi az adott fold AUROC értékét.

Emiatt a keretrendszerben a **Globális AUROC** számítási stratégiát vezettük be. Ennek lényege, hogy nem foldonként értékelünk, hanem a ciklusok során összegyűjtjük az összes alany és az összes fold predikcióját (y_{pred}), valamint a hozzájuk tartozó valós címkéket (y_{true}). A metrika kiszámítása csak egyszer, a futás legvégén történik meg a teljes, globálisan konkatenált predikciós vektoron, amely objektív és statisztikailag szignifikáns képet ad a választott paradigmáról.

5. Eredmények és diszkusszió

(Kidolgozás alatt)

6. Összefoglalás és jövőbeli munkák

(Kidolgozás alatt)

Hivatkozások

[1] P. Angkan, et al., "CLARE: Cognitive Load Assessment in Real-time with Multimodal Data," *IEEE Transactions on Cognitive and Developmental Systems*, 2023.

[2] W. Kraaij, S. Koldijk, M. Sappelli, "The SWELL Knowledge Work Dataset for Stress and User Modeling Research", *Proceedings of the 16th International Conference on Multimodal*

Interaction (ICMI), 2014.

[3] X. Yin, et al., "Zero-shot learning for emotion recognition: A comprehensive review," *IEEE Transactions on Affective Computing*, 2021.

[4] Y. Wang, et al., "Generalizing from a Few Examples: A Survey on Few-shot Learning," *ACM Computing Surveys*, 2020.

[5] E. Perez, et al., "FiLM: Visual Reasoning with a General Conditioning Layer," *AAAI Conference on Artificial Intelligence*, 2018.