

Kognitív terhelés becslése és generalizáció statikus adatok fúziójával

1. Bevezetés és a kutatás célja

A kognitív terhelés mérése és folyamatos monitorozása az elmúlt évtizedben kiemelt kutatási területté vált az ember-gép interfészek (Human-Computer Interaction, HCI), az affektív számítástechnika és az ergonómia területén. A kognitív túlterhelés nemcsak a teljesítmény csökkenéséhez és a hibázási arány növekedéséhez vezet kritikus rendszerek üzemeltetése során, hanem hosszú távon a felhasználó jóllétét is veszélyezteti. Emiatt egyre nagyobb az igény olyan objektív, nem tolakodó módszerekre, amelyek valós időben képesek becsülni az aktuális terhelési és stressz-szintet.

1.1. Kognitív terhelés és stressz - elméleti háttér

A mérnöki és informatikai irodalomban a "kognitív terhelés" és a "stressz" fogalmát gyakran szinonimaként, vagy legalábbis egymással felcserélhető állapotokként használják. Egy robusztus gépi tanulási modell felépítéséhez azonban elengedhetetlen ezen pszichofiziológiai fogalmak pontos elméleti tisztázása és szétválasztása.

A kognitív terhelés elméletét (Cognitive Load Theory, CLT) John Sweller alkotta meg az 1980-as évek végén [6]. Az elmélet alapfeltevése, hogy az emberi munkamemória (working memory) kapacitása szigorúan korlátozott: egyszerre csak meghatározott számú információelemet képes feldolgozni. Sweller az elméletében a terhelést három fő kategóriára bontotta:

1. **Belső (Intrinsic) kognitív terhelés:** Magának a feladatnak az objektív, eredendő bonyolultságából fakad (például egy komplex matematikai egyenlet megoldása nehezebb, mint egy egyszerű összeadás).
2. **Külső (Extraneous) kognitív terhelés:** A feladat prezentációjának módjából ered. A rosszul tervezett felhasználói interfészek (UI), a zavaró tényezők és a felesleges információk növelik ezt a terhelést.
3. **Hasznos (Germane) kognitív terhelés:** A tanulásra, a sémák (mentális modellek) kialakítására és az új információk hosszú távú memóriába való integrálására fordított szellemi erőfeszítés.

Amikor ezen három tényező összege meghaladja az egyén aktuális munkamemória-kapacitását, *kognitív túlterhelés* (cognitive overload) lép fel.

Ezzel szemben a **stressz** egy sokkal tágabb biológiai és pszichológiai fogalom. A stressz a szervezet nem specifikus válasza bármilyen olyan külső vagy belső ingerre (stresszorra), amely kibillent a testet a homeosztázisából, vagy fenyegetést jelent számára.

A két fogalom közötti átfedést a pszichofiziológiai reakciók adják. Amikor egy felhasználó kognitív túlterhelést tapasztal (például egy repülésirányító, akinek hirtelen túl sok paramétert

kell párhuzamosan figyelnie), az agy ezt a kudarcélményt és nyomást *pszichológiai stresszorként* érzékeli. A kognitív túlterhelés ezáltal aktiválja a vegetatív idegrendszer (Autonomic Nervous System, ANS) szimpatikus ágát, beindítva a klasszikus "üss vagy fuss" (fight-or-flight) válaszreakciót.

Ennek a biológiai összefonódásnak köszönhető, hogy a tisztán szellemi, kognitív folyamatok (munkamemória-kihasználtság) mérhetővé válnak perifériás élettani szenzorokkal. A megnövekedett kognitív terhelés a szimpatikus idegrendszeren keresztül olyan megfigyelhető változásokat idéz elő a szervezetben, mint a szívritmus felgyorsulása, a szívritmus-változékonyság (HRV) csökkenése, vagy a tenyéren lévő verejtékmirigyek aktivitása miatti bőrellenállás-csökkenés (SCL). Bár az élettani jelek kiváló indikátorai ennek a megemelkedett "arousal" (készenléti) állapotnak, a köztük lévő leképezés nem egyértelmű és nem lineáris, ami komoly mérnöki kihívásokat vet fel.

1.2. A generalizáció problémája az affektív számítástechnikában

Bár a fiziológiai jelek elemzése ígéretes eredményeket mutat a terhelés becslésében, a meglévő gépi tanulási modellek a gyakorlatban komoly akadályba ütköznek: a generalizáció problémájába. A kognitív terhelésre és a stresszre adott fiziológiai reakciók extrém mértékű egyéni variációt mutatnak. Ami az egyik felhasználónál a stressz egyértelmű jele (pl. jelentős pulzusemelkedés), az egy másikinál lehet normál biológiai ingadozás.

Ennek következtében a hagyományos modellek a szakirodalomban kétféle kiértékelési paradigmában vizsgáztak, eltérő sikerrel. A kutatásunk ezen paradigmák vizsgálatára és kiterjesztésére épül:

- **Zero-shot generalizáció:** A gépi tanulásban és az affektív számítástechnikában a *zero-shot* megközelítés azt jelenti, hogy a modellt olyan adatokon (jelen esetben egy teljesen új, ismeretlen felhasználón) teszteljük, amelyről a betanítás során semmilyen információval nem rendelkezett [3]. Ez a legszigorúbb, egyben legéletszerűbb tesztelési forma (az iparban "out-of-the-box" működésnek is hívják). A meglévő rendszerek itt drasztikus teljesítményromlást, sok esetben véletlen tippeléssel megegyező pontosságot produkálnak az egyéni biológiai zaj miatt.
- **Few-shot generalizáció (finomhangolás):** A *few-shot* tanulás során a modell kap egy minimális, néhány mintából álló adathalmazt az új tesztalanytól. Ezzel a rövid, úgynevezett kalibrációs szakasszal a modell finomhangolható (fine-tuning), így képes alkalmazkodni az egyéni biológiai sajátosságokhoz anélkül, hogy a nulláról kellene betanítani az adott személyre [4].

1.3. A kutatás célja és a vizsgálati kérdések (RQ)

Kutatásunk célja a zero-shot generalizációs szakadék áthidalása, valamint a few-shot adaptáció hatékonyságának növelése. Fő innovációnk a tisztán fiziológiai (dinamikus) adatok kiegészítése statikus, kontextuális információkkal (például demográfiai adatokkal vagy feladatnehézséggel) egy egyedi, kapuzott fúziós (Gated Fusion) mechanizmuson keresztül. Hipotézisünk szerint a modell a statikus adatok bevonásával képessé válik az egyéni biológiai különbségek

kompenzálására, és így javul az új felhasználókra történő általánosítási képessége.

A kutatás során az alábbi három fő kérdésre (Research Questions, RQ) keressük a választ:

- **RQ1:** Képes-e a statikus adatok fúziója szignifikánsan javítani a modell személyfüggetlen (Zero-shot) generalizációs képességét a csupán fiziológiai alapon működő modellekhez képest?
- **RQ2:** Hogyan változik a predikció pontossága, ha a Zero-shot megközelítés helyett Few-shot paradigmát alkalmazunk, és ezen a téren mekkora előnyt jelent a statikus fúzió?
- **RQ3:** Milyen adat-előfeldolgozási lépések (pl. mozgóablakos szegmentáció, interpoláció, alany-szintű normalizálás) elengedhetetlenek ahhoz, hogy a hálózat képessé váljon a robusztus generalizációra?

2. Az adathalmazok és az előfeldolgozási pipeline

A modellek tanításához, kiértékeléséhez és a generalizációs képesség robusztusságának vizsgálatához elengedhetetlen volt olyan multimodális adathalmazok bevonása, amelyek elegendő elemszámot biztosítanak, és több modalitást is lefednek. A kutatás során két nyílt forráskódú adatbázist, a CLARE [1] és a SWELL-KW [2] adathalmazokat vizsgáltuk és alkalmaztuk.

2.1. Adathalmazok bemutatása és korábbi felhasználásuk a szakirodalomban

A kognitív terhelés és a stressz kutatásában a megfelelő minőségű adathalmaz kiválasztása kritikus lépés. A gépi tanulási modellek teljesítménye és generalizációs képessége közvetlenül függ a betanításra használt adatok minőségétől, a feladatok életszerűségétől és az annotációk (címkék) megbízhatóságától.

A SWELL-KW (SWELL Knowledge Work) adathalmaz

A jelen kutatás kísérleti gerincét a SWELL-KW [2] adatbázis adja, amelyet széleskörűen alkalmaznak a szakirodalomban a munkahelyi stressz és a kognitív állapotok detektálására.

- **Méret és résztvevők:** Az adatbázis 25 irodai dolgozó (tudásmunkás) adatait tartalmazza különböző mesterségesen előállított munkahelyi stresszhelyzetek során. Minden alany hozzávetőlegesen 3 órányi kísérleten vett részt.
- **Feladatok:** A kísérleti protokoll három fázisból állt: egy normál munkavégzési (relaxációs) szakaszból (pl. beszámoló írás és prezentációkészítés), egy időnyomás (Time Pressure) alatt végzett feladtból, valamint egy váratlan megszakításokkal (Interruption, pl. sürgős, beérkező e-mailek) terhelt szakaszból.
- **Elemek és modalitások:** A kutatók ezen feladatok közben folyamatos élettani méréseket végeztek. Az adathalmaz tartalmazza az elektrokardiogram (ECG) és a galvános bőrreakció (EDA/GSR) jeleit, emellett a résztvevők testtartását és vizuális arckifejezéseit is rögzítették.
- **Címkék (Labels):** A tanuláshoz a kimeneti címkéket egy bináris osztályozási feladathoz

igazítottuk. A normál munkavégzést alacsony terhelésnek (0. osztály), míg az időnyomást és megszakítást magas terhelésnek/stressznek (1. osztály) címkéztük.

- **Szakirodalmi háttér és következtetések:** Koldijk és munkatársai eredeti publikációjukban [2] klasszikus gépi tanulási algoritmusokat – elsősorban Támogatóvektor-gépeket (Support Vector Machines, SVM) – alkalmaztak a stressz felismerhetőségének vizsgálatára. Eredményeik tökéletesen alátámasztják a jelen kutatás problémafelvetését: kísérleteik során bebizonyosodott, hogy bár a modell egy adott alanyon betanítva (intra-subject) akár 90% körüli pontosságot is képes elérni, új személyekre történő általánosításkor (cross-subject / zero-shot generalizáció) a teljesítmény drasztikusan, véletlen tippelés szintjére esett vissza. A szerzők ezt az egyéni fiziológiai válaszok extrém diverzitásával magyarázták. Jelen kutatás ezt a problémát hidalja át a statikus adatok fúziójával.

A CLARE (Cognitive Assessment in Realtime with Multimodal Data) adathalmaz

A többmodalitású generalizáció és a kifejezetten szemkövetéses (eye-tracking) adatok komplexebb vizsgálata céljából egy frissebb, 2024-ben publikált adathalmazt, a CLARE adatbázist [1] is elemeztük. Ez az adathalmaz a nagy felbontású szenzorok és a sűrű címkézés miatt kiemelkedő fontosságú a területen.

- **Méret és résztvevők:** A CLARE 24 egészséges résztvevő folyamatos méréseit tartalmazza.
- **Feladatok:** A résztvevők a MATB-II (Multi-Attribute Task Battery) repülésszimulációs szoftverrel dolgoztak. Ez a program lehetővé teszi különböző kognitív terhelési szintek (alacsony, közepes, magas komplexitás) beállítását úgy, hogy a felhasználónak több párhuzamos feladatot (pl. célkövetés, üzemanyagszint-menedzsment, audió-kommunikációs feladatok) kell egyszerre megoldania.
- **Elemek és modalitások:** Az adatbázis kiemelkedően gazdag minőségi elemekben: 512 Hz-es ECG, 128 Hz-es EDA, és 256 Hz-es EEG mellett speciális szemüvegekkel (Tobii Pro) 50 Hz-es frekvenciával rögzítettek vizuális Gaze (tekintet) adatokat. A kinyerhető és elemezhető vizuális jellemzők (features) közé tartozik a bal és jobb pupilla átmérője, a pislogások száma, a fixációk, valamint a szakkádok (gyors szemmozgások) sebessége, gyorsulása és amplitúdója.
- **Címkék (Labels):** A CLARE egyik legnagyobb módszertani újítása a valós idejű, sűrű címkézés. A résztvevőknek minden 10. másodpercben egy 1-től 9-ig terjedő skálán (ahol az 1 a nagyon alacsony, a 9 a nagyon magas mentális erőfeszítés) verbálisan kellett jelenteniük az aktuális kognitív terhelésüket. Ez finomszemcsés (fine-grained), regressziós modellek tanítását is lehetővé teszi.
- **Szakirodalmi háttér és következtetések:** A CLARE megalkotói, Angkan és munkatársai [1] baseline modelljeik (CNN és Transformer alapú mélytanulós hálózatok) kiértékelésekor szintén felhívják a figyelmet a generalizációs szakadéokra. Kísérleteikben kimutatták, hogy a személyfüggetlen, kereszt-alanyos (Leave-One-Subject-Out) tesztelésnél az olyan komplex modellek, mint a Transformer, teljesítménye szignifikánsan elmarad az ismert alanyokon végzett 10-szeres keresztvalidáció (10-fold CV) eredményeitől. Ez megerősíti

azt az alaptételünket, miszerint pusztán az architektúra mélységének növelése nem elegendő a biológiai zaj áthidalásához.

2.2. A fiziológiai jellemzők (Features) és az előfeldolgozási módszertan

A kognitív állapotok becslésének egyik legnehezebb mérnöki feladata a folyamatos, folytonos idősoros jelek (raw signals) átalakítása olyan strukturált, diszkrét jellemzővektorokká, amelyeket a mesterséges neurális hálózatok hatékonyan képesek feldolgozni. A kísérleti keretrendszerben (tdk_framework) a **SWELL-KW** adathalmazra egy szigorú adatkinyerési és tisztítási pipeline-t alakítottunk ki.

A 13-dimenziós élettani vektor anatómiája

A kísérlet során a hálózat bemenetét nem közvetlenül a zajos nyers szenzoradatok, hanem abból kinyert, statisztikailag tömörített jellemzők (features) alkotják. A dinamikus bemenetet három fő fiziológiai modalitás biztosítja, amelyek mindegyike a vegetatív idegrendszer (Autonomic Nervous System, ANS), azon belül is a stresszreakcióért felelős szimpatikus, illetve a nyugalmi állapotért felelős paraszimpatikus ág működéséről ad objektív képet:

1. **HR (Heart Rate - Szívritmus):** A percenkénti szívverések száma. Bár az egyik legkönnyebben mérhető paraméter, önmagában a legkevésbé robusztus, mivel a fizikai aktivitás és a biológiai alapvonal (edzettségi szint, életkor) nagymértékben befolyásolja. Kognitív terhelés alatt a szimpatikus idegrendszer aktiválódása jellemzően a HR emelkedéséhez vezet.
2. **HRV - RMSSD (Heart Rate Variability - Szívritmus-változékonyság):** A szívverések közötti (R-R) intervallumok ingadozását méri. A kutatásban az RMSSD (Root Mean Square of Successive Differences) metrikát alkalmaztuk, amely az egymást követő szívverések közötti időkülönbségek négyzetes közepének gyöke. Orvosbiológiai szempontból a magas HRV (és RMSSD) a paraszimpatikus dominancia, azaz a relaxáció és a jó alkalmazkodóképesség jele. Stressz és magas kognitív terhelés hatására a szívritmus "gépiesebbé" válik, az RMSSD értéke pedig szignifikánsan lecsökken.
3. **SCL (Skin Conductance Level - Bőrellenállás/Galvános Bőrreakció):** Az elektrodermális aktivitás (EDA) tónusos komponense. A tenyéren és az ujjakon található ekkrin verejtékmirigyek aktivitását méri, amelyeket kizárólag a szimpatikus idegrendszer (a "fight-or-flight" válasz) vezérel. A kognitív terhelés és az arousal (éberségi szint) növekedésével a mikroszkopikus izzadás miatt a bőr elektromos vezetőképessége megnő (az ellenállás csökken). Ez teszi az SCL-t az egyik legmegbízhatóbb stressz-indikátorrá.

Időablakos szegmentáció és adattanítás

A hálózat nem pillanatnyi (milliszekundumos) mintákból dolgozik, hanem a fenti három modalitásból képzett **13-dimenziós vektorokat** használ bemenetként. Jogosan merül fel a kérdés: miért 13 dimenzió, és miért 1 perces ablakok?

A fiziológiai változások – különösen az endokrin és a vegetatív idegrendszeri reakciók (például a verejtékmirigyek válaszüzeje vagy a szívritmus-variabilitás mérhető változása) – viszonylag lassú

lefolyású folyamatok. Az olyan metrikák, mint az RMSSD, statisztikailag értelmezhetetlenek lennének néhány másodperces adatokból, mert nem tartalmaznának elég szívverést (R-R csúcsot) a variabilitás kiszámításához. Emiatt az adatbázisban a jellemzőket **1 perces ablakokban (time windows)** aggregálták az eredeti kutatók, és minden 1 perces ablakon belül kiszámolták az adott modalitások különböző statisztikai vetületeit (pl. átlag, medián, szórás, minimum, maximum). Ezen statisztikai vetületek összességéből áll elő a 13-dimenziós vektor, amely így rendkívül gazdag információsűrűséggel írja le azt az 1 percnyi biológiai állapotot.

A keretrendszerben a szekvenciális kontextus megőrzése érdekében egy mozgóablakos (sliding window) technikát implementáltunk. Az ablakméretet (window size) 3-ban, a lépésközt (stride) pedig 1-ben határoztuk meg. Ez azt jelenti, hogy a hálózat minden egyes predikciós lépésben az elmúlt 3 perc (3 darab 13-dimenziós vektor) élettani kontextusát vizsgálja egybevonva.

Adattisztítás és címkézés

A valós környezetben rögzített szenzoradatok óhatatlanul tartalmaznak mérési hibákat (artefaktumokat). Az adathalmazban található szenzorhibákat (melyeket az eredeti szerzők 999-es értékkel jelöltek) a pipeline során kiszűrtük, helyükre NaN értékeket rendeltünk, majd ezeket alanyonkénti átlagolással vagy interpolációval pótoltuk a folyamatos időszerelemzés megőrzése érdekében. Statikus jellemzőként, amely a Gated Fusion fúziós ágának bemenetét adja, a résztvevők kérdőíves demográfiai adatait – konkrétan az Életkort (Age) és a Nemet (Gender, binárisan kódolva) – integráltuk a vektorba.

A fent leírt előfeldolgozási és ablakozási metódus futtatása globálisan összesen **3115 mintát (ablakot)** eredményezett. Ebből 1505 darab a nyugalmi (0. osztály) és 1610 darab a terheléses (1. osztály) eset. Ez a feldolgozás egy kiemelkedően jó minőségű, szinte tökéletesen kiegyensúlyozott (balanced) adathalmazt biztosított a hálózat tanításához, minimalizálva az egyosztályos túltanulás (majority class bias) kockázatát.

3. Saját módszertan és architektúra

A kognitív terhelés objektív becslése egy tipikus multimodális gépi tanulási probléma, ahol egyszerre állnak rendelkezésre (ablakokból kinyert) dinamikus fiziológiai jelek, valamint konstans (statikus) metaadatok az alanyról vagy a feladat környezetéről. A kutatásunk során kidolgozott, a tdk_framework-ben implementált architektúra két fő komponensből áll: egy teljesen összekötött (Fully Connected) feldolgozó ágból a dinamikus adatokhoz, és egy egyedi Gated Fusion (FiLM) mechanizmusból, amely a statikus adatokat integrálja.

3.1. Mesterséges neurális hálózatok az affektív számítástechnikában

Az affektív számítástechnika (affective computing) és a kognitív állapotbecslés területén a korai kutatásokban jellemzően a klasszikus gépi tanulási (Machine Learning) algoritmusok domináltak. Az olyan felügyelt tanulási módszerek, mint a támogatóvektor-gépek (Support Vector Machines, SVM), a k-legközelebbi szomszéd (k-NN), vagy a Random Forest

algoritmusok elterjedtek voltak a stressz és a kognitív terhelés fiziológiai alapú detektálására. Ezeknek az algoritmusoknak az alkalmazása azonban egy kritikus szűk keresztmetszettel járt: nagymértékben támaszkodtak a kézi jellemzőkinyerésre (manual feature engineering). A kutatóknak előzetes orvosi vagy jelfeldolgozási domain tudás alapján kellett meghatározniuk, hogy a nyers élettani jelekből milyen statisztikai paramétereket és mintázatokat számítsanak ki a modell számára.

A kognitív terhelés mérése során rögzített emberi élettani adatok (például a szívritmus-változékonyság vagy a galvanos bőrellenállás) azonban eredendően zajosak, dinamikusak és erősen nemlineáris természetűek. Ami még ennél is nagyobb kihívást jelent, az a rendkívül magas inter-szubjektív variancia; az egyének biológiai alapvonalai, reaktivitása és a stresszre adott élettani válaszai drasztikusan eltérhetnek. Egy klasszikus algoritmus, amely merev, kézzel definiált szabályrendszerek és jellemzők alapján húzza meg a döntési határait, gyakran képtelen megfelelően általánosítani (generalizálni) egy új felhasználóra.

Ezt a módszertani korlátot a mesterséges neurális hálózatok (Artificial Neural Networks, ANN) és a mélytanulás (Deep Learning) megjelenése hidalta át. A neurális hálózatok legfőbb architektúráis előnye a reprezentációtanulás (representation learning) képességében rejlik. Ez a mechanizmus lehetővé teszi, hogy az algoritmus az egymást követő rejtett rétegein (hidden layers) keresztül, automatikusan és hierarchikusan vonja ki a feladat szempontjából leginkább releváns mintázatokat az adatokból, anélkül, hogy azokat a tervező előre, mereven definiálná.

A kognitív állapotok becslésénél a neurális hálózatok képesek felfedezni azokat a rejtett, sokdimenziós és nemlineáris összefüggéseket a fiziológiai vektorok között, amelyek emberi logikával vagy klasszikus statisztikával nehezen megragadhatók. Bár a jelen kutatás keretrendszerében a nyers idősorokat egy előfeldolgozási fázis során ablakozott jellemzővektorokká alakítjuk, a mélytanulós architektúra alkalmazása elengedhetetlen feltétele annak, hogy a modell elég robusztus legyen a biológiai zaj szűrésére. Ez a rugalmas reprezentációs tér adja meg az alapot ahhoz is, hogy a későbbi fázisokban a statikus demográfiai adatok fúziójával sikeresen kompenzáljuk az egyéni eltéréseket, és áttörjük a Zero-shot generalizáció korlátait.

3.2. A Teljesen Összekötött Hálózatok (FCN) és a Többrétegű Perceptron (MLP)

A kognitív terhelés becslésére szolgáló kísérleti keretrendszerben (tdk_framework) a dinamikus élettani adatok feldolgozását egy Teljesen Összekötött Hálózat (Fully Connected Network, FCN), vagy más néven Többrétegű Perceptron (Multilayer Perceptron, MLP) végzi. Az MLP az egyik legalapvetőbb előrecsatolt (feedforward) mesterséges neurális hálózati architektúra. Felépítése szigorúan strukturált rétegekből áll: egy bemeneti rétegből (input layer), egy vagy több rejtett rétegből (hidden layers), és egy kimeneti rétegből (output layer). Ebben az elrendezésben minden réteg minden egyes neuronja közvetlen, súlyozott kapcsolatban áll a következő réteg összes neuronjával (ezt jelöli a "teljesen összekötött" kifejezés). Ez a sűrű kapcsolati háló (dense connections) teszi lehetővé, hogy a hálózat rendkívül komplex,

nemlineáris leképezéseket tanuljon meg a bemeneti jellemzők és a kimeneti célváltozók között.

A gépi tanulásban a dinamikus, időben változó adatok (például az élettani jelek folytonos mérése) modellezésére gyakran alkalmaznak rekurrens neurális hálózatokat (RNN), mint például a Hosszú Rövidtávú Memória (LSTM) vagy a Kapuzott Rekurrens Egység (GRU), illetve egydimenziós konvolúciós hálózatokat (1D-CNN). A rekurrens hálózatok belső memóriaállapotuk révén kiválóan alkalmasak a szekvenciális időbeli függőségek leírására, míg a CNN-ek a lokális mintázatok (például hirtelen kiugrások a pulzusban) térbeli vagy időbeli kinyerésére specializálódtak. Ezen komplex architektúrák alkalmazása azonban jelentős számítási kapacitást, nagyobb memóriát és jóval több tanítási adatot igényel az alulillesztés (underfitting) elkerülése érdekében.

A jelen kutatás keretein belül a nyers idősoros adatokat egy szigorú előfeldolgozási lépés során mozgóablakos (sliding window) technikával szegmentáltuk. Ennek eredményeként a modell bemenete nem egy hosszú, változó hosszúságú nyers szekvencia, hanem egy előre kiszámított statisztikai jellemzőket tartalmazó, laposított (flattened), fix 13-dimenziós vektor ablakonként. Mivel az időbeli dinamika és a morfológiai információk nagy részét az ablakozás és a jellemzőkinyerés már strukturált formába öntötte, a mély szekvenciális modellek (mint a GRU) használata felesleges komplexitást vezetett volna be, ami növeli a túltanulás (overfitting) kockázatát egy korlátozott elemszámú adathalmazon. A laposított, alacsony dimenziószámú, de magas információsűrűségű bemeneti vektorok esetén az FCN/MLP architektúra bizonyult a leghatékonyabb és legrobosztusabb választásnak. A teljesen összekötött rétegek tökéletesen alkalmasak arra, hogy megtalálják a különböző élettani modalitások (például a pulzusszám és a bőrellenállás) közötti rejtett, nemlineáris keresztkorrelációkat egy adott időablakon belül, mindezt kiemelkedő számítási hatékonyság mellett.

3.3. A hálózat matematikai építőelemei és tanulási folyamata

A fent bemutatott Többrétegű Perceptron (MLP) architektúra működése alapvető lineáris algebrai műveletekre és nemlineáris matematikai transzformációkra épül. A hálózat tanulási képessége ezen építőelemek iteratív optimalizálásából fakad.

Lineáris rétegek (Dense / Linear layers)

Az architektúra gerincét a teljesen összekötött, lineáris rétegek adják. Egy ilyen réteg feladata, hogy a bemeneti teret – jelen esetben például az időablakokból kinyert 13-dimenziós fiziológiai jellemzővektort – egy új, magasabb vagy alacsonyabb dimenziójú rejtett reprezentációs térbe transzformálja. Matematikailag egy lineáris réteg működése az alábbi affin transzformációval írható le:

$$y = Wx + b$$

ahol:

- x jelöli a bemeneti vektort (vagy az előző réteg kimenetét).
- W a súlymátrix (weight matrix), amely a réteg neuronjai közötti kapcsolatok erősségét kódolja.
- b a torzítási vektor (bias), amely biztosítja a transzformáció eltolhatóságát az origótól, így rugalmasabb döntési határokat téve lehetővé.
- y a réteg nyers, lineáris kimenete.

A betanítási (training) fázis során a hálózat célja a hiba-visszaterjesztés (backpropagation)

algoritmus segítségével úgy optimalizálni a W súlyokat és a b torzításokat, hogy minimalizálja a predikciós hibát. Biológiai és fiziológiai kontextusban ez a folyamat jelenti a *tanulást*: a hálózat a súlyok módosításán keresztül automatikusan megtanulja, hogy az egyes jellemzőknek (például a pulzusvariabilitás csökkenésének vagy a bőrellenállás hirtelen növekedésének) mekkora relatív fontosságot, azaz súlyt kell tulajdonítani a stressz-szint meghatározásakor.

Aktivációs függvények és a nemlinearitás szerepe

Bár a lineáris rétegek hatékonyan képesek skálázni és kombinálni a bemeneti jellemzőket, önmagukban elégtelenek a kognitív terheléshez hasonló komplex jelenségek modellezésére. Ha egy neurális hálózat kizárólag lineáris rétegekből állna, akkor – függetlenül a rétegek számától – az egész hálózat matematikai értelemben összevonható lenne egyetlen

$y = W'x + b'$ lineáris transzformációvá. Ez azt eredményezné, hogy a modell legfeljebb csak egyszerű lineáris regresszióra lenne képes, és elbukna az élettani változók közötti bonyolult összefüggések megragadásában.

Ennek elkerülése érdekében minden lineáris réteget egy nemlineáris **aktivációs függvény** követ. Az aktivációs függvények bevezetésével a hálózat képessé válik görbült döntési felületek kialakítására, ami a magas dimenziós feladatoknál elengedhetetlen. A tdk_framework keretrendszerben két meghatározó aktivációs függvényt alkalmazunk:

1. **ReLU (Rectified Linear Unit):** A hálózat rejtett rétegeiben (hidden layers) a ReLU aktivációs függvényt alkalmazzuk. Matematikai definíciója rendkívül egyszerű:

$$f(x) = \max(0, x)$$

A ReLU minden negatív értéket nullára cserél, a pozitív értékeket pedig változatlanul hagyja. Számítási szempontból rendkívül hatékony, emellett a mély hálózatokban enyhíti az eltűnő gradiens (vanishing gradient) problémáját, ami stabilabb és gyorsabb konvergenciát eredményez a betanítás során.

2. **Sigmoid:** Mivel a kognitív terhelés becslését bináris osztályozási feladatként fogalmaztuk meg (0: alacsony terhelés, 1: magas terhelés), a hálózat utolsó kimeneti rétegén (output

layer) a Sigmoid függvényt alkalmazzuk. Ennek képlete:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

A Sigmoid függvény a nyers lineáris kimenetet (logits) a $(0, 1)$ nyílt intervallumba "préseli". Ez a kimenet közvetlenül értelmezhető valószínűségként (probability): minél közelebb van az érték az 1-hez, a hálózat annál nagyobb magabiztossággal jelzi a magas kognitív terhelés vagy stressz jelenlétét az adott időablakban.

Veszteségfüggvény (Binary Cross-Entropy)

A hálózat felépítése (az előrecsatolt, *forward pass* folyamat) után definiálni kell, hogyan értékeli ki a saját predikcióit, és miként tanul a hibáiból. Mivel a kognitív terhelés becslését egy bináris osztályozási problémaként fogalmaztuk meg, a hiba kiszámítására a bináris keresztentropia (Binary Cross-Entropy, BCE) veszteségfüggvényt alkalmazzuk. A hiba-visszaterjesztés során a hálózat célja ennek az értéknek a minimalizálása.

A BCE matematikai formulája egy N elemű kötegre (batch) az alábbiak szerint írható fel:

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

ahol:

- $y_i \in \{0, 1\}$ a valódi, elvárt osztálycímke (ground truth).
- $\hat{y}_i \in (0, 1)$ a hálózat Sigmoid rétege által adott predikció, ami a magas terhelés valószínűségét fejezi ki.

A logaritmus büntetés biztosítja, hogy ha a hálózat nagy magabiztossággal téved (például 0.99-es valószínűséget jósol egy ténylegesen nyugalmi, $y_i = 0$ állapotra), a veszteség értéke drasztikusan megnőjön. Ez a karakterisztika különösen fontos a fiziológiai jeleknél, ahol a fals pozitív vagy fals negatív riasztások kritikusak lehetnek egy valós idejű monitorozó rendszerben.

Súlyfrissítés és az Adam optimalizáló

A hiba kiszámítása után az optimalizáló algoritmus feladata a hálózat súlyainak (W) és torzításainak (b) frissítése a gradiensereszkedés elve alapján. A `tdk_framework`

keretrendszerben ehhez az Adam (Adaptive Moment Estimation) optimalizálót használtuk, amely a jelenlegi gépi tanulási gyakorlat egyik legrobusztusabb algoritmus.

A klasszikus sztochasztikus gradiensereszkedéssel (SGD) szemben az Adam nem egyetlen globális tanulási rátát használ minden paraméterre, hanem adaptívan, paraméterenként állítja be azt. Az algoritmus kiszámítja a gradiensek első momentumát (az átlagot, m_t) és második momentumát (a nem központosított varianciát, v_t) egy exponenciálisan simított mozgóátlag segítségével:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

ahol g_t az aktuális gradiens a t -edik

lépésben, a β_1 és β_2 pedig a felejtési tényezők. Egy torzítás-korrekción (bias correction) után a hálózat paramétereinek (θ) frissítése a következő képlettel történik:

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

ahol η az alap tanulási ráta. Az affektív

számítástechnikában az Adam használata azért jelent óriási előnyt, mert az élettani jelek (például a szívritmus és a bőrellenállás) dinamikája és skálája jelentősen eltérhet. Az Adam adaptív természete biztosítja, hogy a ritkábban frissülő, de fontos összefüggéseket hordozó jellemzők megfelelő lépközt kapjanak a tanulás során, felgyorsítva a modell konvergenciáját.

3.4. A Batch Normalization (Kötegelt Normalizálás) létfontossága

A mély neurális hálózatok tanítása során az egyik legnagyobb kihívást az úgynevezett *belső kovariánseltolódás* (internal covariate shift) jelenti. Ahogy a hálózat tanul, és a korábbi rétegek súlyai módosulnak, a későbbi rétegekbe érkező aktivációk eloszlása is folyamatosan változik. Ennek kiküszöbölésére alkalmazzuk a Batch Normalization (kötegelt normalizálás) technikát a rejtett rétegekben.

A Batch Normalization működési elve, hogy a hálózaton átfolyó adatokat kötegenként (mini-batch) normalizálja. Matematikailag kiszámolja az adott kötegre tartozó minták átlagát (μ) és szórását (σ), majd ezek alapján úgy transzformálja a bemenetet, hogy annak eloszlása

nulla várható értékű ($\mu = 0$) és egységnyi szórású ($\sigma^2 = 1$) legyen. Végül a hálózat tanulható skálázó (γ) és eltoló (β) paraméterekkel nyeri vissza a reprezentációs rugalmasságát.

Biológiai relevancia és a hálózat stabilitása

Bár a Batch Normalization a számítógépes látásban (computer vision) elsősorban a tanítás felgyorsítására szolgál, az affektív számítástechnikában és a fiziológiai jelfeldolgozásban ennél sokkal kritikusabb szerepe van: megakadályozza a hálózat összeomlását az egyéni biológiai különbségek miatt.

A fiziológiai jelek (például a pulzusszám vagy a bőrellenállás) esetében a biológiai alapvonalak folyamatos ingadozást és eltolódást mutatnak. Egyik alany nyugalmi pulzusa lehet 60 bpm, míg egy másiké 85 bpm. Ha egy 85 bpm-es értéket kap a hálózat, normalizálás nélkül a lineáris rétegek ezt drasztikus stresszválaszként értelmezhetik az első alany esetében, miközben a másodikonál ez csak a normál biológiai működés része. A Batch Normalization lényegében egy automatikus, hálózaton belüli dinamikus alapvonal-korrekcióként (baseline correction) működik. A kötegelt átlag és szórás kiszámításával a hálózat nem az abszolút biológiai értékeket tanulja meg, hanem a relatív kilengéseket (zajokat és trendeket) az aktuális köteg kontextusában.

3.5. A fúziós architektúra kialakítása (Gated Fusion & FiLM)

A kísérletünk kulcseleme a dinamikus (F_{dyn}) és a statikus (x_s) adatok hatékony egyesítése. A hagyományos multimodális hálózatok leggyakrabban az úgynevezett késői fúziót (late fusion) vagy az egyszerű konkatenációt (összefűzést) alkalmazzák. Azonban az emberi fiziológia esetében a statikus adatok (például az életkor vagy a nem) nem csupán "plusz információk", hanem a dinamikus reakciók *kontextusát* jelentik. Például egy 50 éves alany pulzusváltozása ugyanakkora stressz hatására biológiailag eltérhet egy 25 éves alanyétól.

Ezt a kontextualizációt egy FiLM (Feature-wise Linear Modulation) [5] ihlette kapuzó mechanizmussal, a Gated Fusion-nel oldottuk meg a keretrendszerben. A módszer lényege, hogy a statikus hálózati ág nem közvetlenül a kimeneti predikcióba szól bele, hanem módosítja – "áthangolja" – a dinamikus ág belső reprezentációját.

A statikus bemeneti vektort (x_s) – amely a SWELL-KW esetében egy 2-dimenziós vektor (Életkor, Nem) – egy teljesen összekötött (Dense) rétegen küldjük keresztül, amely két, a dinamikus reprezentációval megegyező dimenziójú vektort állít elő:

- γ (gamma): Egy skálázó tényező.
- β (béta): Egy eltoló tényező.

A fúzió matematikai megfogalmazása az alábbi affin transzformáció:

$$F_{out} = \gamma \odot F_{dyn} + \beta$$

ahol a $\odot$ az elemenkénti szorzást jelöli. Ez

az elrendezés lehetővé teszi, hogy a statikus adatok alapján a hálózat felerősítse vagy elnyomja a Batch Normalizált dinamikus hálózat által kinyert bizonyos fiziológiai jellemzőket.

Várakozásaink szerint ez a feltételes kondicionálás az, amely képessé teszi a modellt arra, hogy egy új alany statikus paramétereit meglátva a hálózat azonnal a megfelelő biológiai lencsén keresztül értelmezze a beérkező adatokat, ezzel áthidalva a generalizációs szakadékot.

4. Kísérleti rendszer és kiértékelési keretrendszer

[Tanulas Keretrendszer Tablazat]

A kidolgozott Gated Fusion architektúra és a multimodális adatok hiteles kiértékeléséhez egy robusztus, PyTorch-alapú kísérleti keretrendszert (tdk_framework) fejlesztettünk ki. A keretrendszer elsődleges célja annak objektív mérése volt, hogy a különböző szintű personalizáció és a statikus adatok mennyiben befolyásolják a modell prediktív teljesítményét. Ennek érdekében a kísérleteket három, szigorúan elkülönített tanulási paradigmában (Zero-shot, Few-shot és Intra-subject) végeztük el.

4.1. Tanulási paradigmák és adatfelosztás

A szakirodalomban gyakori hiba a nem megfelelő adatvágásból fakadó adatszivárgás (data leakage). Ennek elkerülése érdekében az egyes paradigmákat az alábbiak szerint definiáltuk és implementáltuk a tesztelő szkriptben (train_paradigms.py):

1. Zero-shot (LOSO - Leave-One-Subject-Out) paradigma:

A legszigorúbb generalizációs teszt. A rendelkezésre álló N darab alanyból a modellt $N - 1$ alany adatain tanítottuk be, majd a teljesen elkülönített, a modell számára

"ismeretlen" N -edik alanyon teszteltük. Ezt a folyamatot minden alanyra megismételtük (cross-validation). Ennek a paradigmának a futása során minden egyes fold (hajtás) végén elmentettük a modell aktuális súlyait, amely a későbbi Few-shot finomhangolás alapjául szolgált.

2. Intra-subject (Személyre szabott) paradigma:

Ebben a megközelítésben minden alanyhoz egy saját, izolált modellt képeztünk ki. A kísérlet során egy adott alany saját adatbázisát egy **rétegzett (stratified) 80/20-as vágással** osztottuk fel tanító és tesztalmazra. A rétegzés (melyet a scikit-learn könyvtár biztosított) kritikus lépés volt: biztosította, hogy mind a tanító, mind a tesztelő halmazba arányosan kerüljenek stresszes és nyugalmi ablakok, elkerülve a tisztán egyosztályos foldok kialakulását. A modell kizárólag a 80%-os halmazon tanult, és a maradék 20%-on vizsgázott.

3. Few-shot (Finomhangolás / Fine-tuning) paradigma:

Ez a módszer a Zero-shot és az Intra-subject paradigmák közötti hidat képezi. Bemenetként a LOSO validáció során már betanított, "általános" alapmodellt kapta. Ez az alapmodell egy rétegzett vágás során megkapta az adott (ismeretlen) tesztalany adatainak 20%-át egy rövid kalibrációs szakasz erejéig (fine-tuning). Miután a modell az alany saját adataival frissítette a súlyait, a teljesítményét a maradék, továbbra is láthatatlan 80%-on értékeltük ki.


Megjegyzés a kísérleti keretrendszer technikai stabilitásához: A keretrendszer folyamatos futása érdekében a beépített pipeline automatikusan kezeli a magányos (Batch size = 1) tesztadatokat is, elkerülve ezzel, hogy a program a belső belső normalizációs számítások során hibaüzenettel leálljon.

4.2. Kiértékelési metrikák

(Kidolgozás alatt)

5. Eredmények és diszkusszió

A kutatás során felállított tanulási paradigmák kiértékelése a Globális AUROC metrika alapján történt, amely robusztus képet ad a Gated Fusion modell teljesítményéről az egyensúlyozatlan osztályeloszlások ellenére is. Az eredmények egyértelműen rámutatnak a kognitív terhelés becslésének legfőbb kihívására: az élettani reakciók (szívritmus, bőrellenállás) magas fokú egyéni variációjára.



[paradigm_comparison.png Ábra: A Zero-shot, Few-shot és Intra-subject paradigmák Globális AUROC eredményei]

A teljesen személyfüggetlen, **Zero-shot (LOSO)** kiértékelés során a modell 0.57-es AUROC értéket ért el. Ez az eredmény, amely alig haladja meg a véletlen tippelés (0.50) szintjét, empirikusan bizonyítja a kutatás alapfeltevését: egy pusztán fiziológiai adatokon betanított, "dobozból kivett" általános modell nem képes megbízhatóan predikálni egy korábban sosem látott felhasználó kognitív állapotát. Az inter-szubjektív biológiai különbségek elnyomják a

feladatnehezésgből fakadó mintázatokat.

Ezzel szemben az **Intra-subject** paradigma, ahol a modell dedikáltan egyetlen felhasználó adatain tanult és tesztelt, kiemelkedő, 0.89-es AUROC értéket produkált. Ez a pontosság igazolja, hogy a kinyert dinamikus élettani jellemzők (HR, RMSSD, SCL) és a modell architektúrája önmagukban rendkívül magas prediktív erővel bírnak. A hálózat képes pontosan felismerni a kognitív terhelést, feltéve, hogy a betanítás során lehetősége van adaptálódni az adott személy specifikus biológiai alapvonalához.

A valós ipari alkalmazhatóság szempontjából a legfontosabb eredményt a **Few-shot (Fine-tuning)** paradigma hozta. A Zero-shot alapmodell mindössze 20%-nyi (néhány perces kalibrációnak megfelelő) egyéni adattal történő finomhangolása az AUROC értéket 0.57-ről 0.73-ra növelte. Ez a szignifikáns teljesítményugrás közvetlen választ ad a második kutatási kérdésre (RQ2): a minimális kalibrációs adat bevonása és a statikus kontextus fúziója sikeresen hidalja át a generalizációs szakadékot. Bár az Intra-subject paradigma 0.89-es pontosságát nem éri el, a Few-shot megközelítés egy skálázható, a gyakorlatban is bevethető kompromisszumot kínál az ember-gép interfészek (HCI) számára.

5.1. A statikus adatok fúziójának pszichofiziológiai háttere (Diszkusszió)

A statikus adatok (Életkor és Nem) bevonásával elért szignifikáns teljesítménynövekedés (0.57-ről 0.73-ra a Few-shot paradigmában) nem csupán egy gépi tanulási anomália, hanem mély pszichofiziológiai okokra vezethető vissza. A fiziológiai paraméterek alapvonalai (baseline) és a stresszre adott reaktivitás ugyanis erősen függenek ezektől a demográfiai változóktól.

Az életkor hatása a szívritmus-változékonyságra (HRV):

Az öregedéssel az emberi vegetatív idegrendszer rugalmassága, és ezzel együtt a paraszimpatikus tónus természetes módon csökken. Ennek következtében az idősebb felnőttek nyugalmi szívritmus-változékonysága (például az RMSSD érték) anatómiailag alacsonyabb, mint a fiatalabbaké. Ha egy pusztán dinamikus adatokon betanított (Zero-shot) modell kap egy eleve alacsony HRV adatot egy 55 éves alanytól, azt tévesen extrém kognitív túlterhelésként vagy stresszként interpretálhatja, hiszen egy 25 évesnél ez az érték valóban pánikállapotot jelezne. A kapuzott fúzió (Gated Fusion) révén a hálózat megtanulja az "életkor-kontextust": a FiLM réteg az idősebb kor láttán módosítja a dinamikus ág súlyait, lényegében eltávolítja a döntési határt, és megtanulja, hogy ennél a felhasználónál a biológiai alapvonal természetéből fakadóan alacsonyabb.

A nemi különbségek az elektrodermális aktivitásban (EDA/SCL):

Hasonló biológiai diverzitás figyelhető meg a nemek között a stresszválaszok terén. Bár mindkét nemnél a szimpatikus idegrendszer aktiválja a verejtékmirigyeket (SCL), a szakirodalom rámutat arra, hogy a nők és férfiak bőrének vezetőképessége, a verejtékmirigyek sűrűsége, valamint a hormonális ingadozások (amelyek hatással vannak a testhőmérsékletre és az

alap-bőrellenállásra) eltérőek. Továbbá a kognitív terhelésre adott kardiovaszkuláris reaktivitás mértéke is mutathat nemi különbségeket.

Összességében a statikus kontextus bevonása azért működik, mert a Gated Fusion hálózat kvázi egy "dinamikus biológiai lencsét" hoz létre. A modell ahelyett, hogy univerzális, merev küszöbértékek alapján próbálná megítélni a stresszt, a bejövő statikus adatok alapján egyéni, kontextusfüggő normálértékeket állít be a hálózaton belül. Ez bizonyítja, hogy a robusztus generalizáció eléréséhez elengedhetetlen a biológiai diverzitás modellezése.

6. Összefoglalás és jövőbeli munkák

(Kidolgozás alatt)

Hivatkozások

- [1] P. Angkan, et al., "CLARE: Cognitive Load Assessment in Real-time with Multimodal Data," *IEEE Transactions on Cognitive and Developmental Systems*, 2024.
- [2] W. Kraaij, S. Koldijk, M. Sappelli, "The SWELL Knowledge Work Dataset for Stress and User Modeling Research", *Proceedings of the 16th International Conference on Multimodal Interaction (ICMI)*, 2014.
- [3] X. Yin, et al., "Zero-shot learning for emotion recognition: A comprehensive review," *IEEE Transactions on Affective Computing*, 2021.
- [4] Y. Wang, et al., "Generalizing from a Few Examples: A Survey on Few-shot Learning," *ACM Computing Surveys*, 2020.
- [5] E. Perez, et al., "FiLM: Visual Reasoning with a General Conditioning Layer," *AAAI Conference on Artificial Intelligence*, 2018.
- [6] J. Sweller, "Cognitive load during problem solving: Effects on learning," *Cognitive Science*, 1988.